



Super resolución en simulaciones cosmológicas

Diego Antonio Villalba González

Asesor: Dr. José Alberto Vázquez

Ciudad de México, 25 de junio de 2025



INSTITUTO DE
CIENCIAS
FÍSICAS



Facultad de
Ciencias
UNAM



Resumen

Contexto y problemática

Las simulaciones cosmológicas enfrentan un compromiso latente entre resolución y costo computacional; el estudio de estructuras como halos o filamentos pequeños requiere simulaciones de alto coste computacional y de almacenamiento.

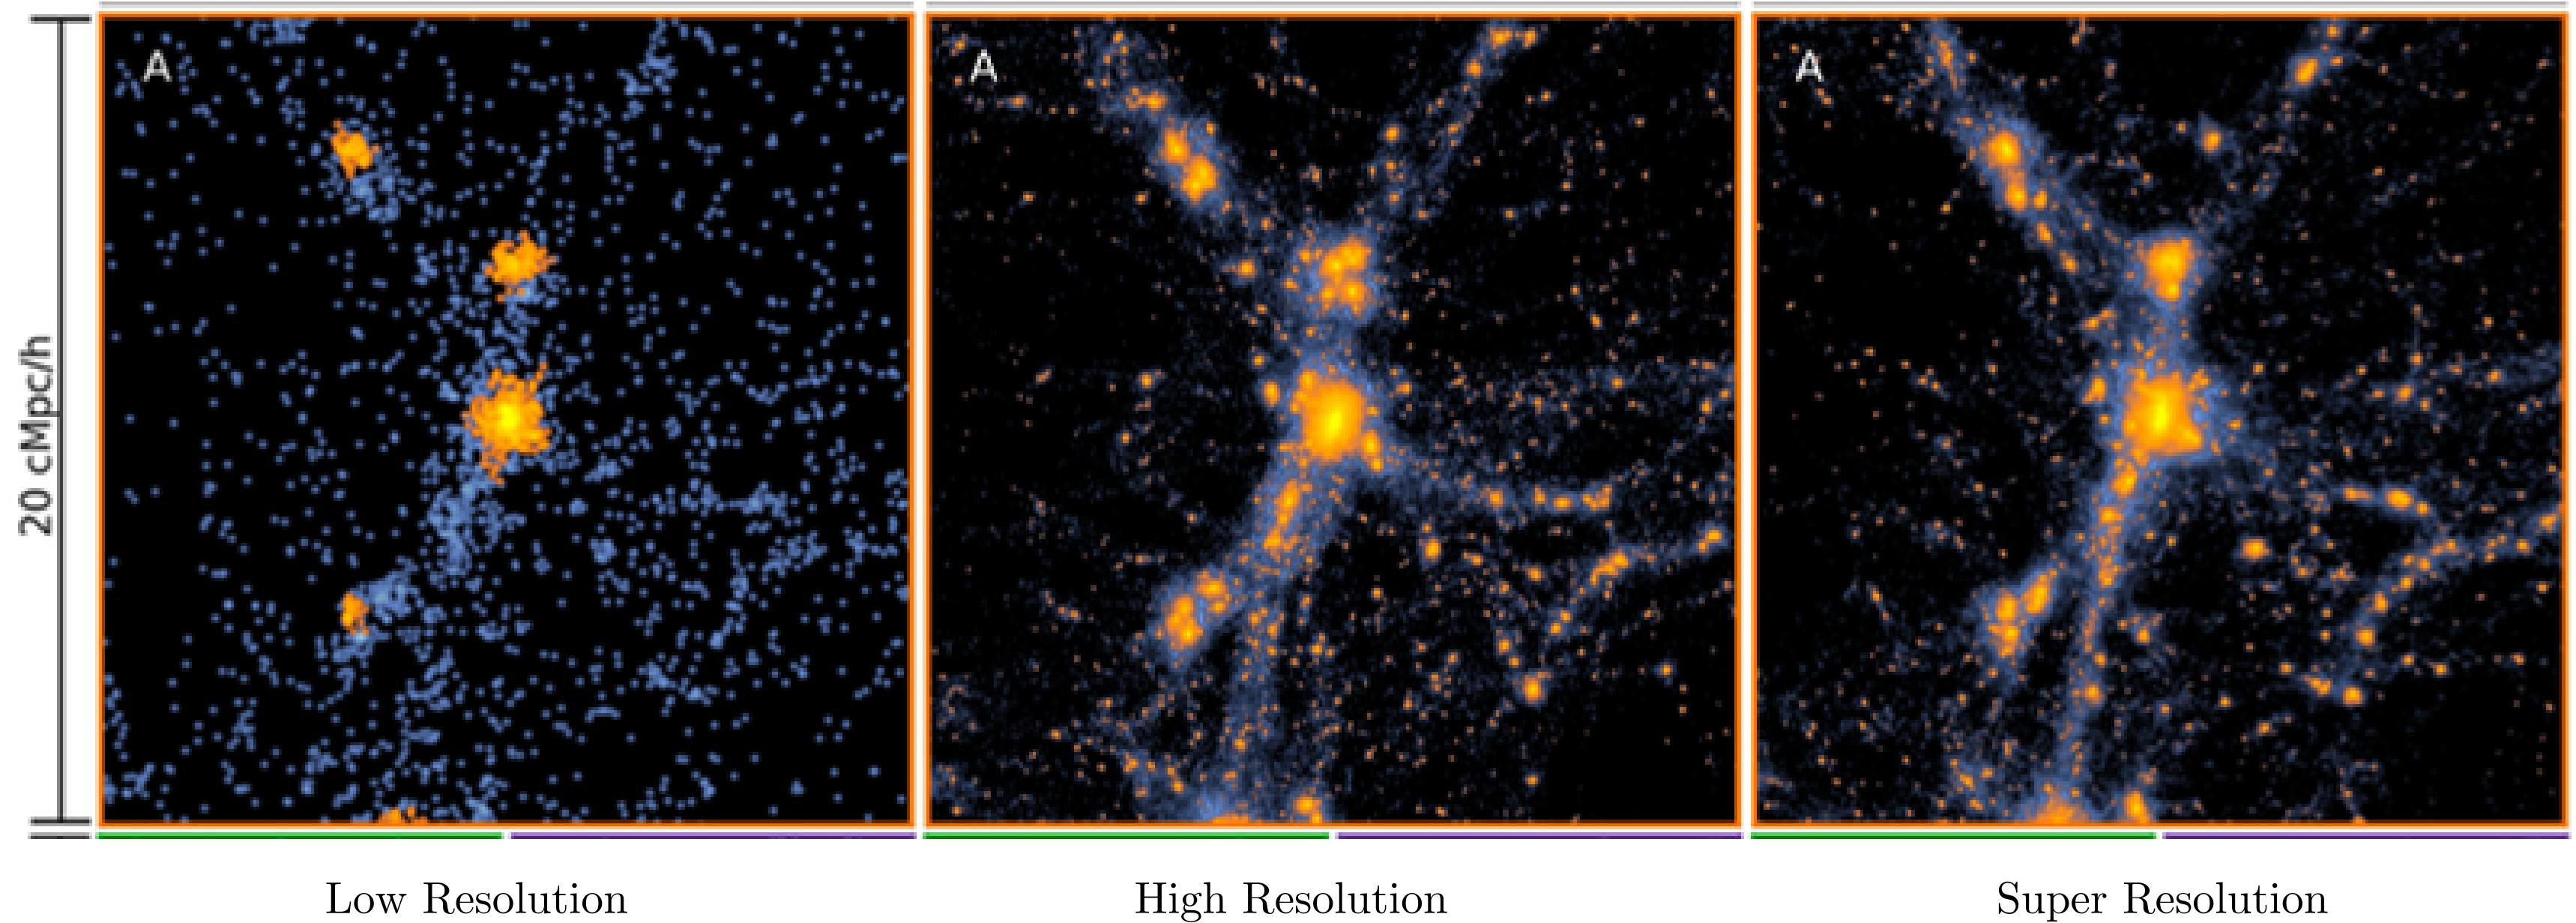
Para abordar esto, desde hace algunos años se han empleado modelos de redes neuronales generativas profundas como GANs y VAEs para mejorar la resolución de simulaciones cosmológicas de un menor costo computacional, permitiendo recuperar estructuras a pequeña escala en muy poco tiempo.

Sin embargo, estos enfoques presentan desafíos: desde inestabilidad en el entrenamiento, pérdida de información estadística, generación de artefatos hasta falta de interpretabilidad física.



Resumen

Contexto y problemática



Li, Y., Ni, Y., Croft, R. A. C., Di Matteo, T., Bird, S., & Feng, Y. (2021). AI-assisted super-resolution cosmological simulations. arXiv:2010.06608



Resumen

Enfoque del trabajo

En este trabajo se incorpora la Transformada escalonada de Wavelets (WST) (basandonos en su capacidad para una representación estable ante deformaciones y sensible a la no-Gaussianidad) en una arquitectura de red generativa profunda residual. Con el objetivo de aumentar la resolución del campo de densidad de materia oscura obtenido en la simulación Illustris-3 alcanzando resultados comparables con los obtenidos en la simulación de mayor resolución Illustris-2.

Evaluamos la calidad de estos resultados estimando parámetros cosmológicos como el espectro de potencias y la abundancia de halos.

Concluimos que este método nos permite recrear modelos más interpretables y físicamente consistentes en grandes y medianas escalas, dandonos la capacidad reconstruir simulaciones a partir de datos limitados.



Índice

2 Super resolución

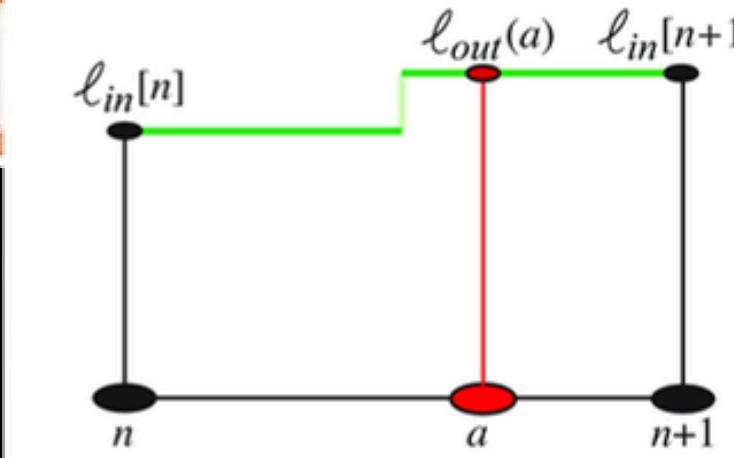
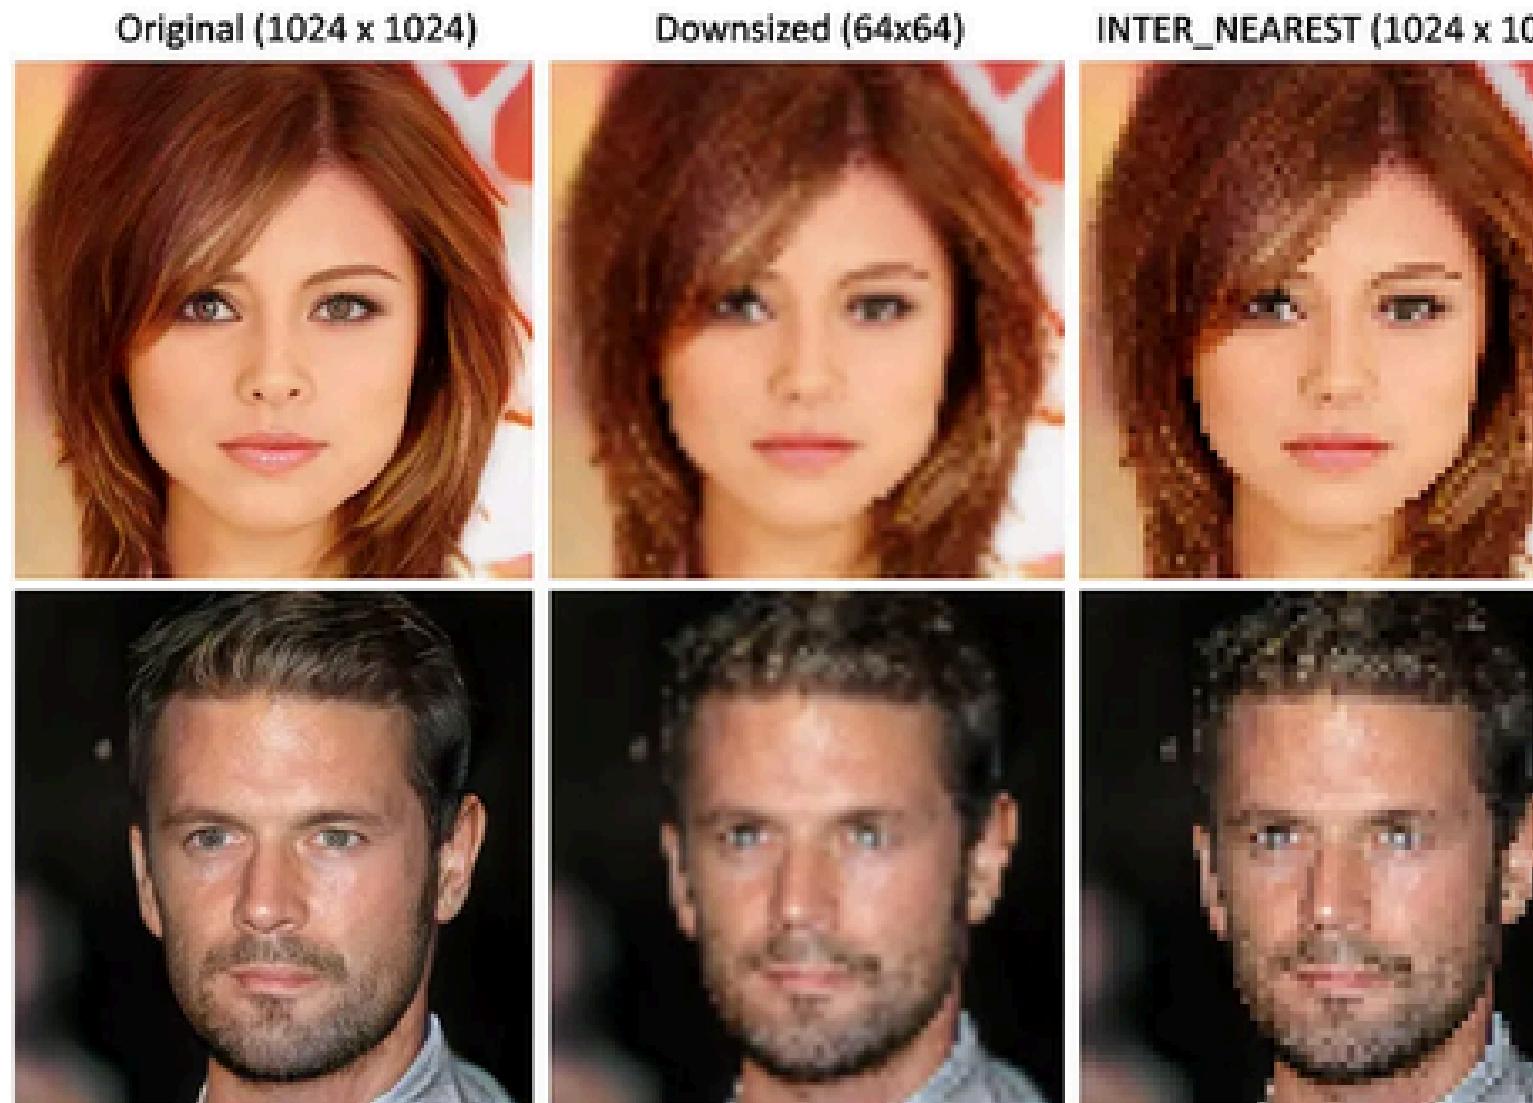
- Introducción
- **Super resolución**
- Wavelets
- Nuestro trabajo
- Referencias

Procesos clásicos en el aumento de resolución

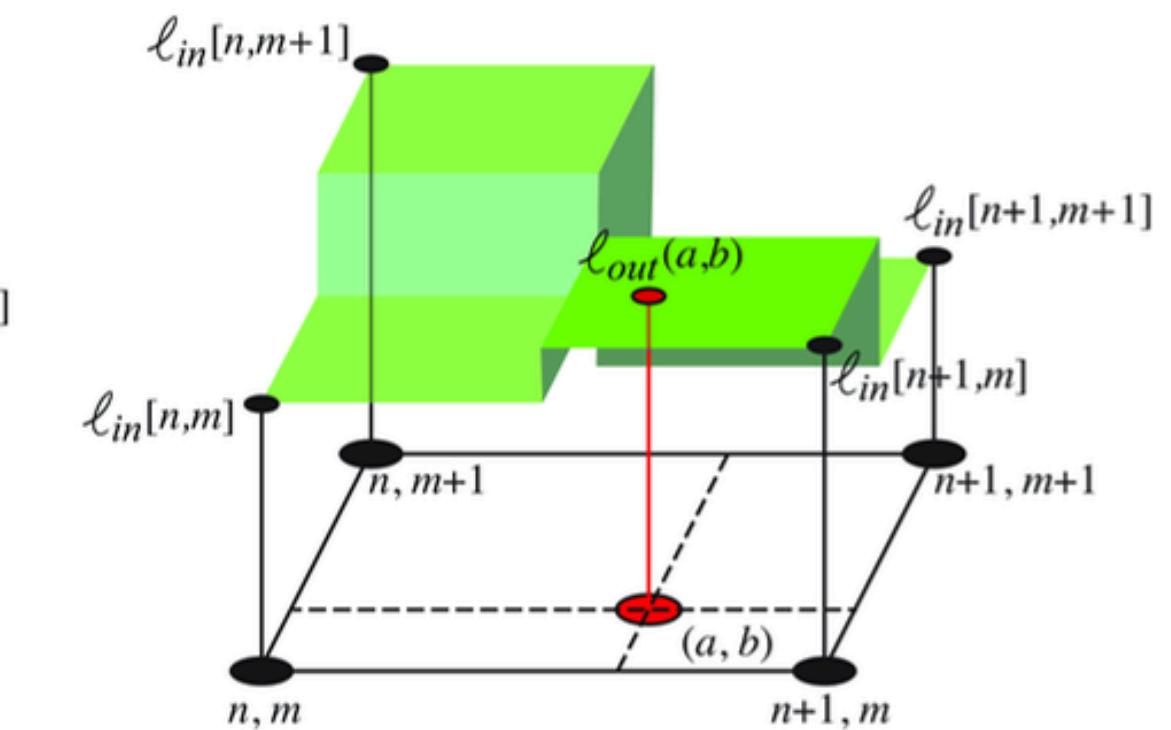
Interpolaciones

Las primeras ideas para el aumento de resolución de imágenes no provienen del deep learning, nacen con el campo de la visión computacional, surgiendo los conocidos métodos de interpolación entre píxeles:

Vecino más cercano



(a) 1D Nearest neighbor interpolation



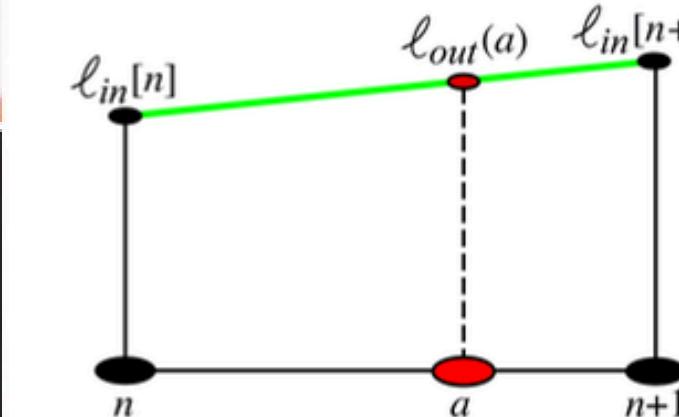
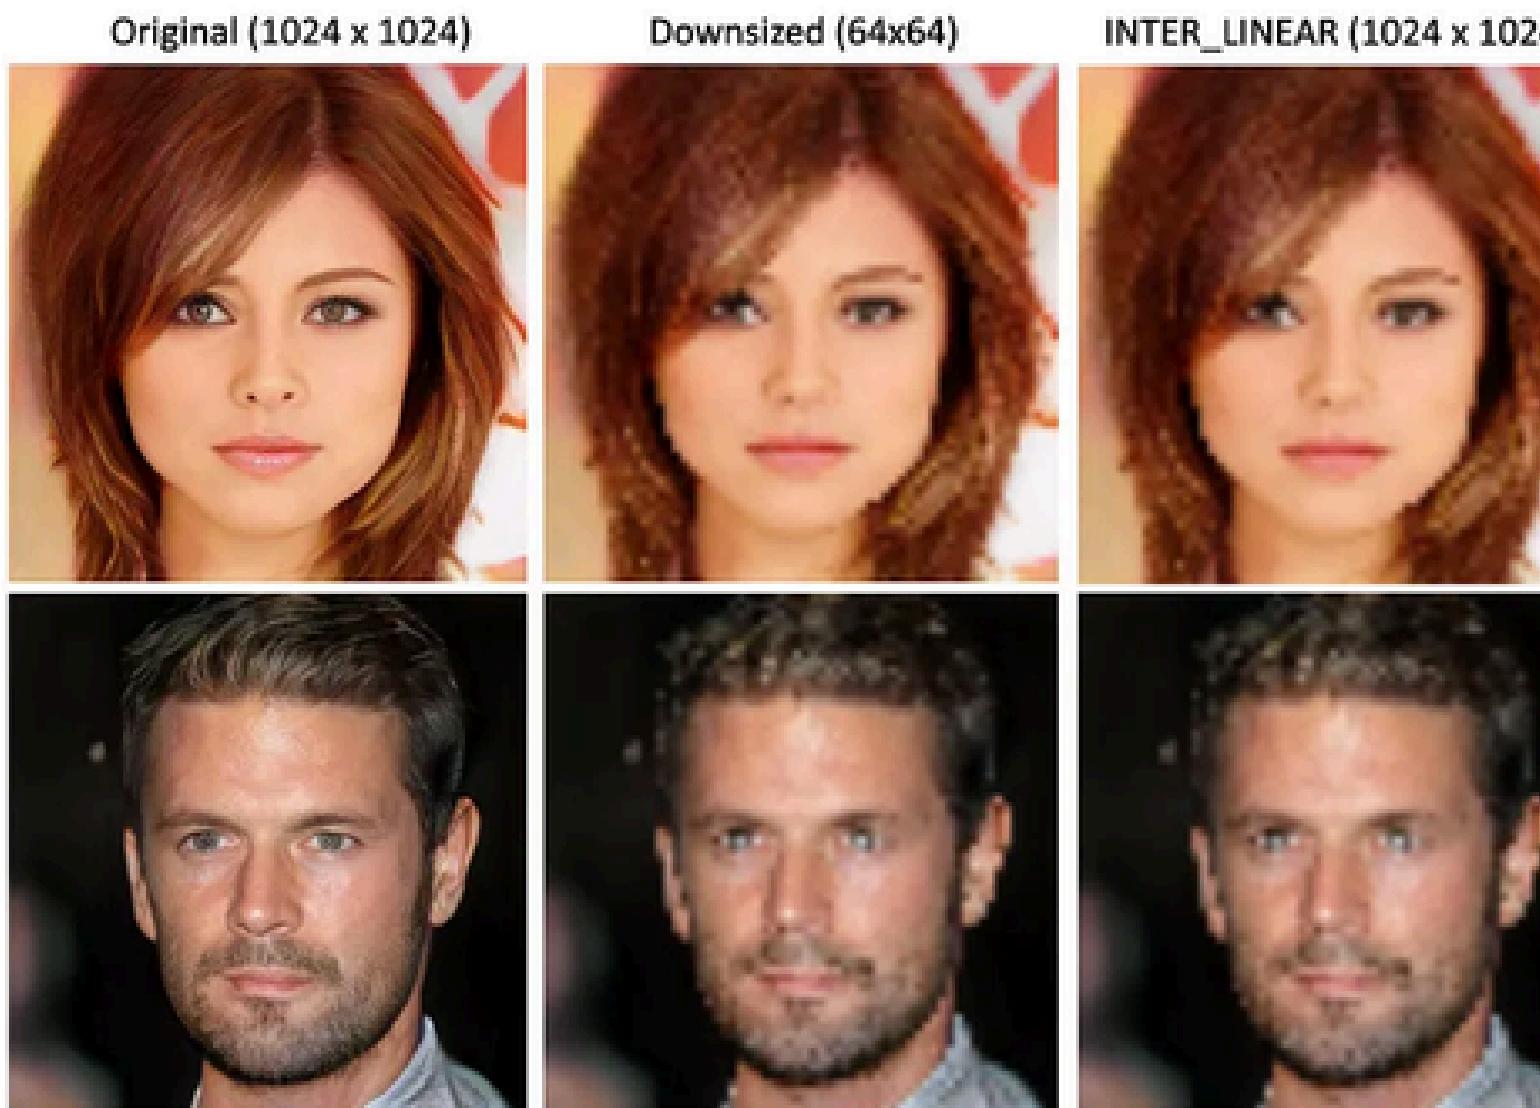
(b) 2D Nearest neighbor interpolation

Procesos clásicos en el aumento de resolución

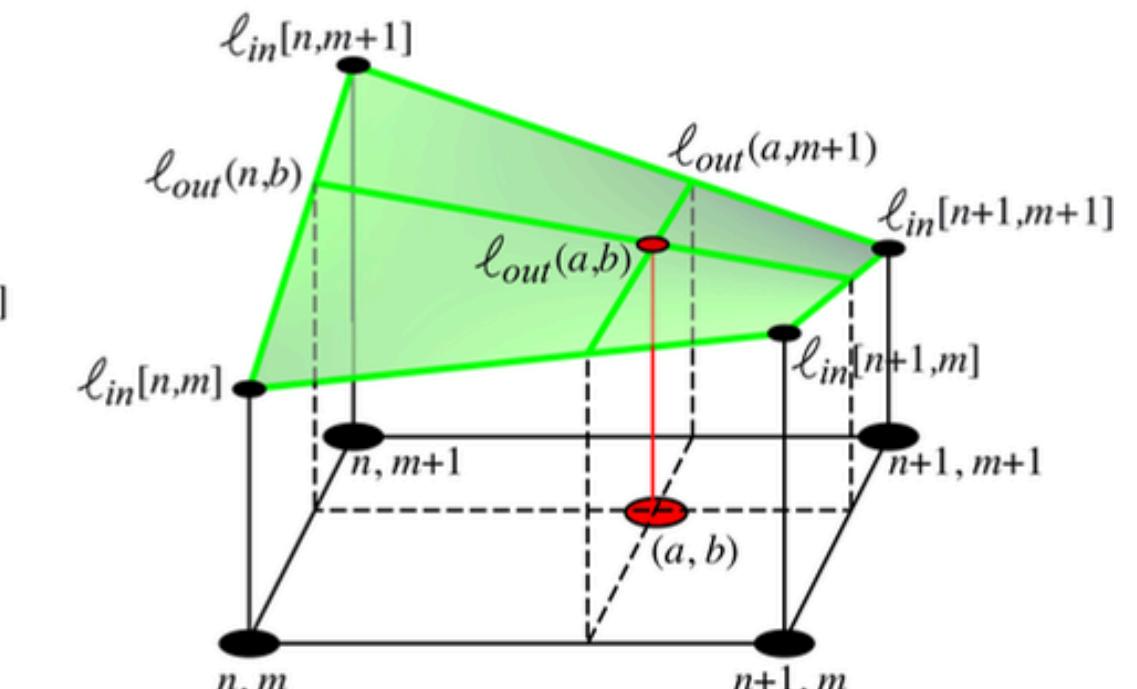
Interpolaciones

Las primeras ideas para el aumento de resolución de imágenes no provienen del deep learning, nacen con el campo de la visión computacional, surgiendo los conocidos métodos de interpolación entre píxeles:

Bilineal



(a) Linear interpolation



(b) Bilinear interpolation



Los desafíos de la súper resolución

Interpolaciones

El reto mas importante en el desarrollo de la super resolución se encuentra en recuperar la información perdida durante el proceso de degradación de la imagen, multiples imágenes de alta resolución corresponden a una misma imagen de baja resolución.



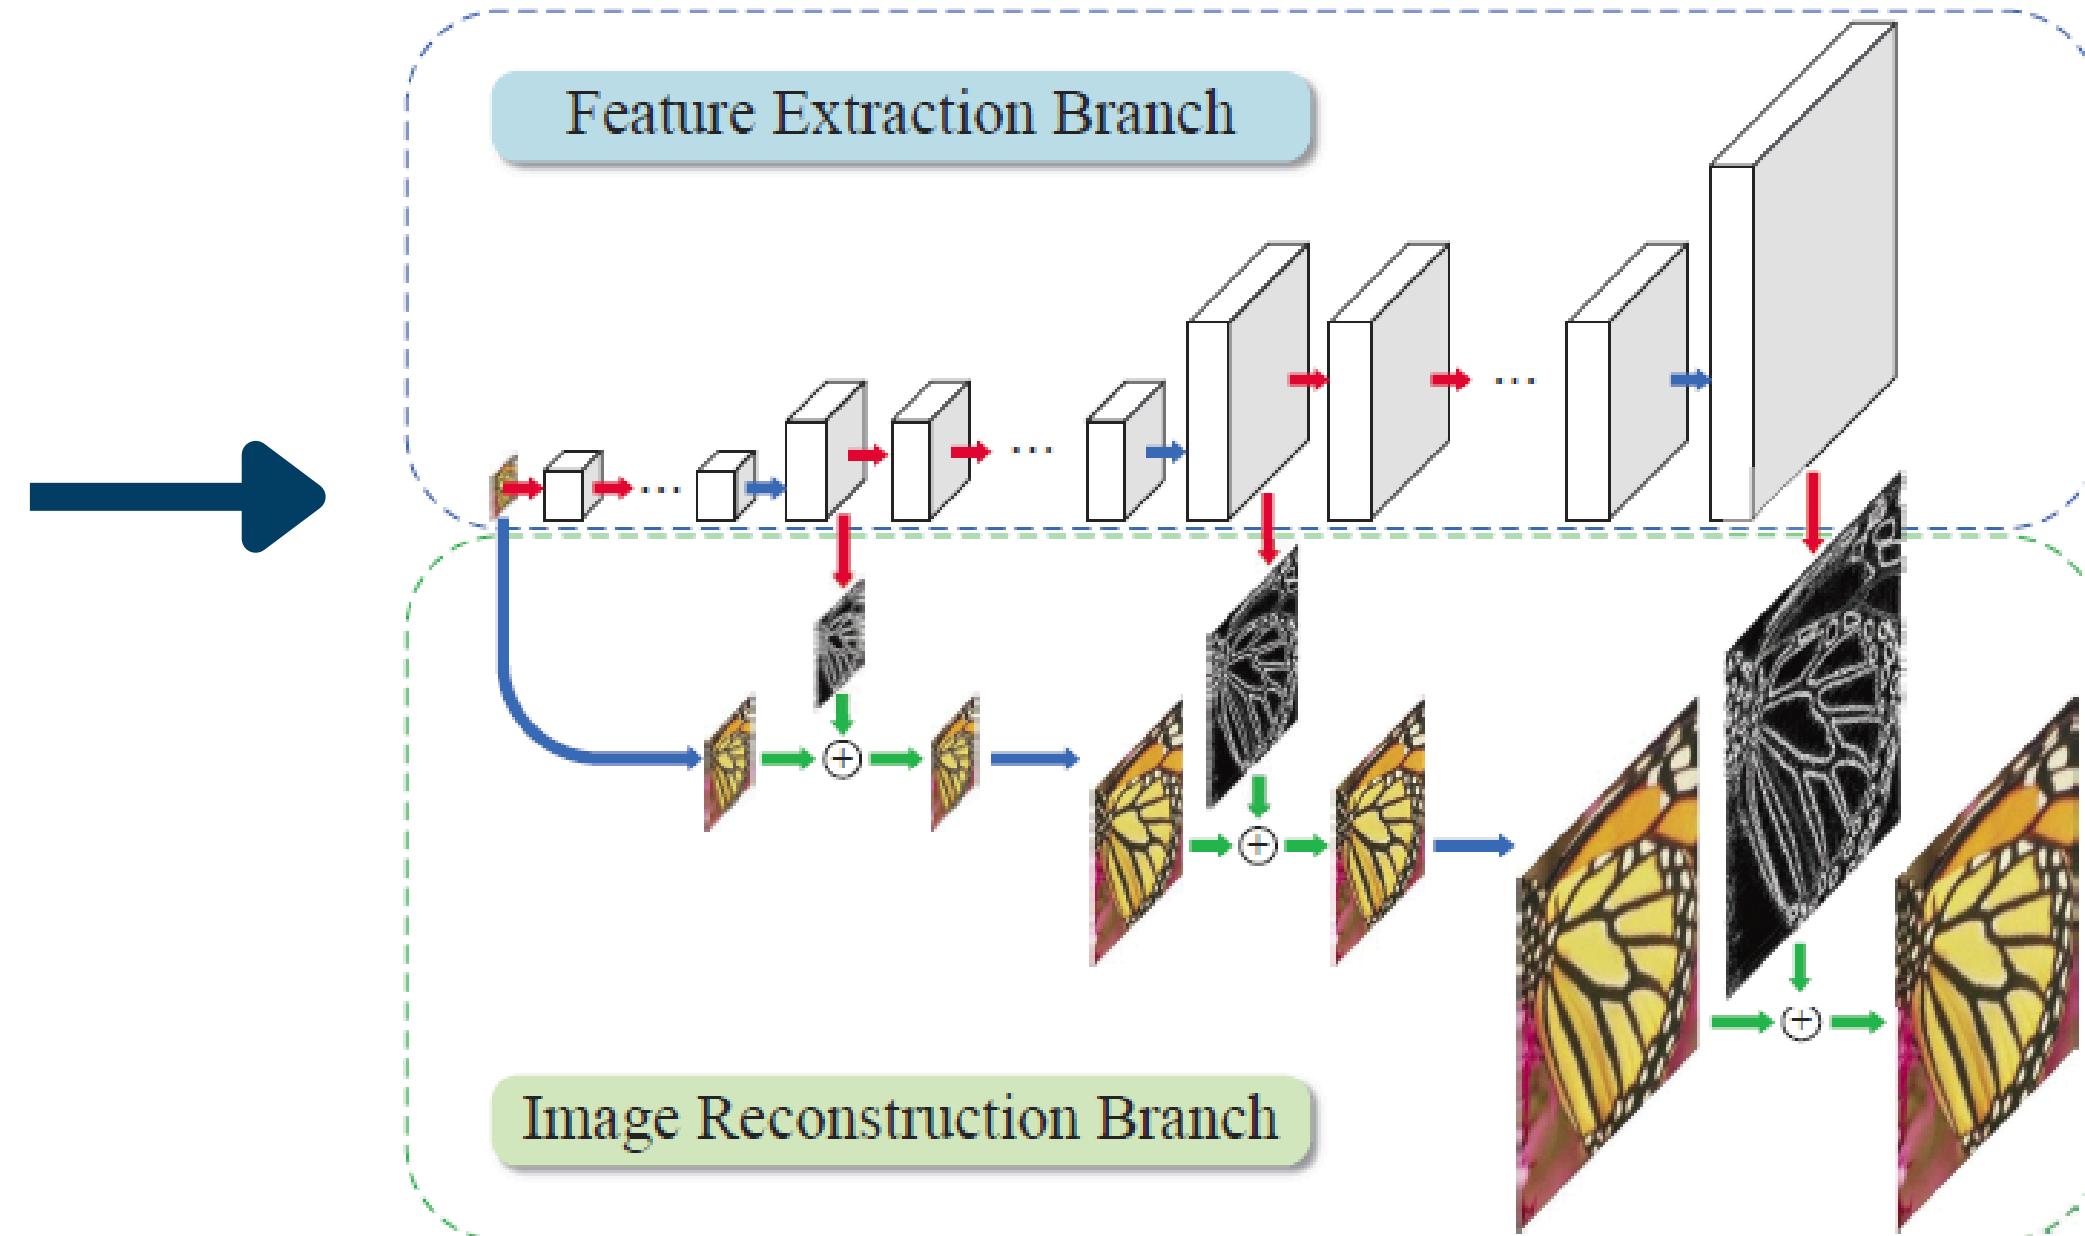
Solución mediante aprendizaje máquina

recuperando información

Si buscamos reconstruir la información para aumentar la resolución de una imagen la solución está en aprender la estructura de diferentes fuentes similares para poder así realizar una reconstrucción.



ImageNet

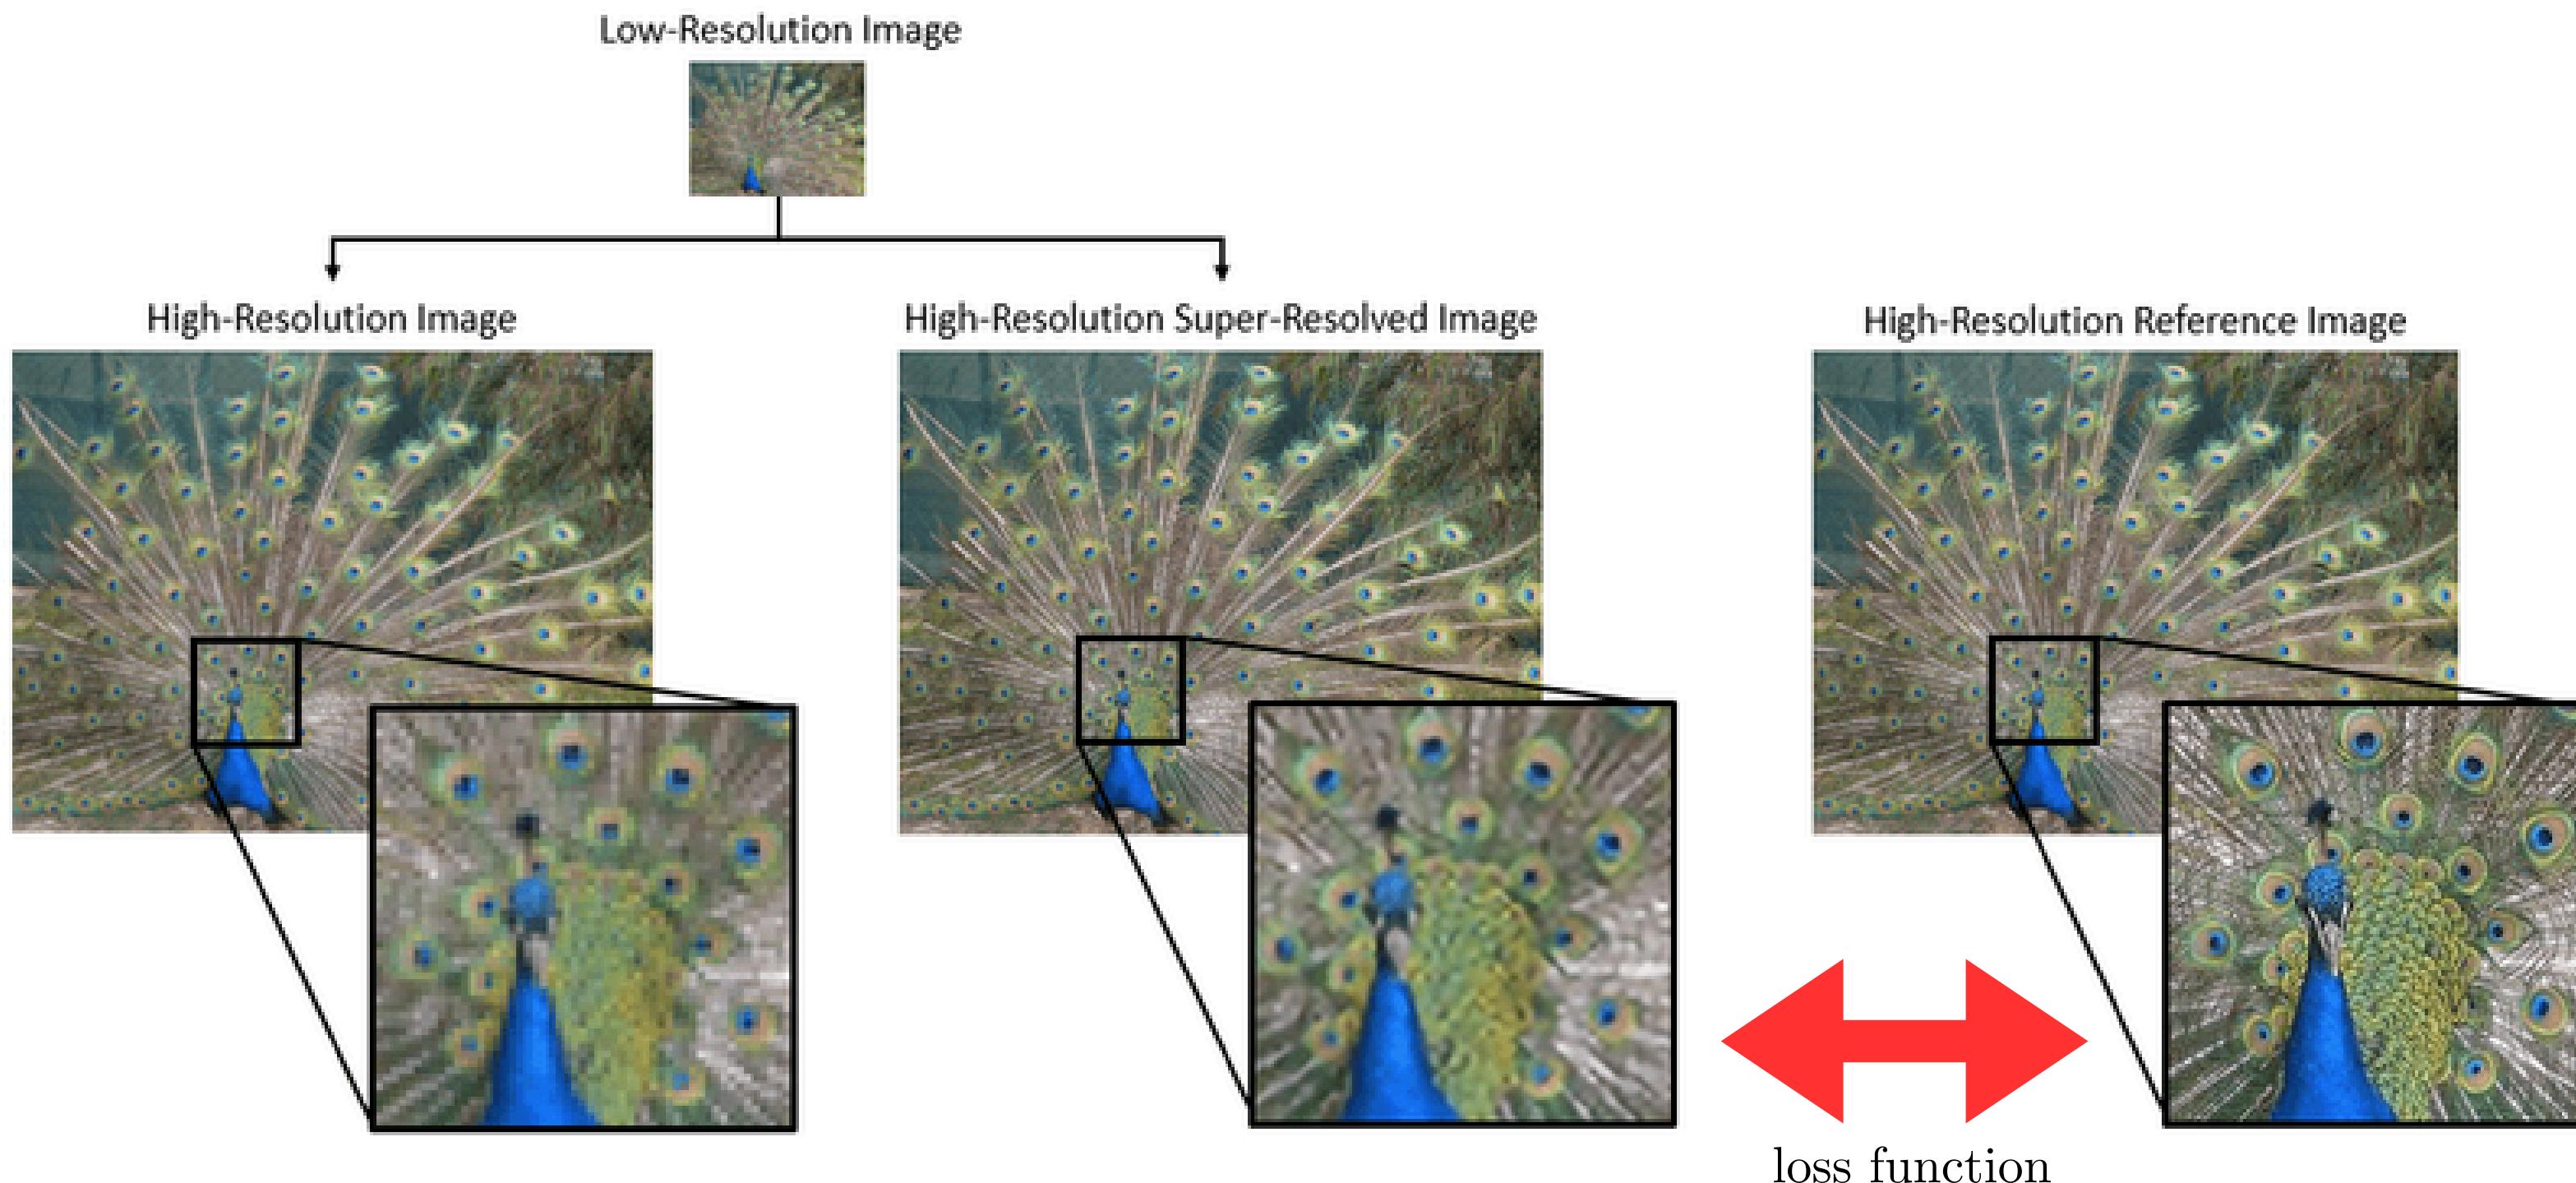




Solución mediante aprendizaje máquina

recuperando información

Proceso de entrenamiento iterativo

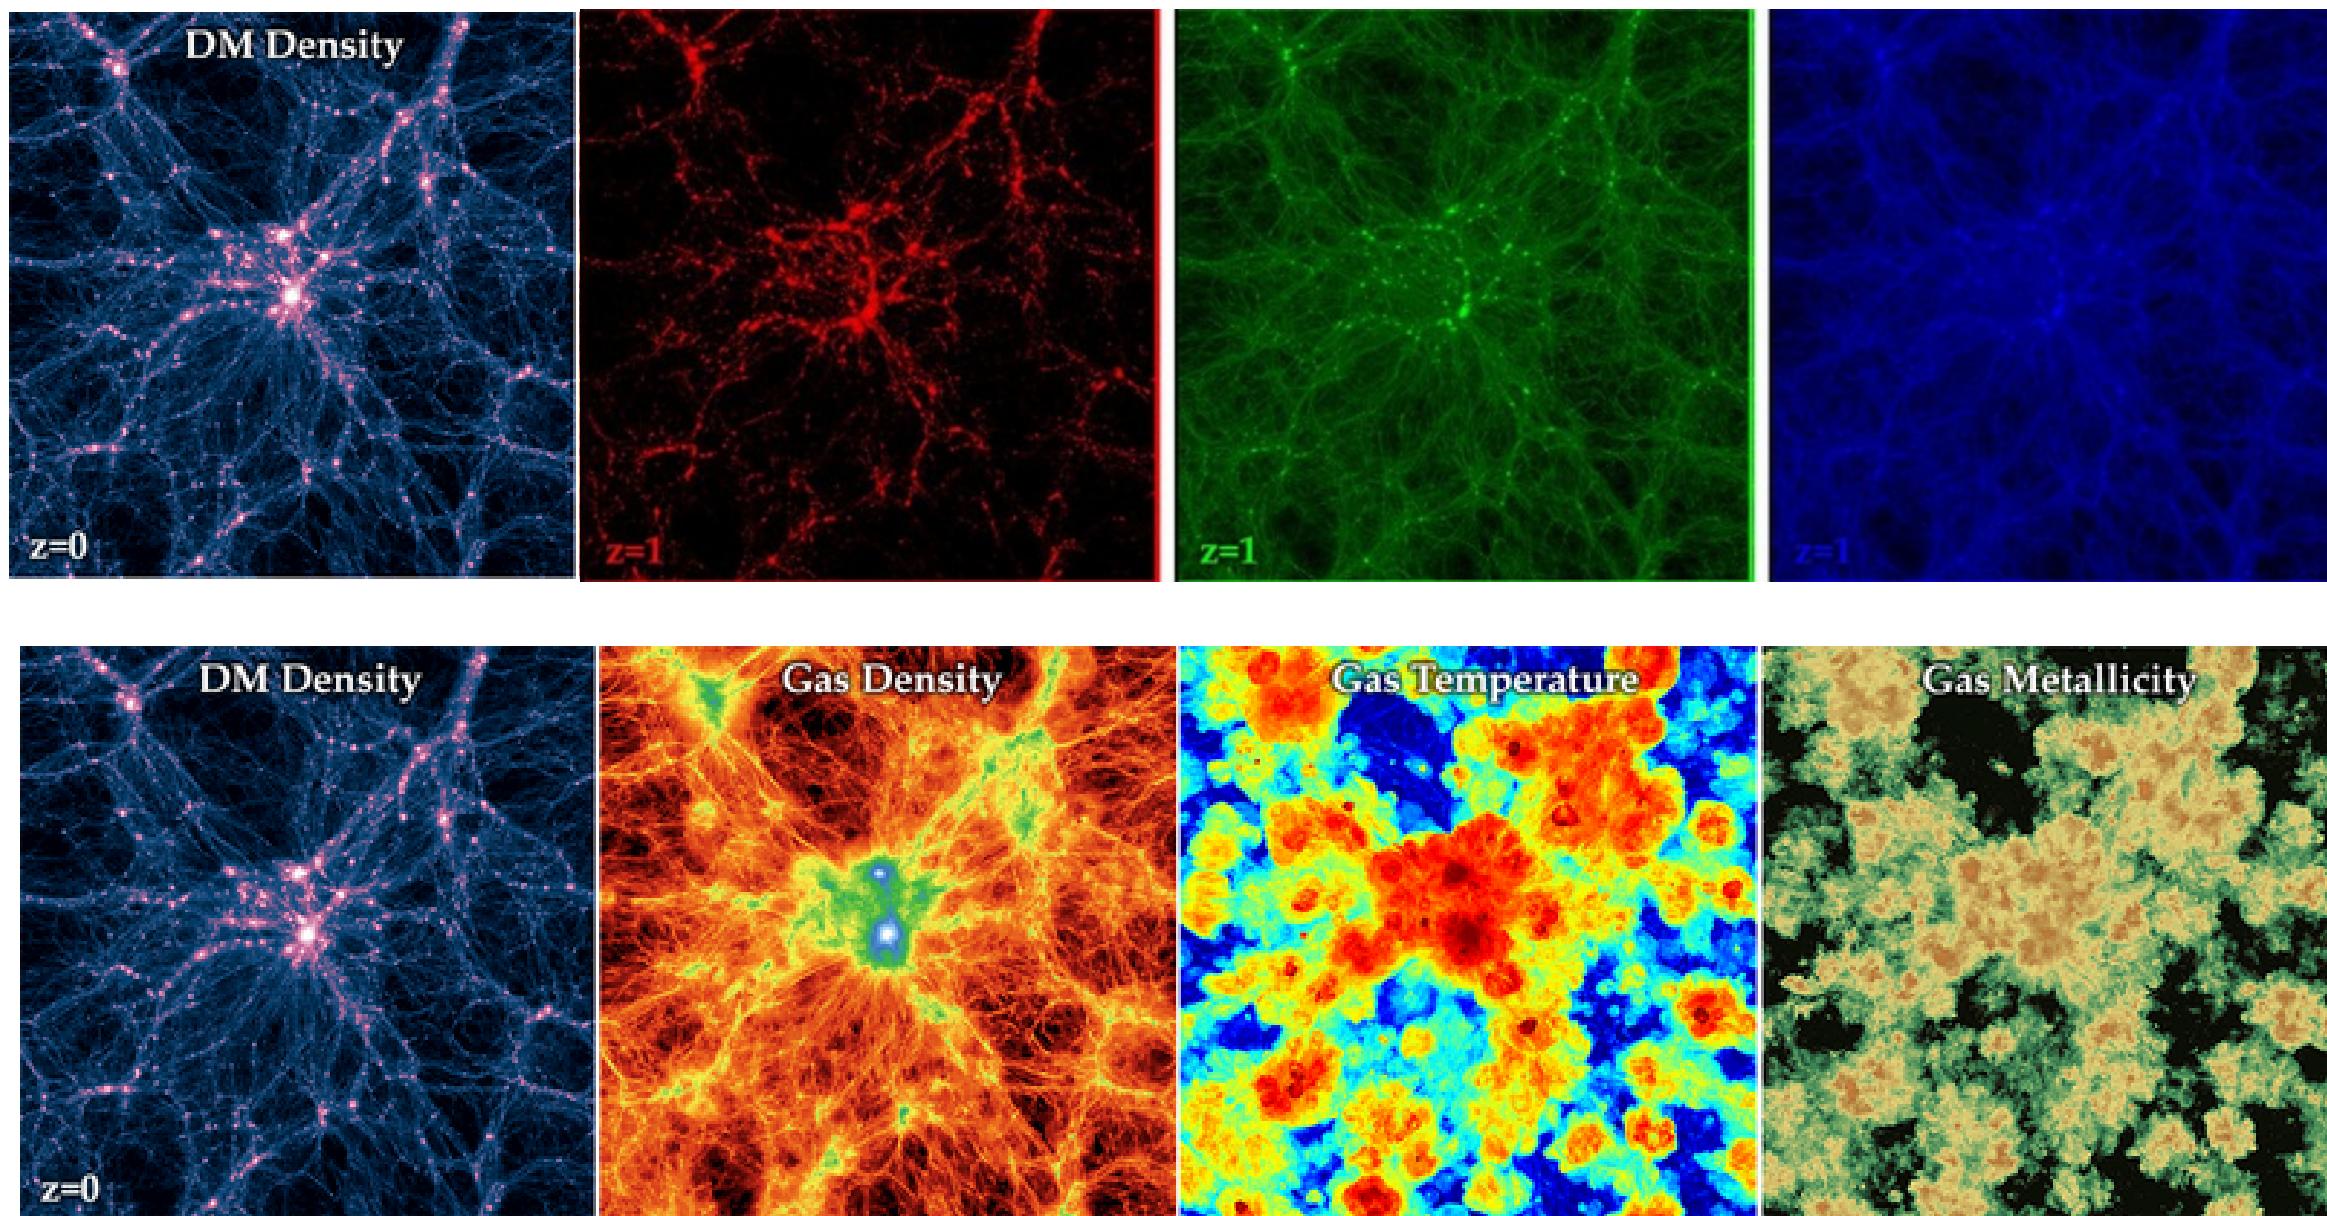




Aplicaciones cosmológicas

recuperando información

Dentro de las aplicaciones comerciales, buscamos ampliar la resolucion en los 3 canales de color, esto puede ser trasladado a mejorar la resolucion de diferentes parámetros cosmologicos como la densidad o temperatura



Actualmente existen diferentes arquitecturas para lograr este cometido, desde redes neuronales convolucionales (CNNs) y modelos generativos (GANs, VAEs) hasta modelos de difusión, sin embargo estos no están exentos de problemas.

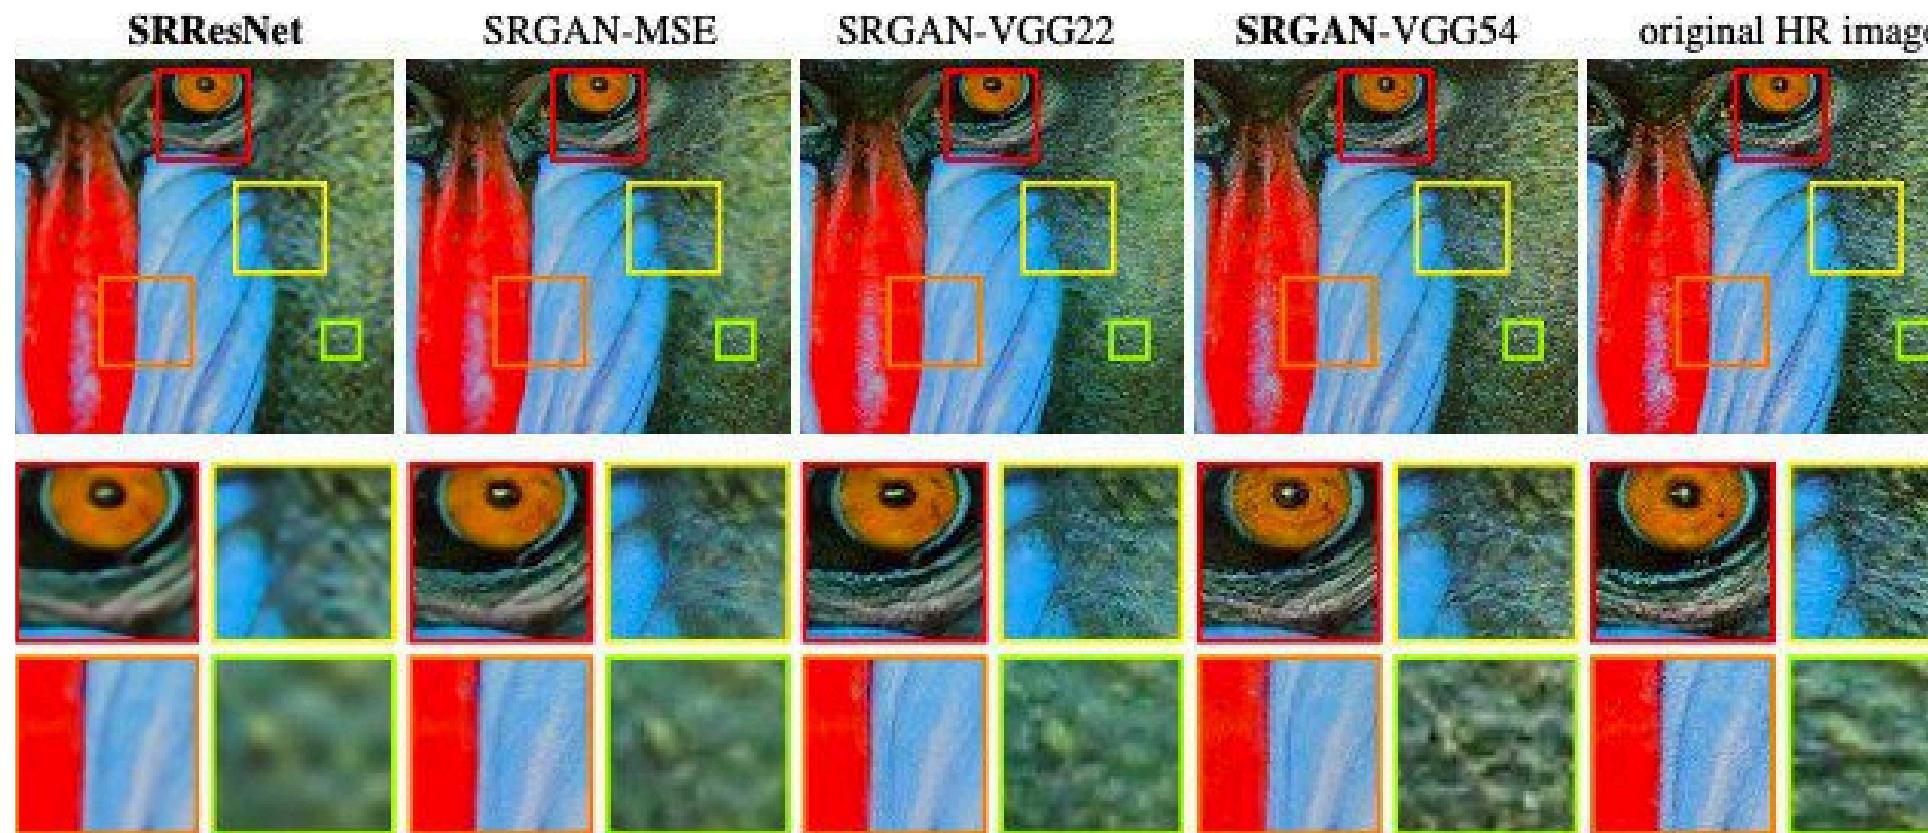
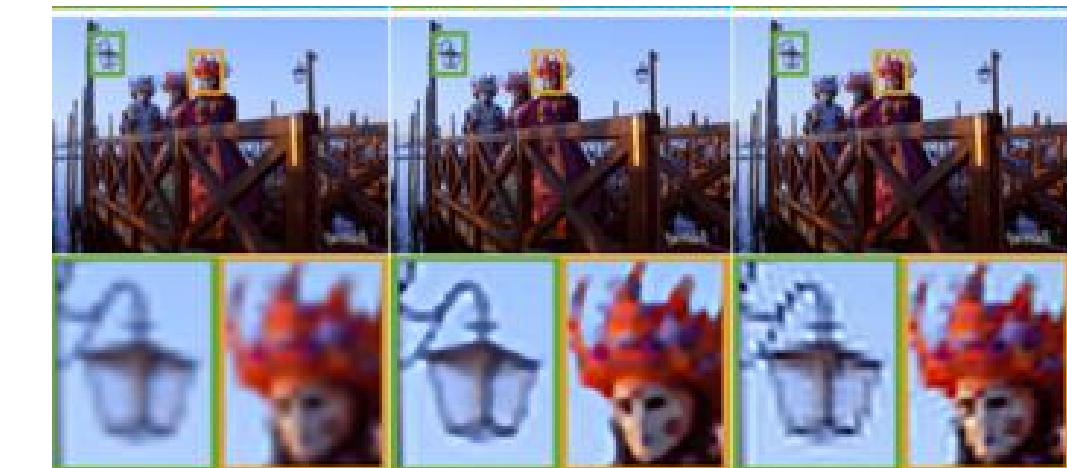


Figure 6: **SRResNet** (left: a,b), **SRGAN-MSE** (middle left: c,d), **SRGAN-VGG2.2** (middle: e,f) and **SRGAN-VGG54** (middle right: g,h) reconstruction results and corresponding reference HR image (right: i,j). [4× upscaling]



Artefactos



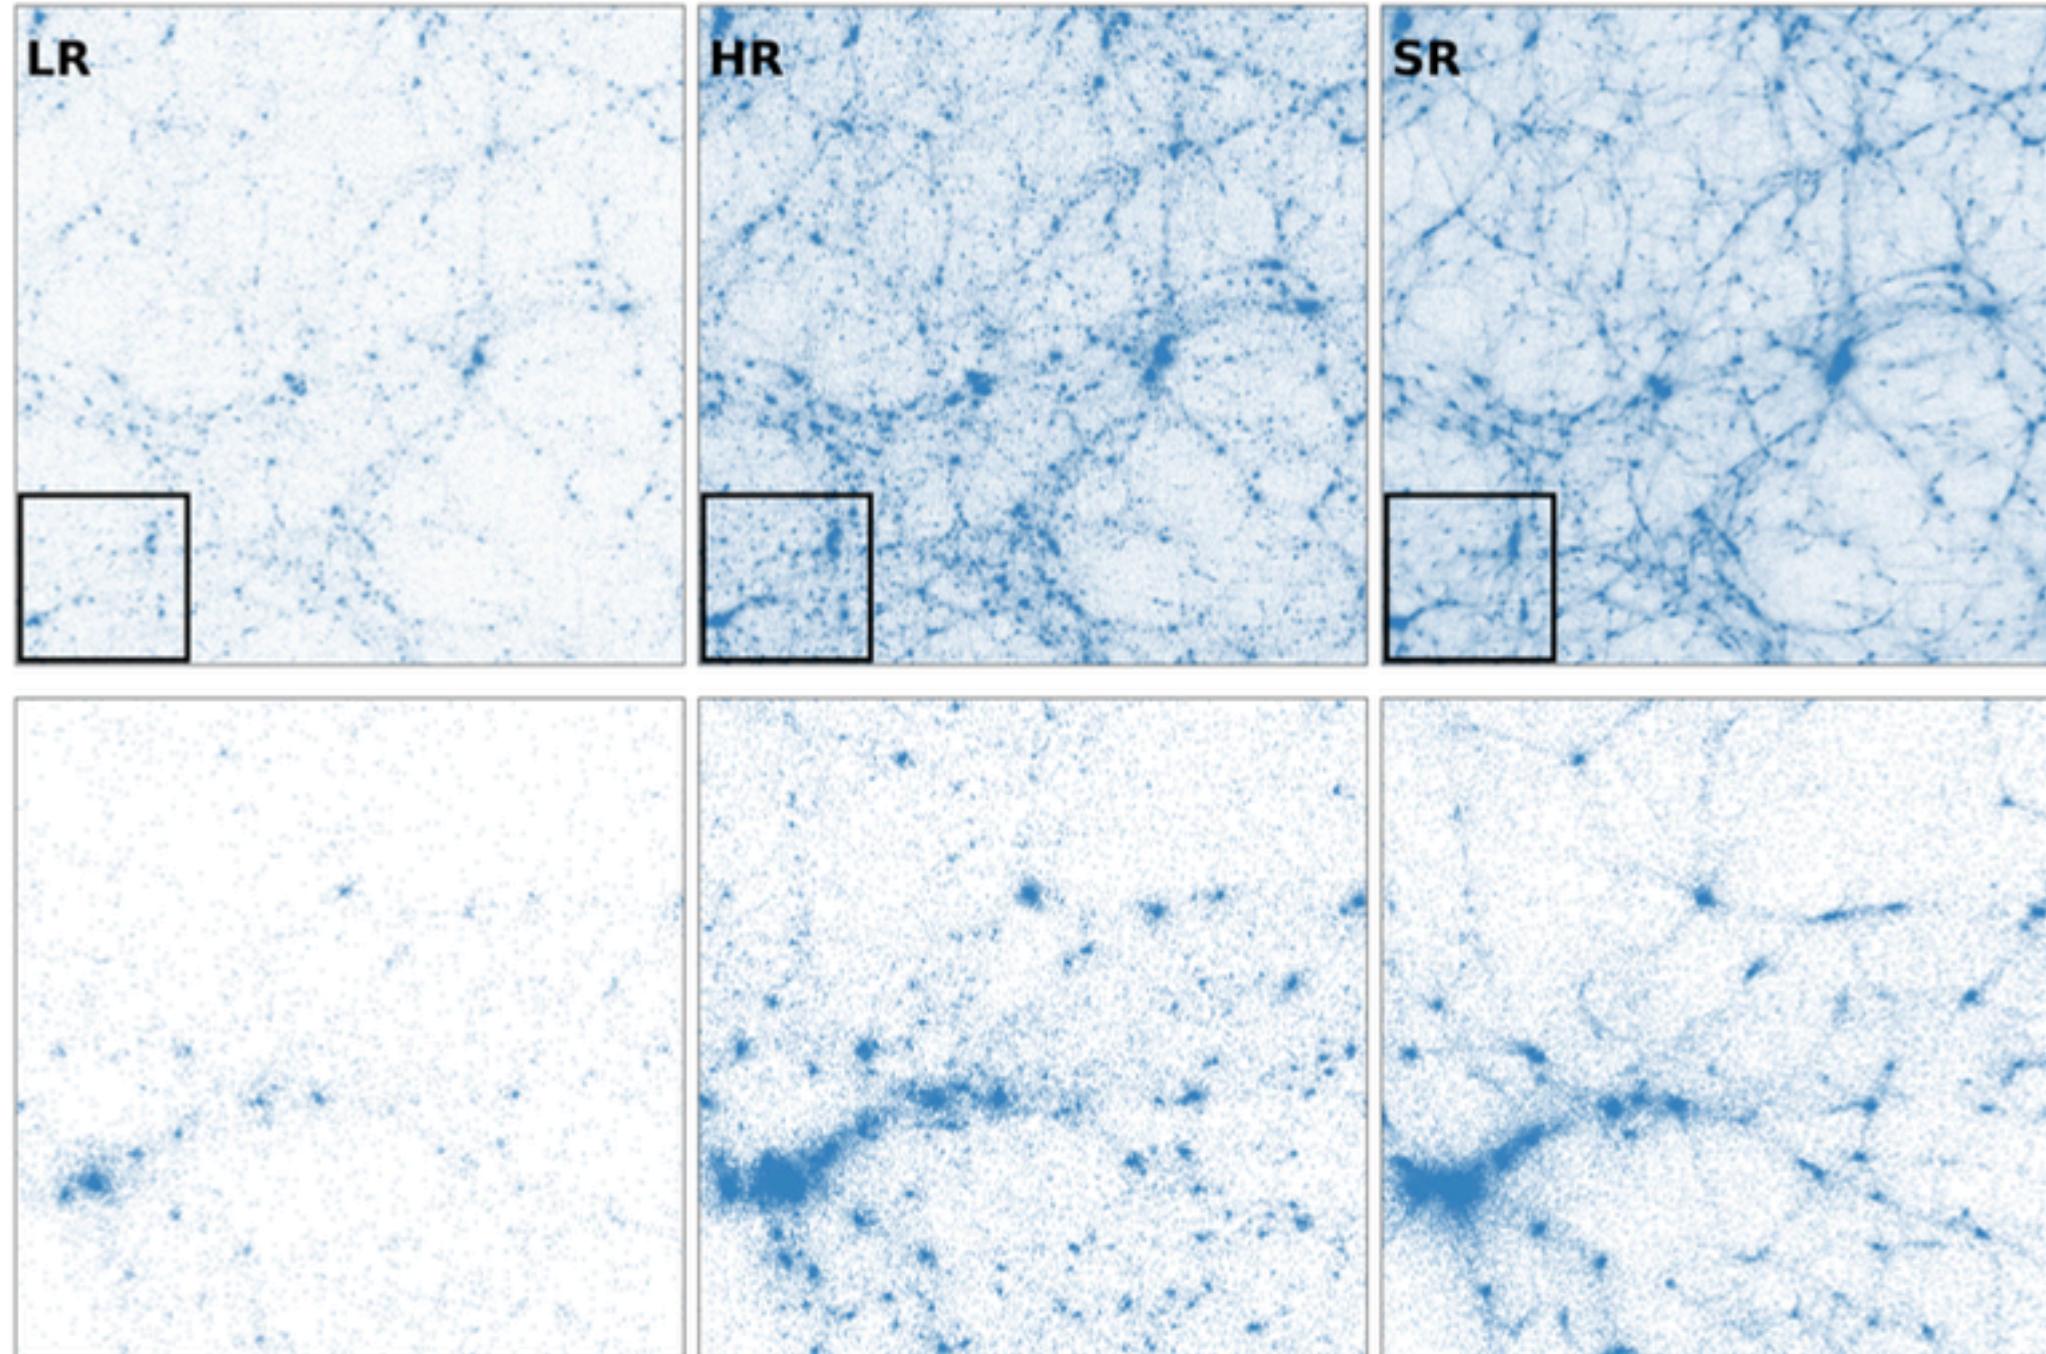
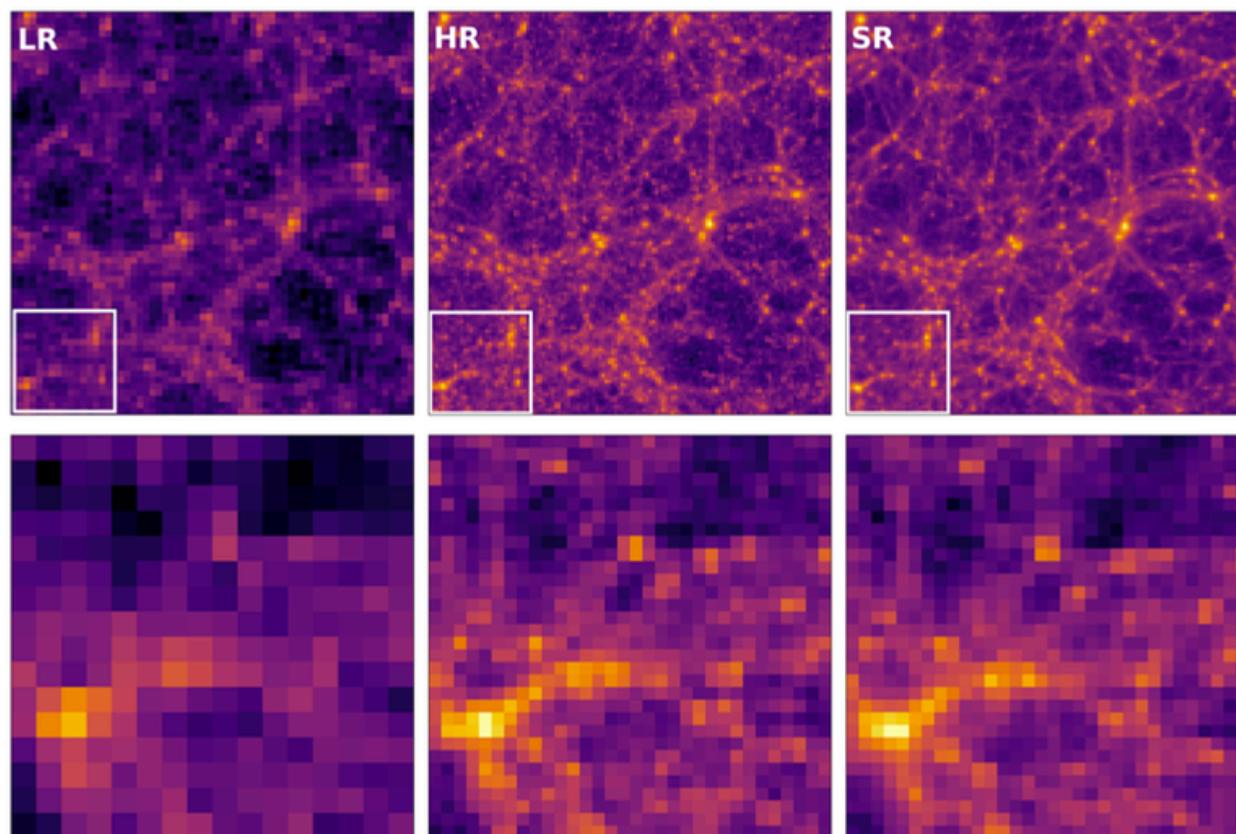
Aliasing



Aplicaciones cosmológicas

recuperando información

Al emplear una arquitectura tipo GAN presentamos como defecto “halucinaciones”, el modelo al buscar recrear los detalles de alta frecuencia inventa estructuras inexistentes en la imagen original de alta resolución



Brennan, J., Balu, S., Regan, J., & Power, C. (2025). On the use of WGANs for super resolution in dark-matter simulations. Preprint. arXiv:2501.13056. <https://arxiv.org/abs/2501.13056>



¿Cómo hacemos que un modelo sea más interpretable?

¿Cómo evitamos alucinaciones?

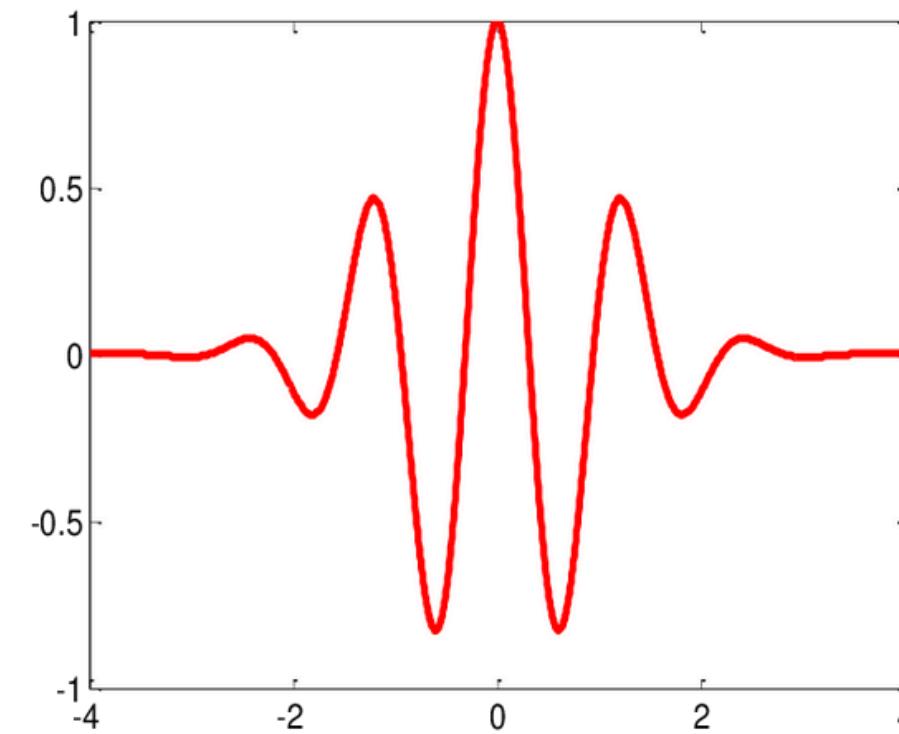


Índice

3 Wavelets

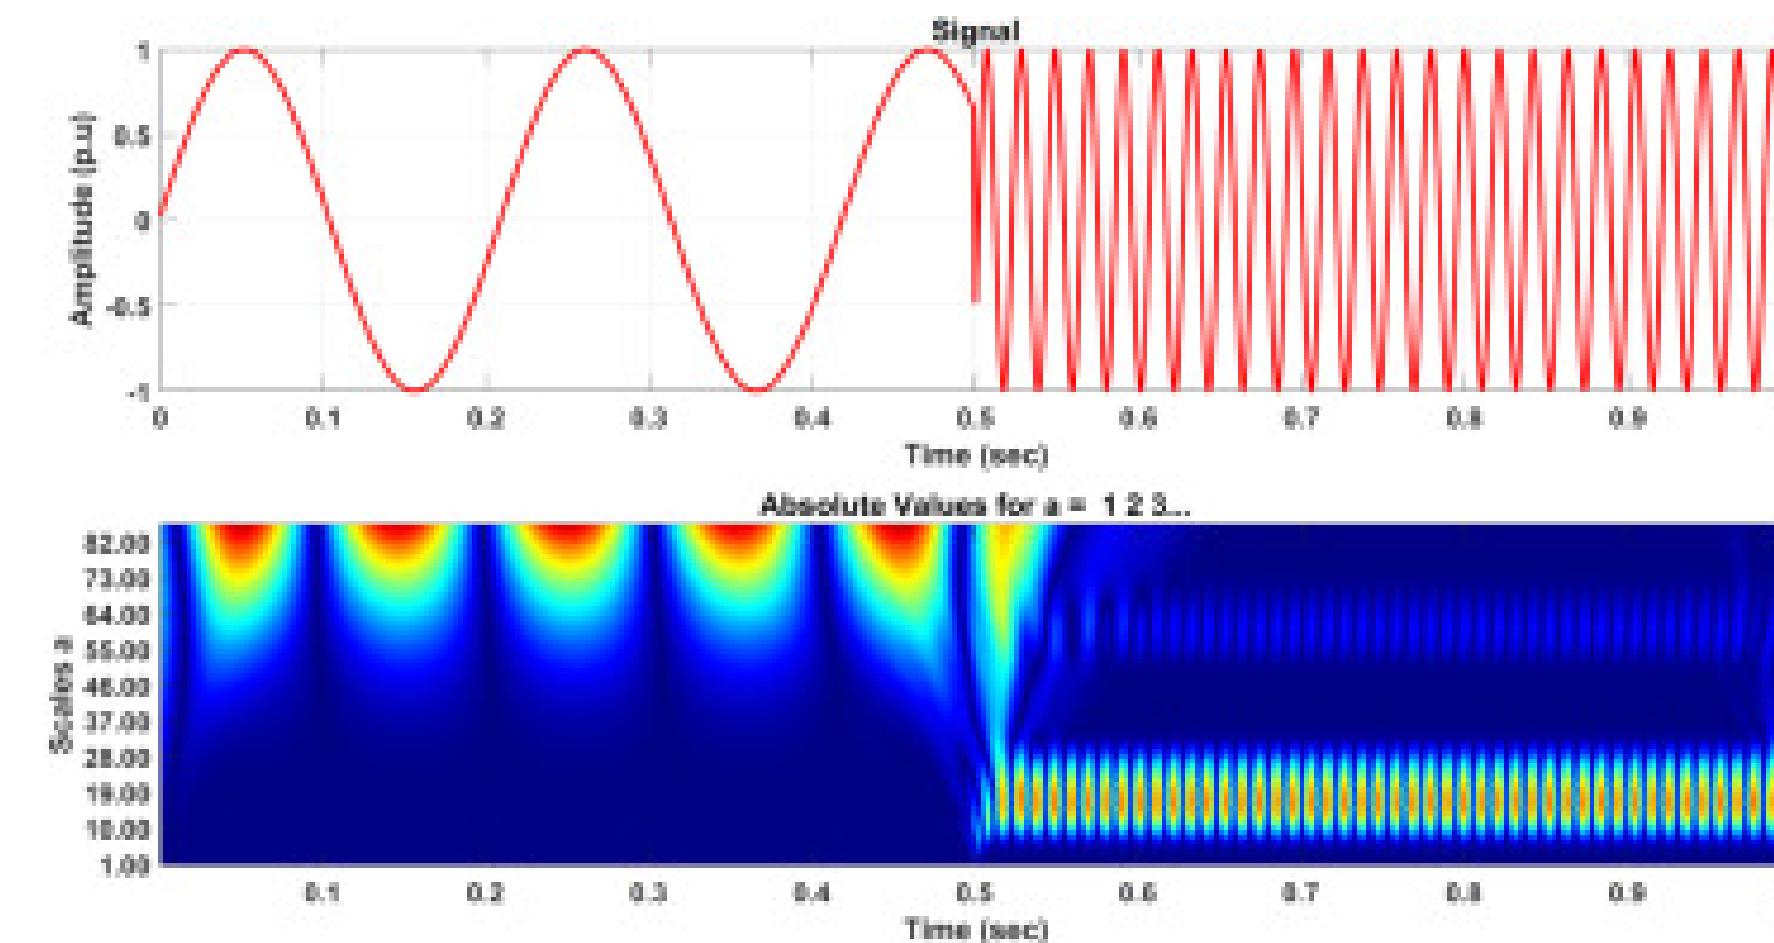
- Introducción
- Super resolución
- **Wavelets**
- Nuestro trabajo
- Referencias

Un wavelet es una función oscilatoria localizada en tiempo y frecuencia, utilizada en el análisis de señales para descomponer datos en múltiples escalas. A diferencia de la transformada de Fourier, los wavelets pueden capturar tanto información de frecuencia como de localización temporal o espacial.



$$\psi(t) = e^{i\omega_0 t} e^{-t^2/2}$$

Morlet Wavelet

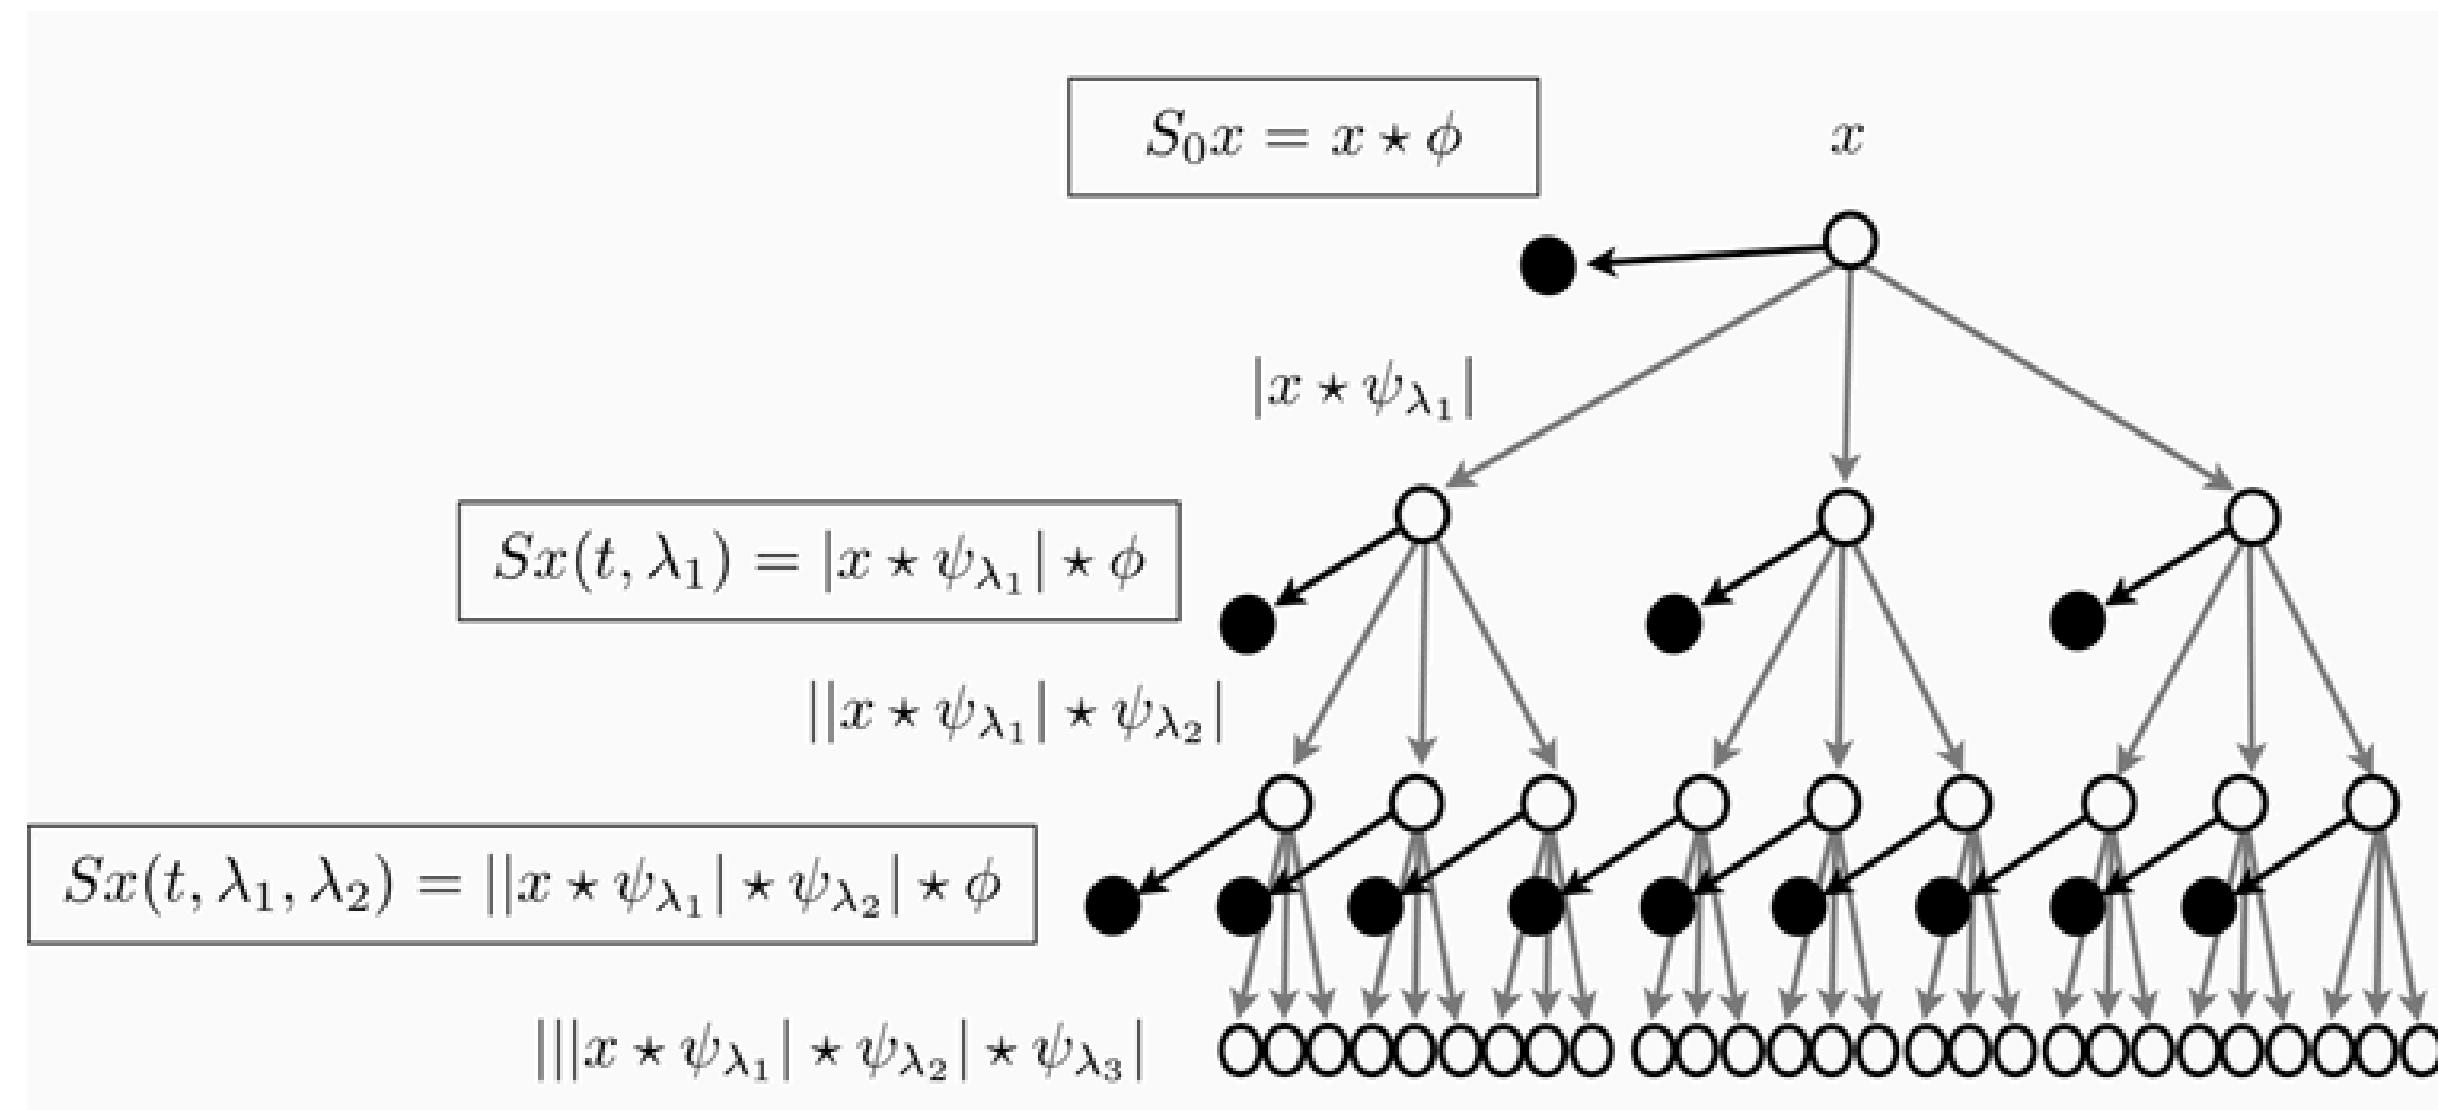


Resultado de una CWT

Wavelet Scattering Transform

Definición

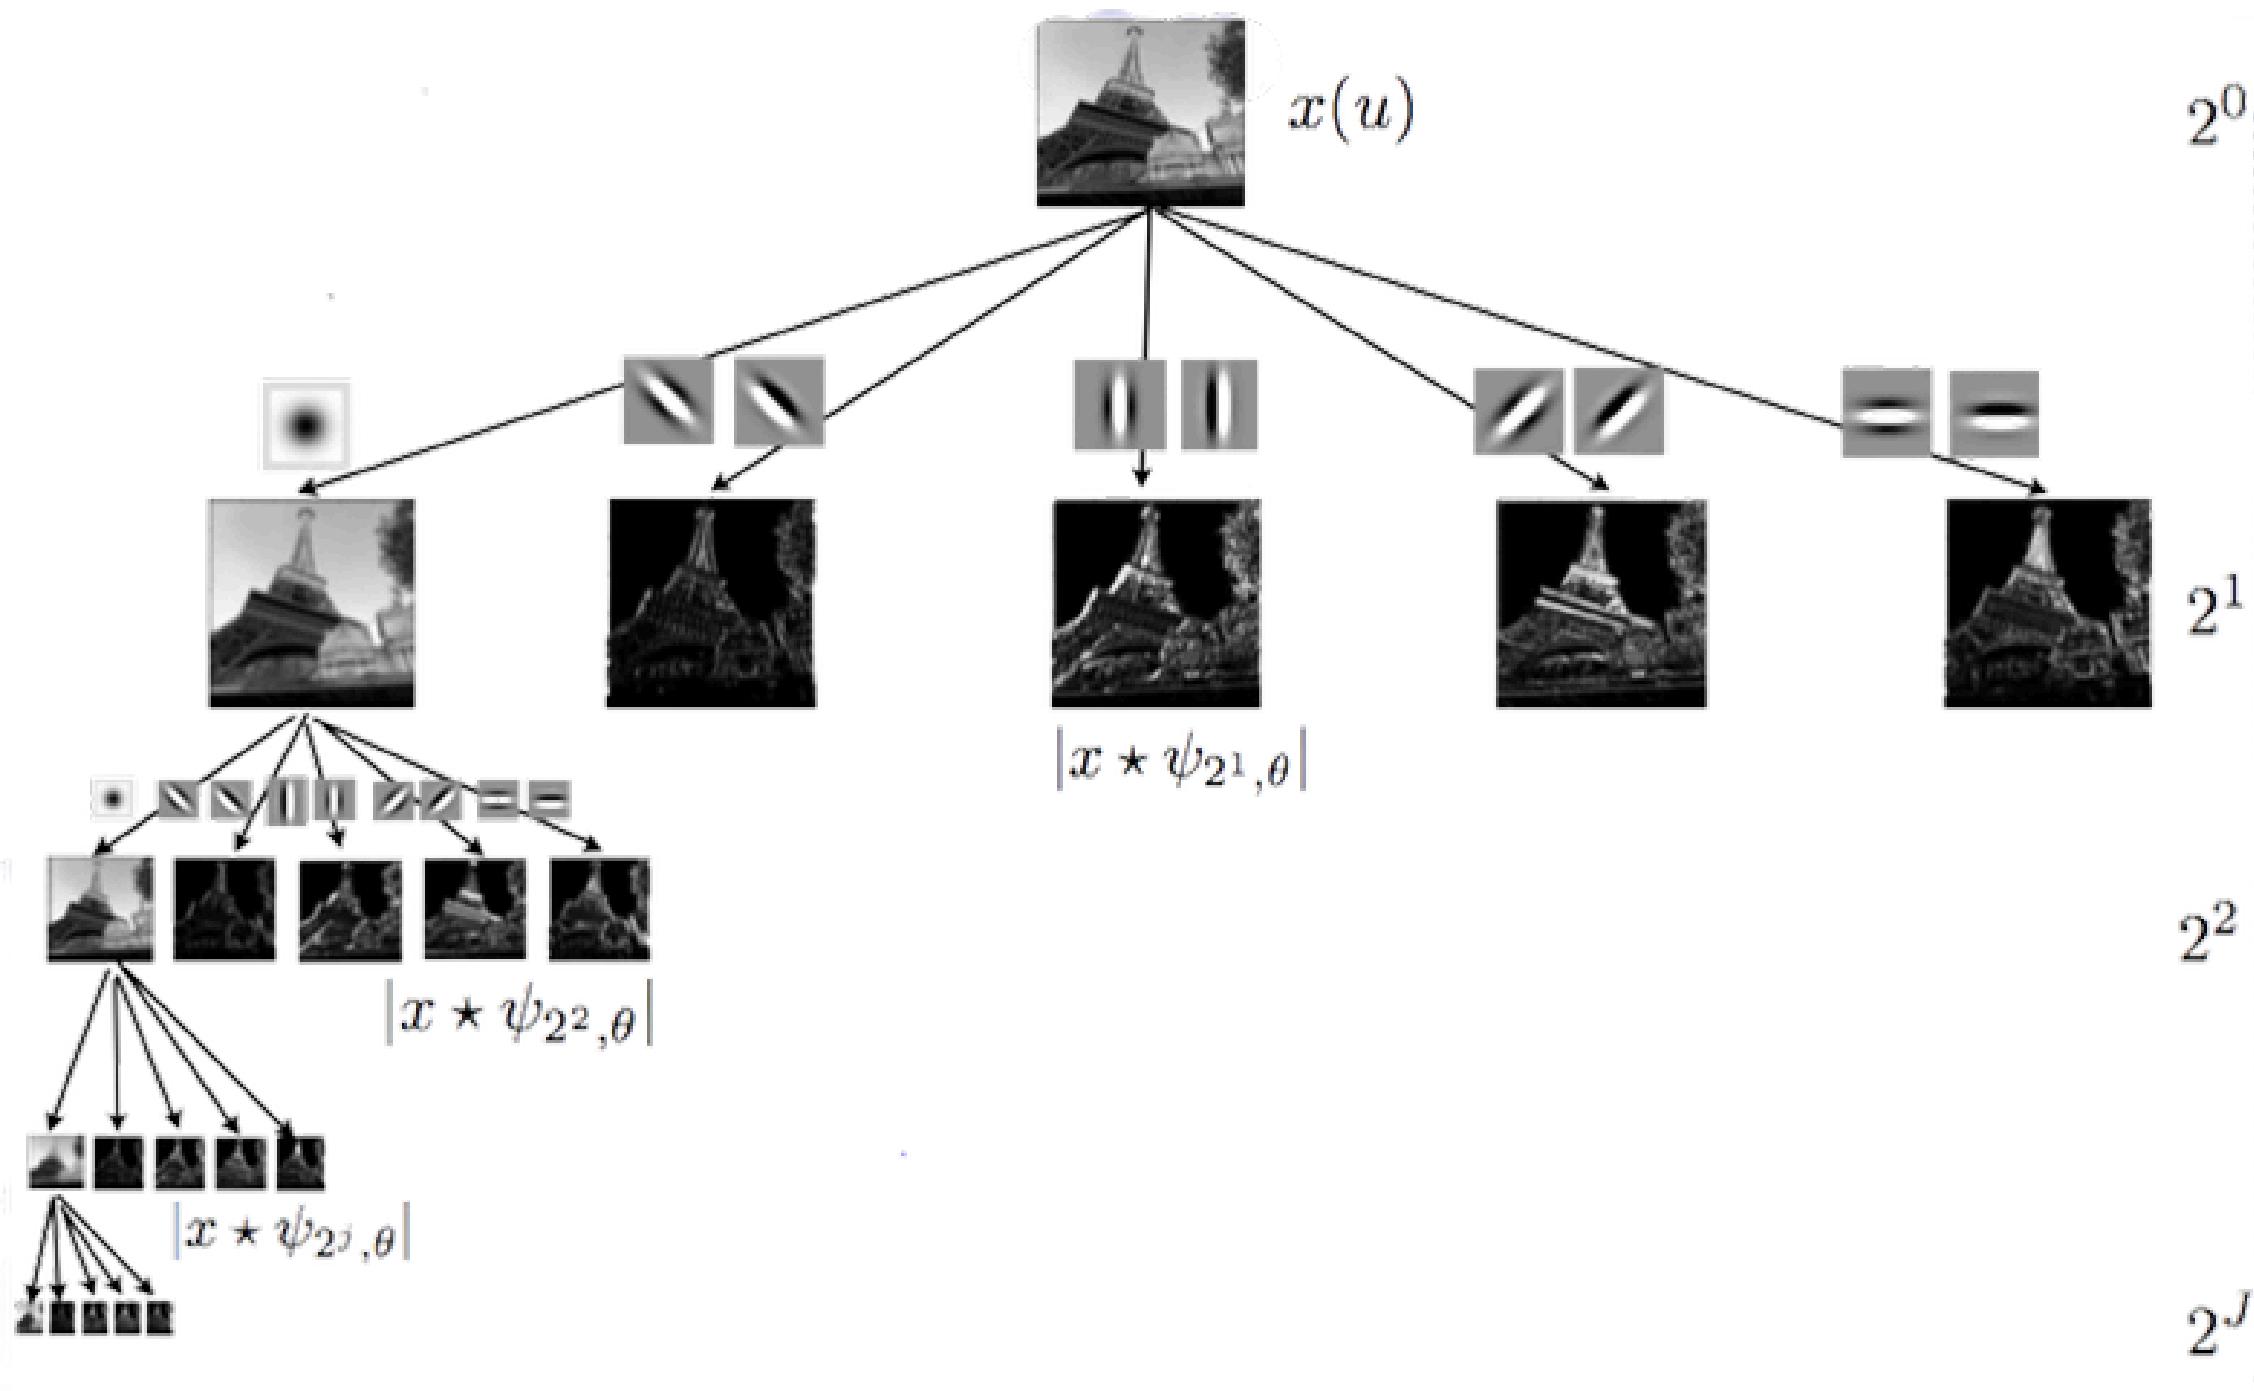
A raíz de esto se introdujo el concepto de la Transformada escaloada de wavelets (Wavelet Scattering Transform), esa transformada descompone las imágenes conservando la información espacial, frecuencial y estable ante rotaciones. Se obtiene mediante una cascada de operadores de módulo wavelet en una red convolucional profunda, dispersando la información de la señal en múltiples trayectorias.



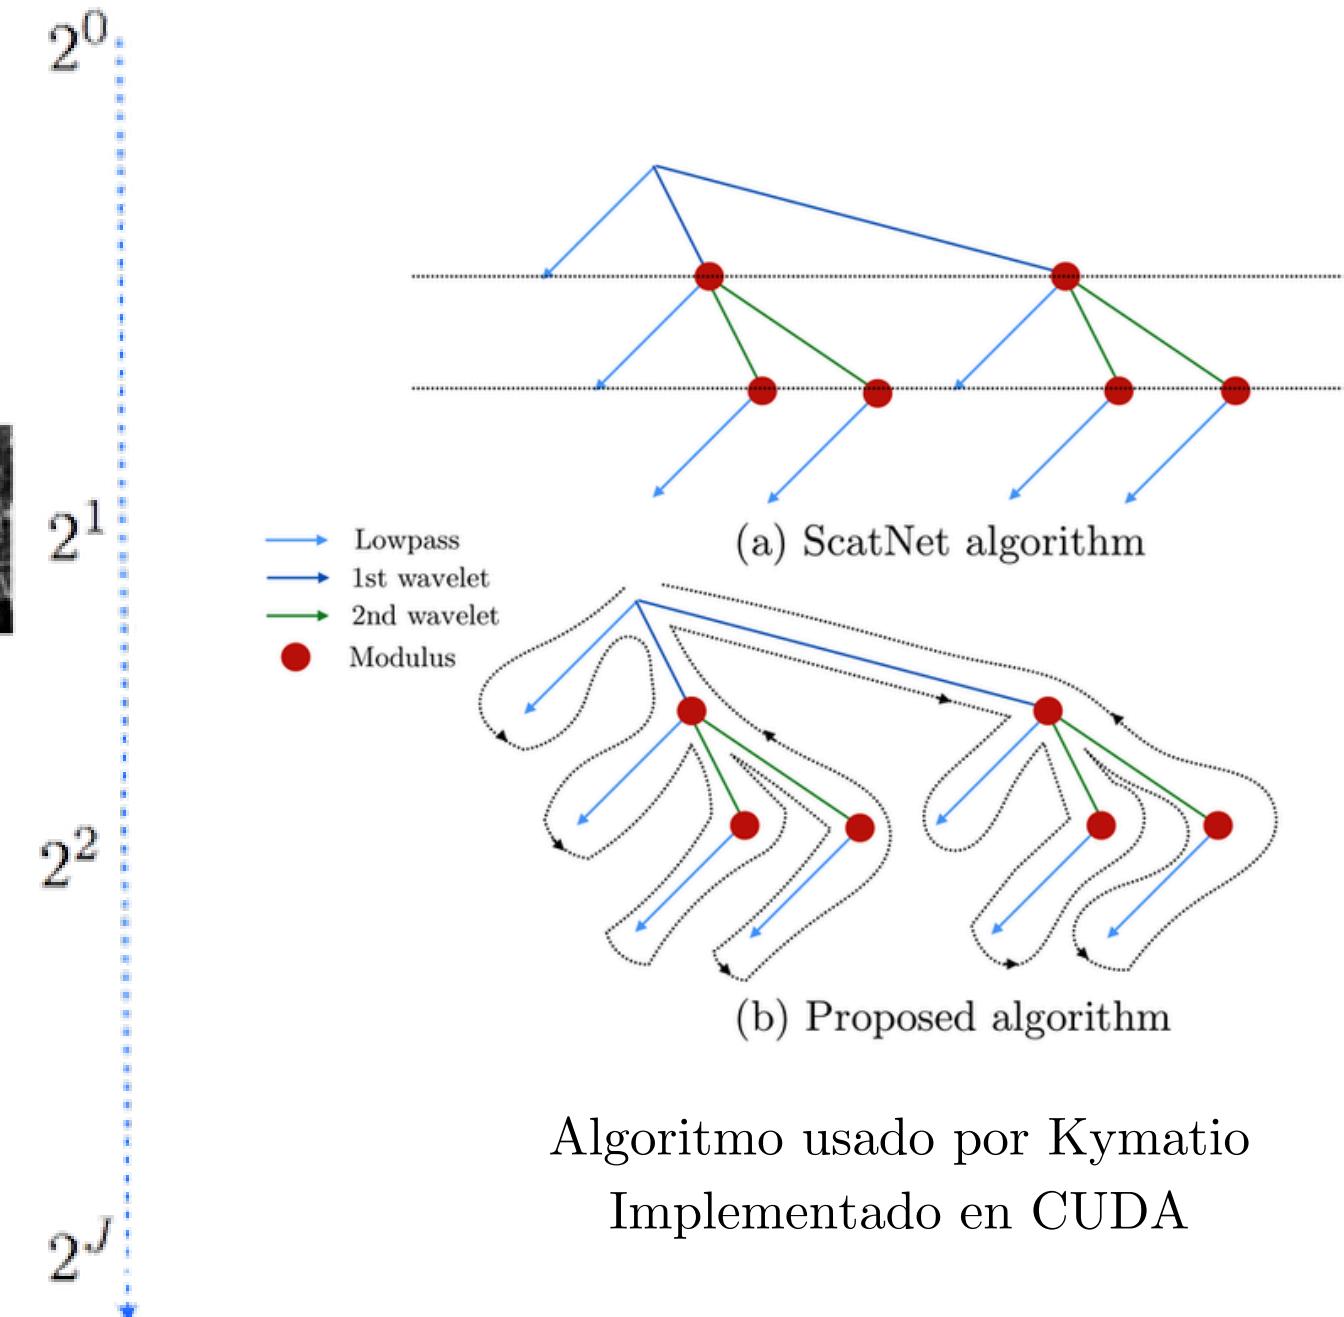
Wavelet Scattering Transform

Definición

Podemos visualizar un ejemplo de sus características



Ejemplo de representación





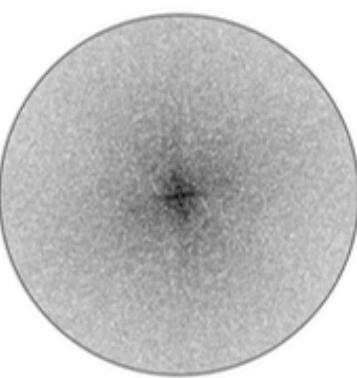
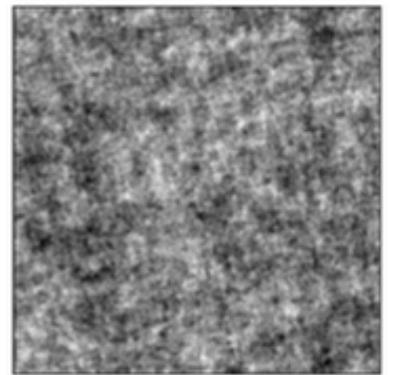
Wavelet Scattering Transform

Ventajas

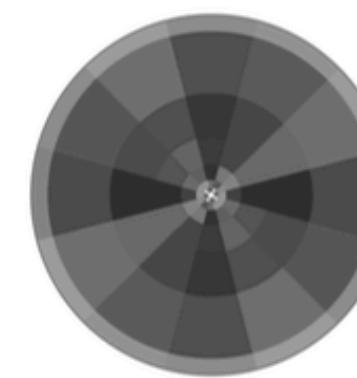
El uso de WST trae varias ventajas consigo, es una representación estable a rotaciones y no presenta los problemas de el análisis de fase en la descomposición via transformada de Fourier.



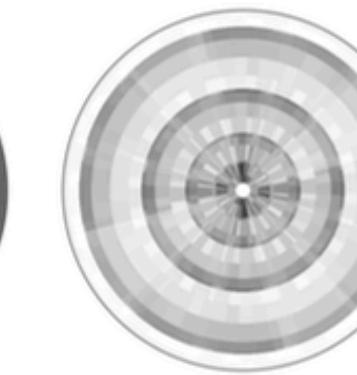
Texture



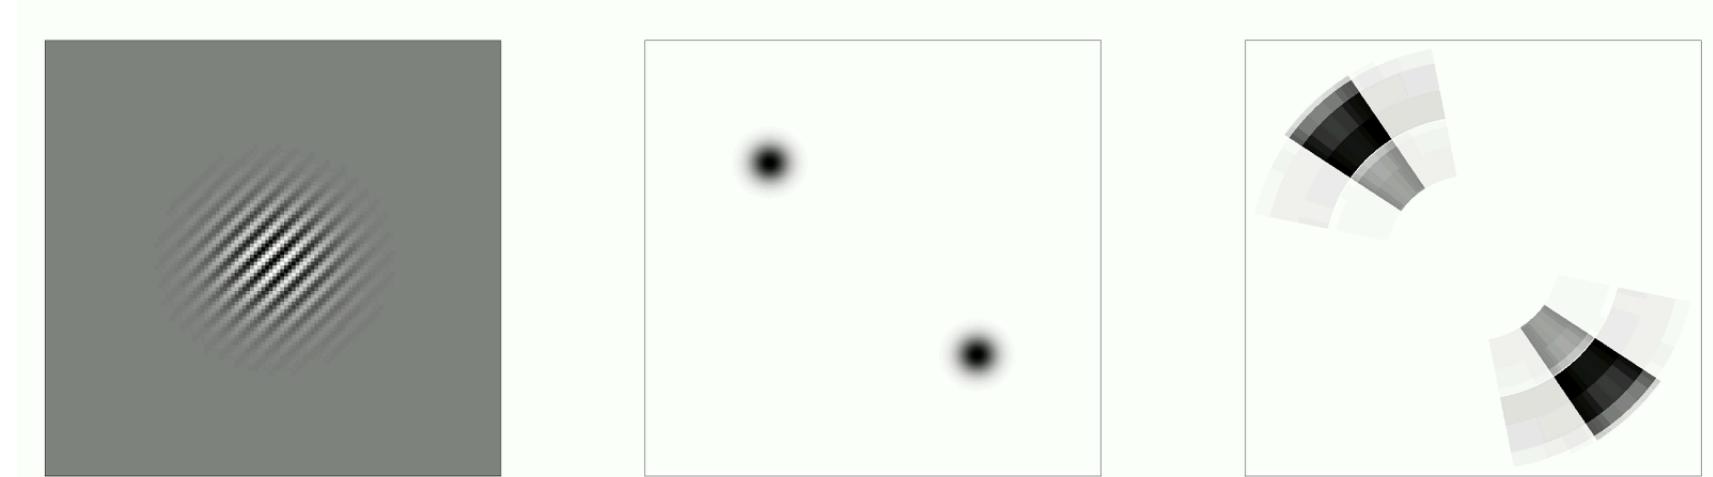
Fourier
(Amplitude)



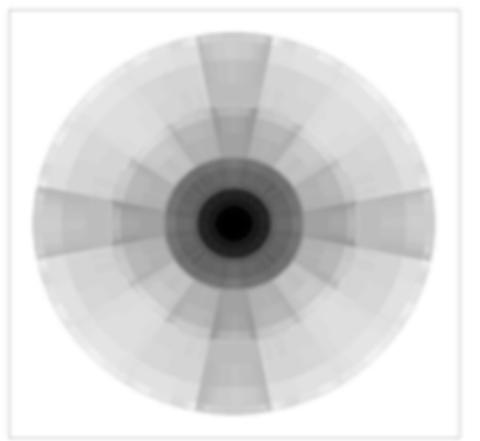
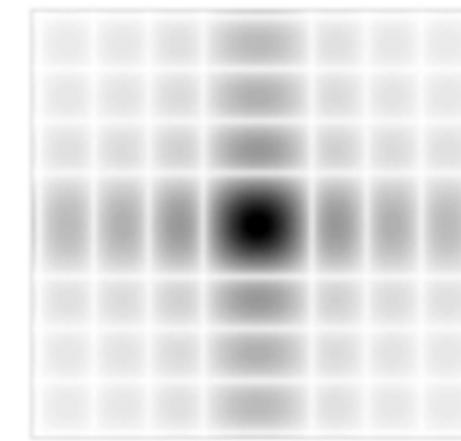
WST Coefficients



Momentos de orden mayor



Estabilidad ante rotaciones

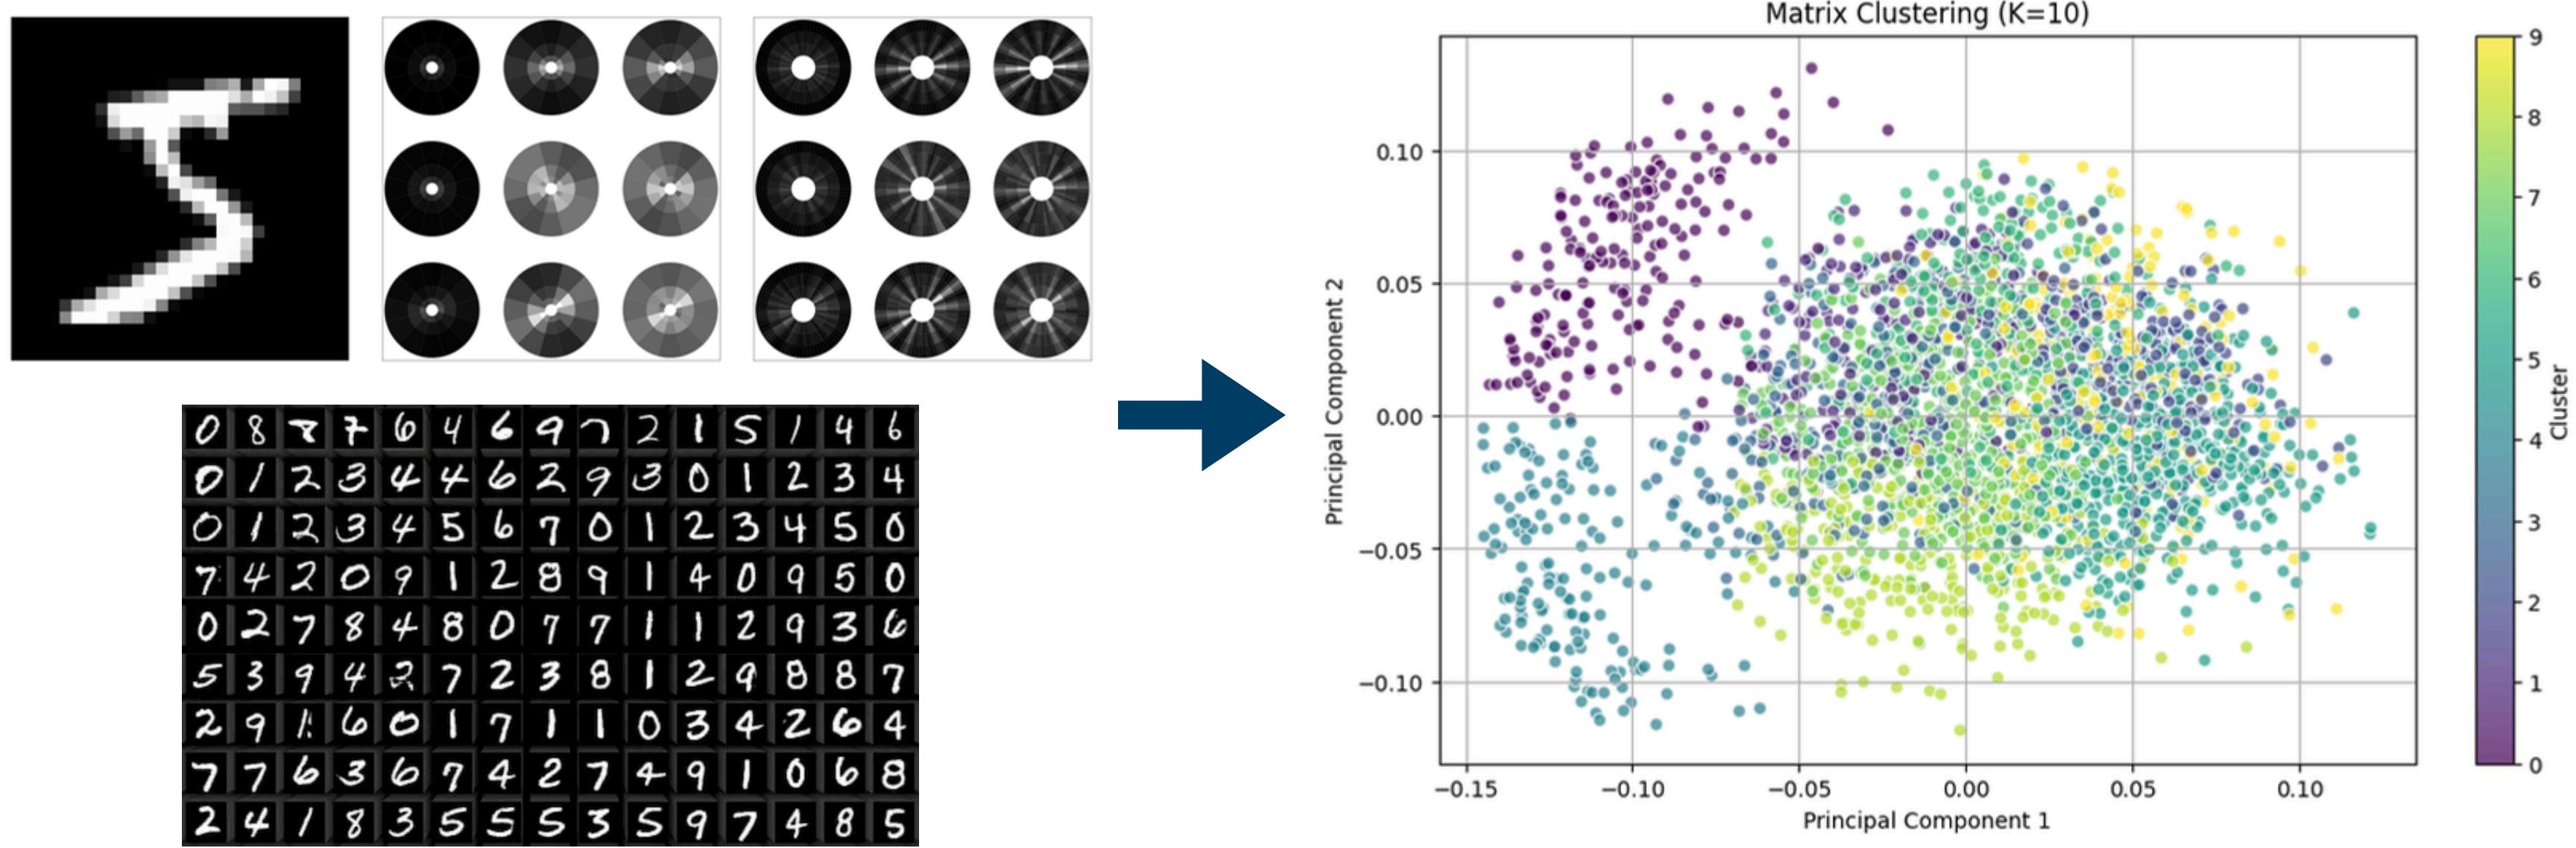


**Información de localización
espacial y Frecuencial**

Wavelet Scattering Transform

Su uso como métrica

En este ejemplo podemos ver el resultado de la clasificación de dígitos del MNIST dataset mediante el uso de coeficientes de WST como red convolucional, lo que nos permite usarlo como métrica de pérdida.



Clasificación de dígitos MNIST mediante K-means, representación mediante PCA

Wavelet Scattering Transform

Su uso como métrica

Diferentes autores han planteado que La WST puede ser una herramienta altamente robusta para capturar información no gaussiana en campos cosmológicos, siendo comparable al espectro de potencia en sensibilidad a parámetros fundamentales. Aplicada a simulaciones tipo N-body, el WST permite recuperar información ligada a correlaciones de orden superior con bajo costo computacional y alta interpretabilidad.

- Cheng, S., Ting, Y.-S., Ménard, B., & Bruna, J. (2023). Scattering Spectra Models for Physics. arXiv:2306.17210. <https://arxiv.org/abs/2306.17210>
- Valogiannis, G., & Dvorkin, C. (2022). Towards an optimal estimation of cosmological parameters with the wavelet scattering transform. Physical Review D, 105(10), 103534. <https://doi.org/10.1103/PhysRevD.105.103534>

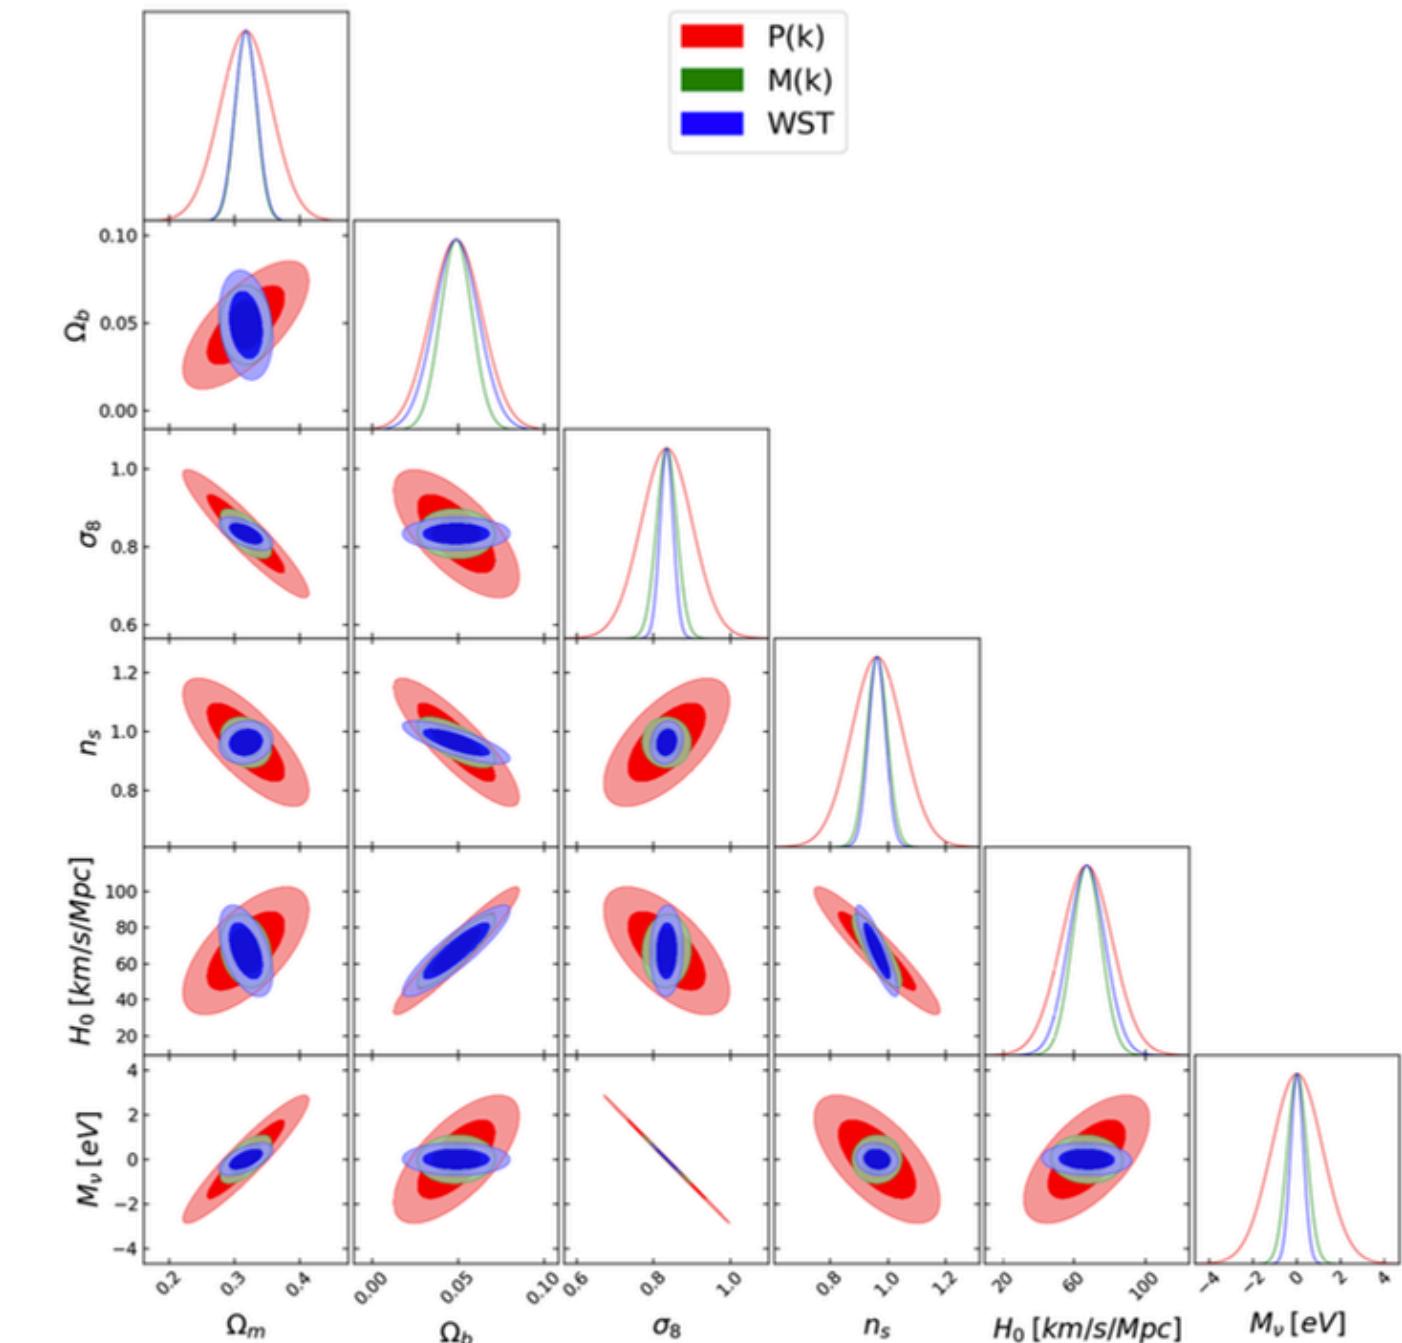


FIG. 3. Forecasted one-dimensional and two-dimensional distribution functions for all six cosmological parameters obtained by the power spectrum $P(k)$ (red), the marked power spectrum $M(k)$ (green), and the optimal WST (blue), when working with the density field traced by CDM + baryons. The corresponding normalized probability density functions for each parameter are shown along the diagonal.



Índice

4 Nuestro Trabajo

- Introducción
- Super resolución
- Wavelets
- **Nuestro trabajo**
- Referencias



Illustris Simulations

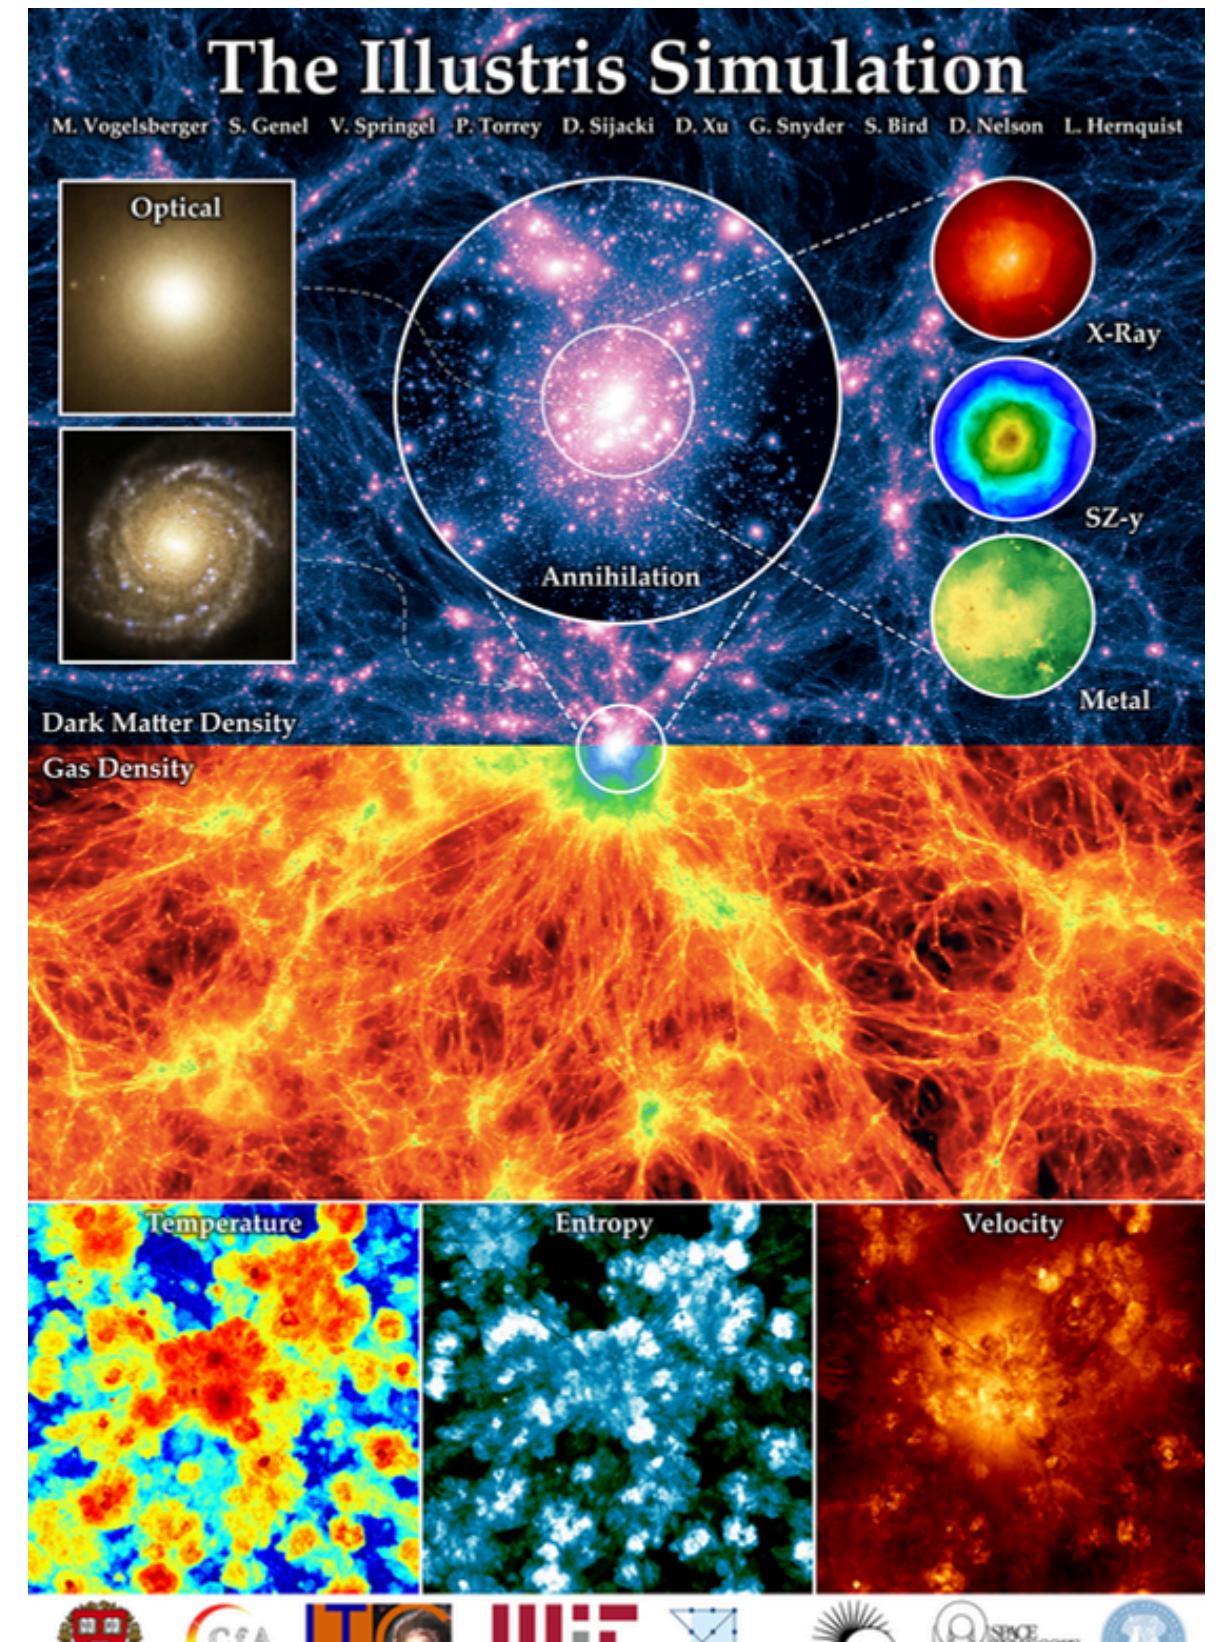
Conjunto de datos de entrenamiento

Las simulaciones Illustris (2015) son simulaciones numéricos de gran escala que modelan el crecimiento de estructuras cósmicas en un cubo comóvil de 106.5 Mpc/h, desde el universo temprano hasta hoy, su objetivo principal es:

- Comprender la formación y evolución de galaxias en un entorno realista.
- Estudiar el impacto del gas, la materia oscura y los agujeros negros.
- Comparar con observaciones astronómicas y validar modelos teóricos.
- Generar datos para entrenar modelos de inteligencia artificial en cosmología.

Estas simulaciones están divididas por familias

- Illustris-1: alta resolución (1820^3 partículas)
- Illustris-2: resolución media (910^3)
- Illustris-3: resolución baja (455^3)





Illustris Simulations

Conjunto de datos de entrenamiento

Condiciones Iniciales:

- Generadas a redshift $z = 127$ con el código N-GenIC.
- Basadas en perturbaciones gaussianas lineales del fondo cósmico de microondas.
- Misma semilla para todas las versiones, garantizando comparabilidad

Modelo Cosmológico:

- Λ CDM plano, con parámetros de WMAP-9:

$$\Omega_m = 0.2726, \quad \Omega_\Lambda = 0.7274 \quad H_0 = 70.4 \text{ km/s/Mpc} \quad \sigma_8 = 0.809, \quad n_s = 0.963$$

Contenido Simulado:

- Partículas de materia oscura y gas bariónico
- Formación estelar y retroalimentación (stellar & AGN feedback)
- Evolución de agujeros negros supermasivos
- Resolución espacial adaptativa mediante mallas móviles (AREPO)

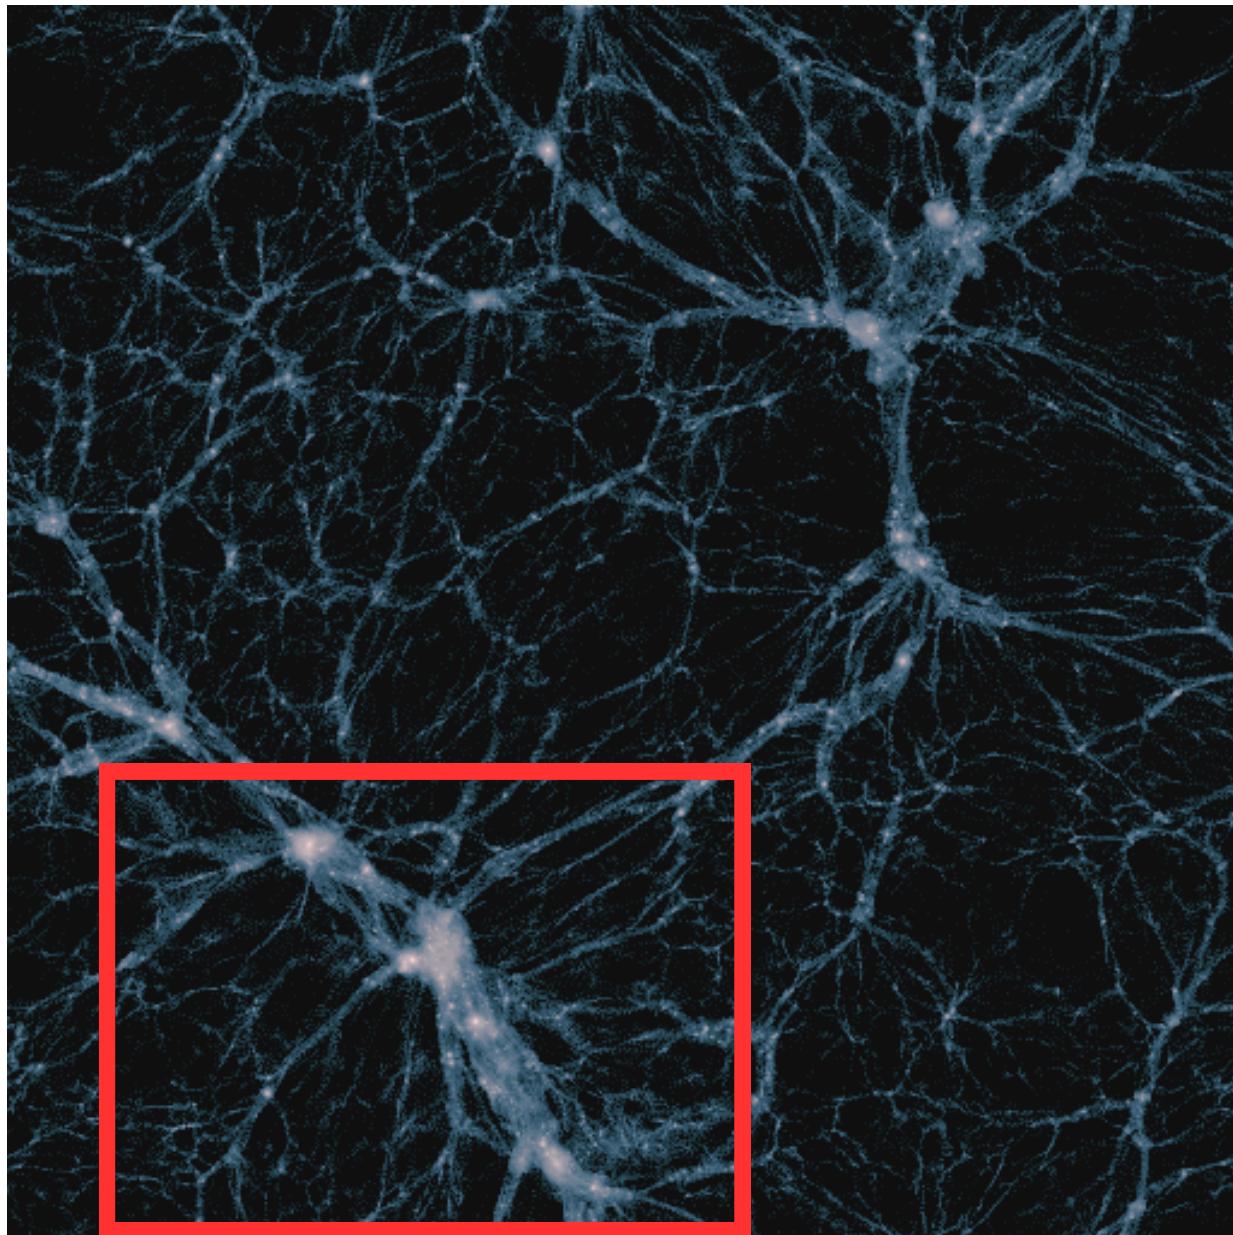


Illustris Simulations

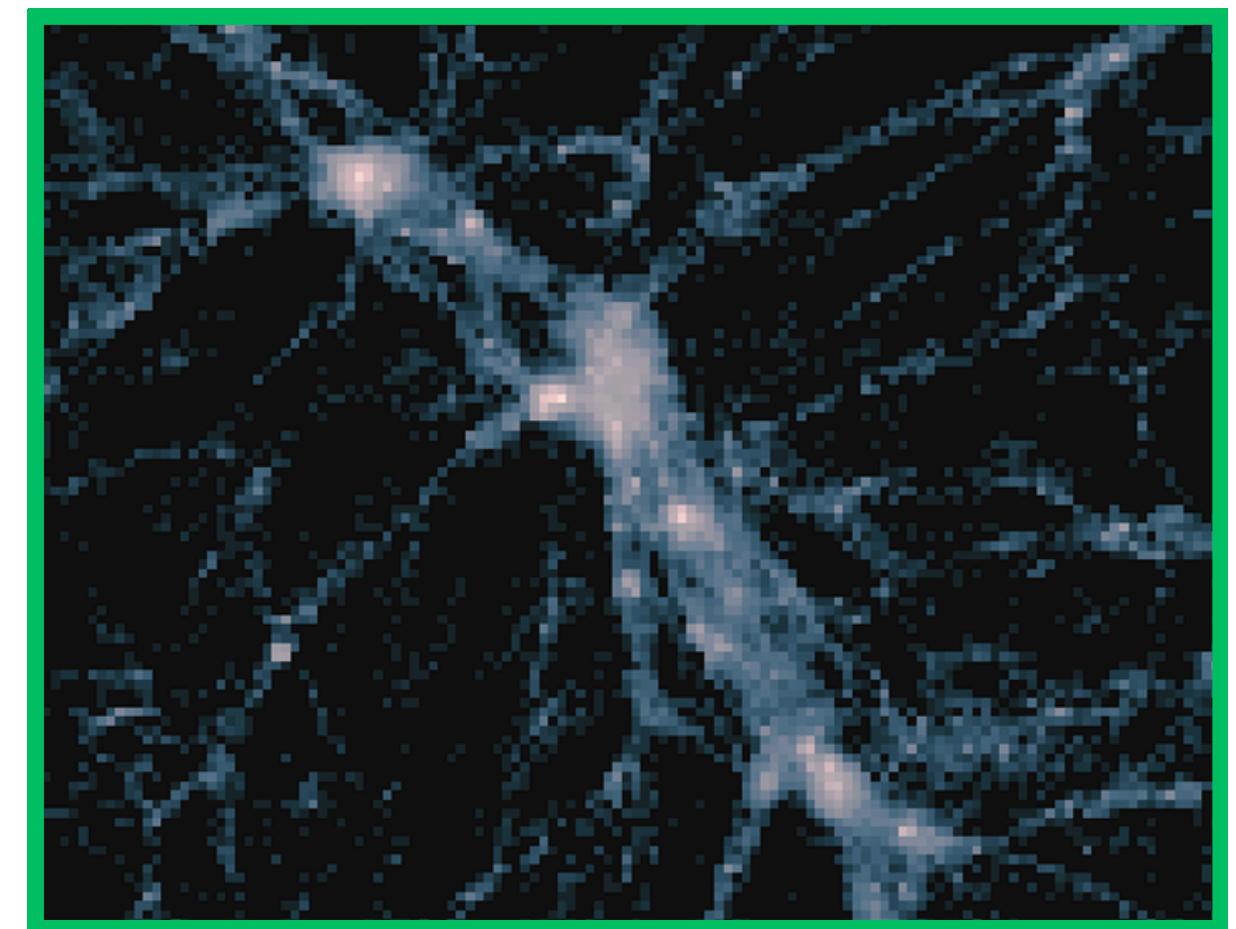
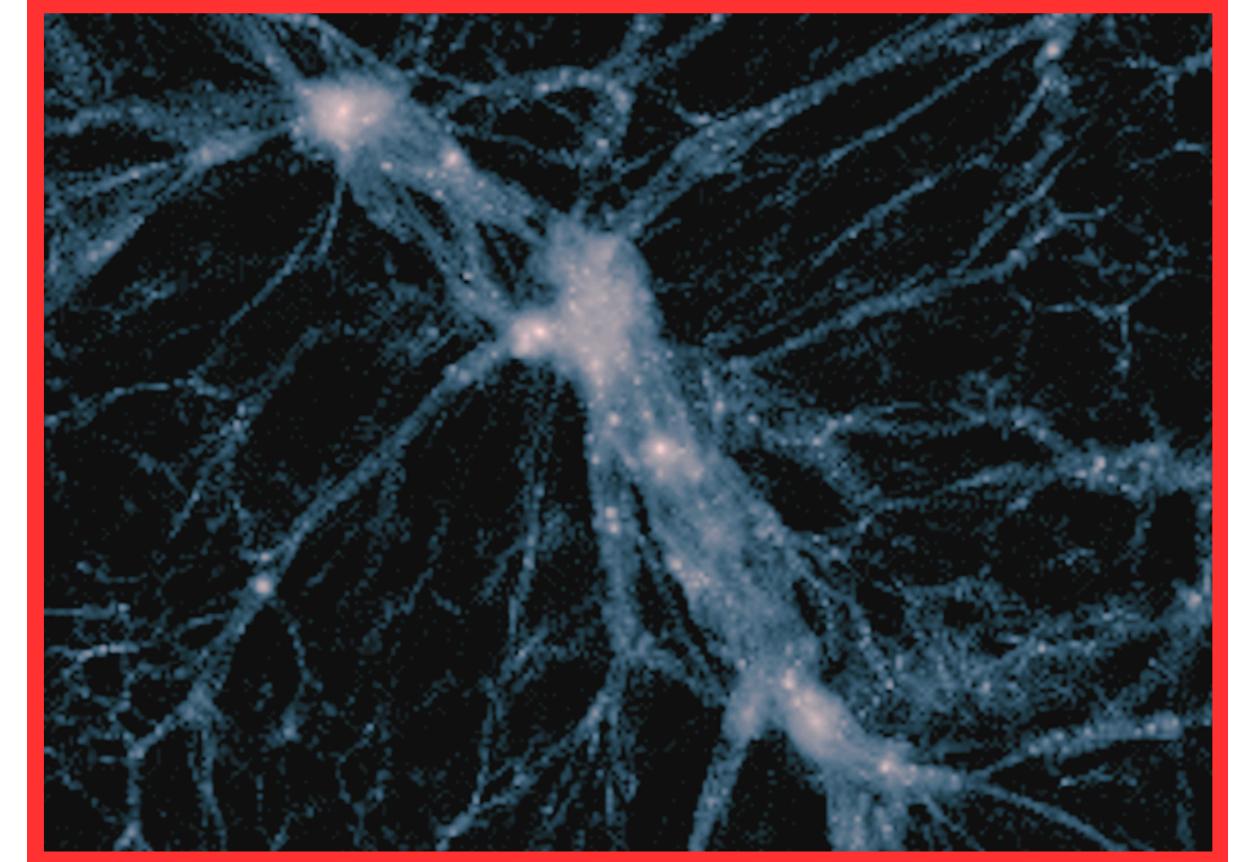
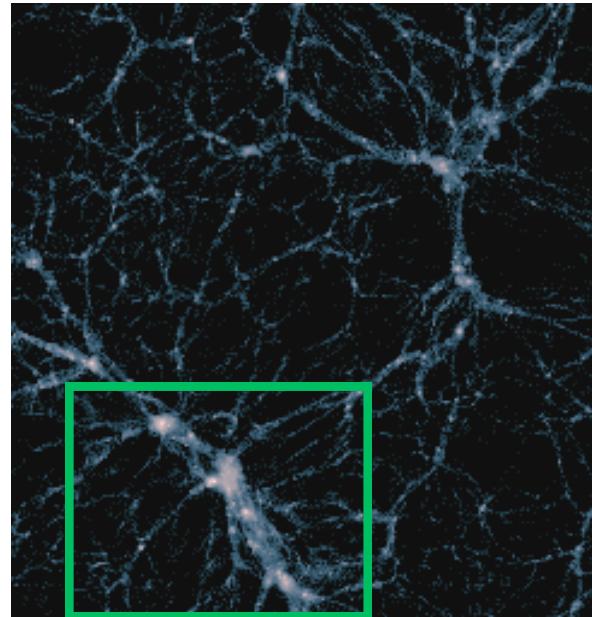
Conjunto de datos de entrenamiento

Generamos cortes en cada plano de un grosor de 0.25 Mpc, con un numero de celdas acorde con la densidad de particulas.

Illustris-2



Illustris-3



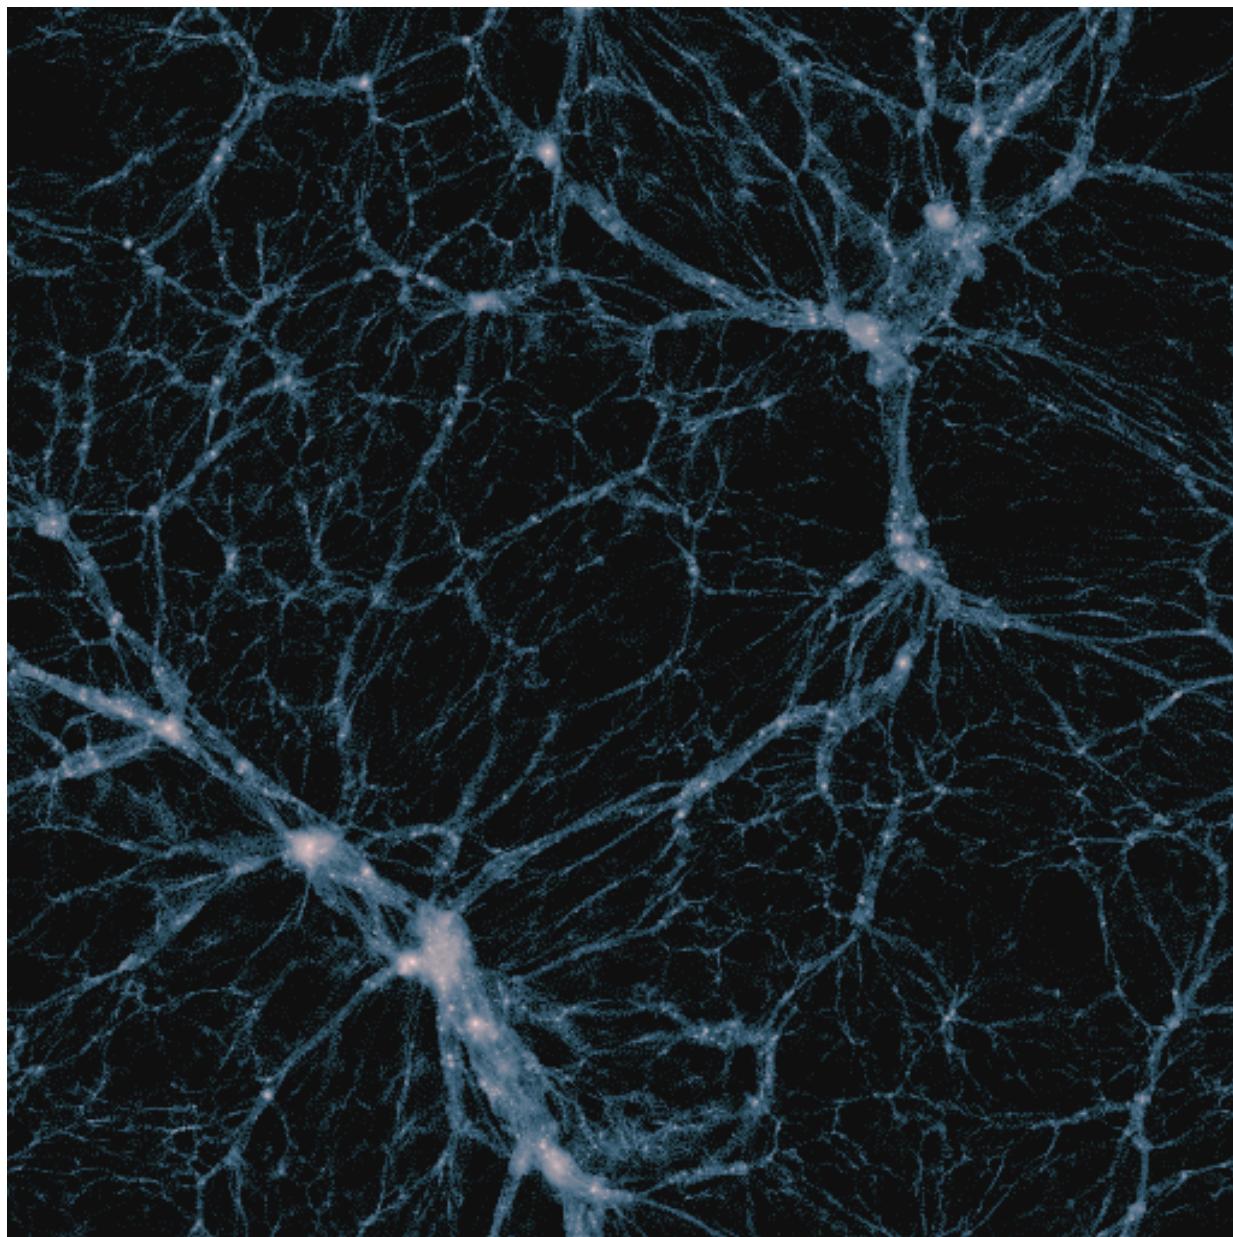


Illustris Simulations

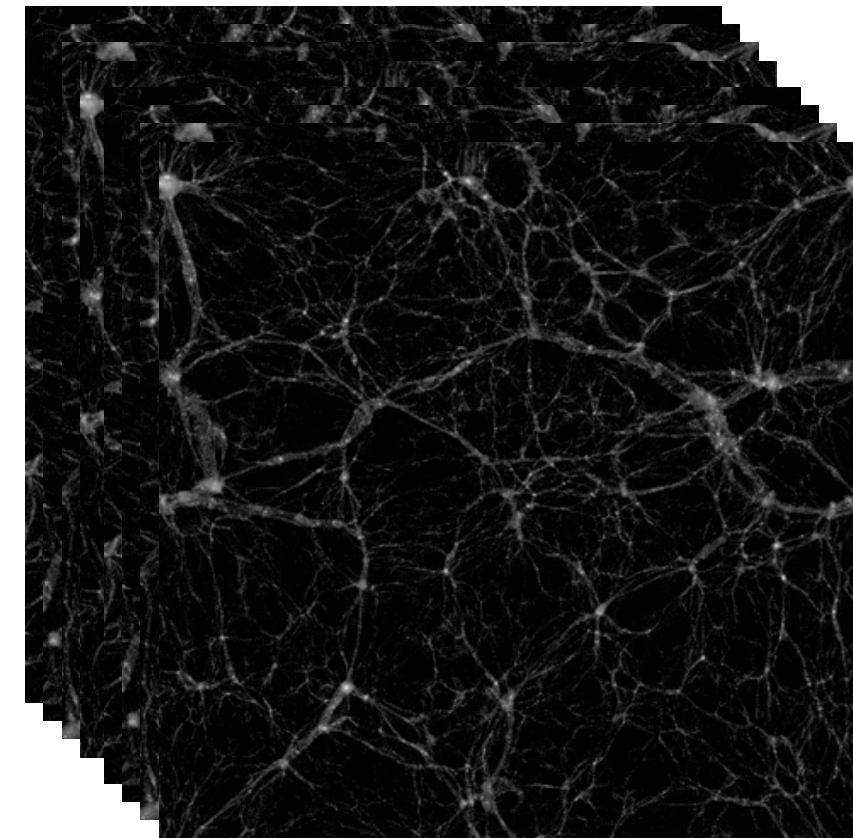
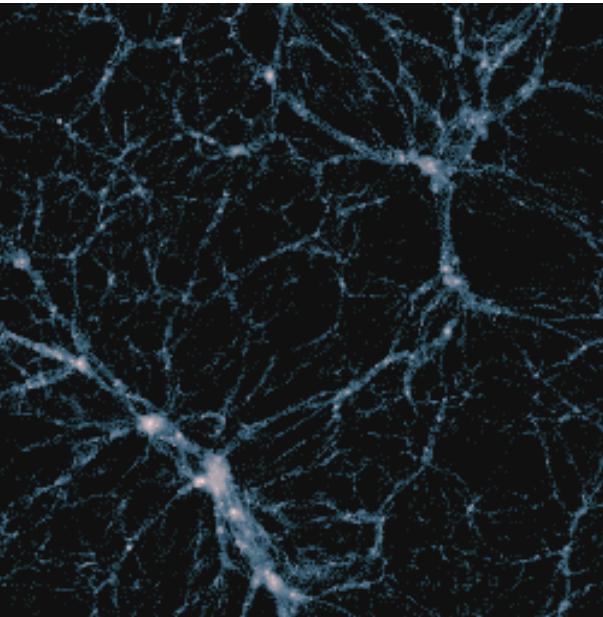
Conjunto de datos de entrenamiento

El dataset de entrenamiento contempló 7200 pares de imágenes, divididos en 90% entrenamiento, 10% validación, con 800 para test

Illustris-2

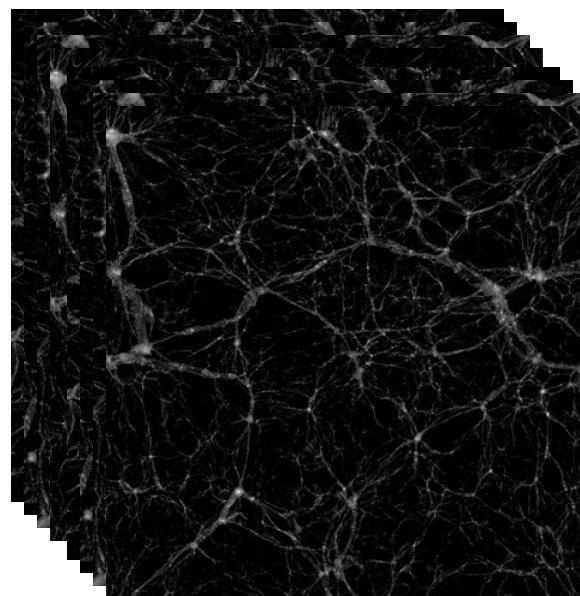


Illustris-3



Illustris-2
7200

Training - 6480
Validation - 720

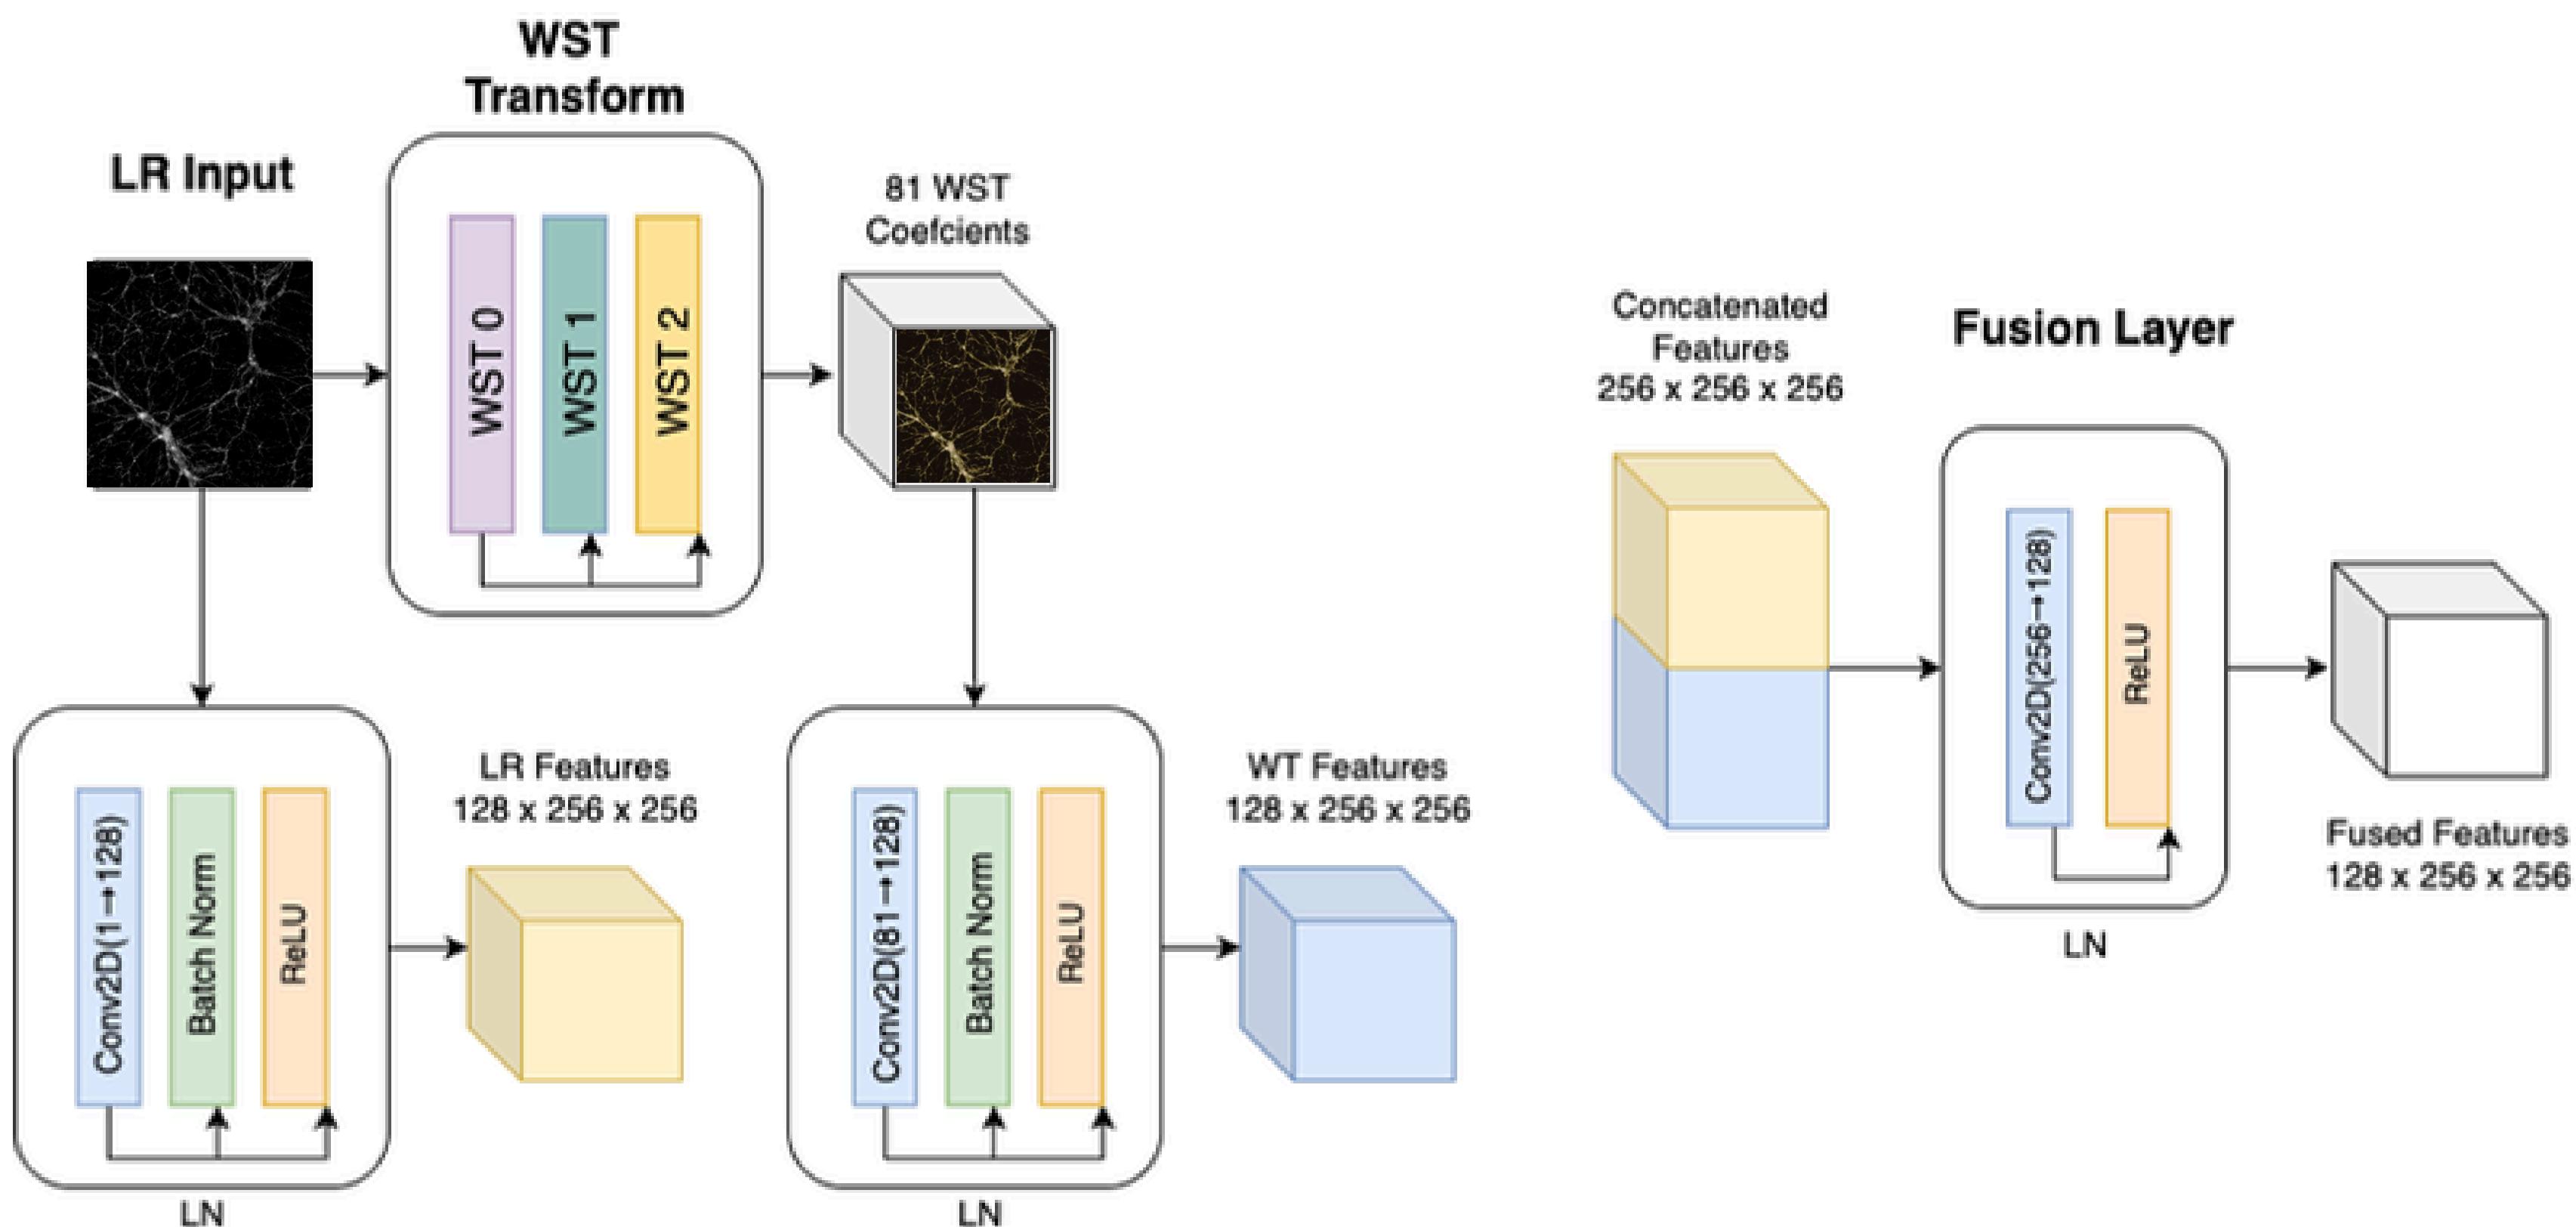


Illustris-3
7200



Estructura de la red

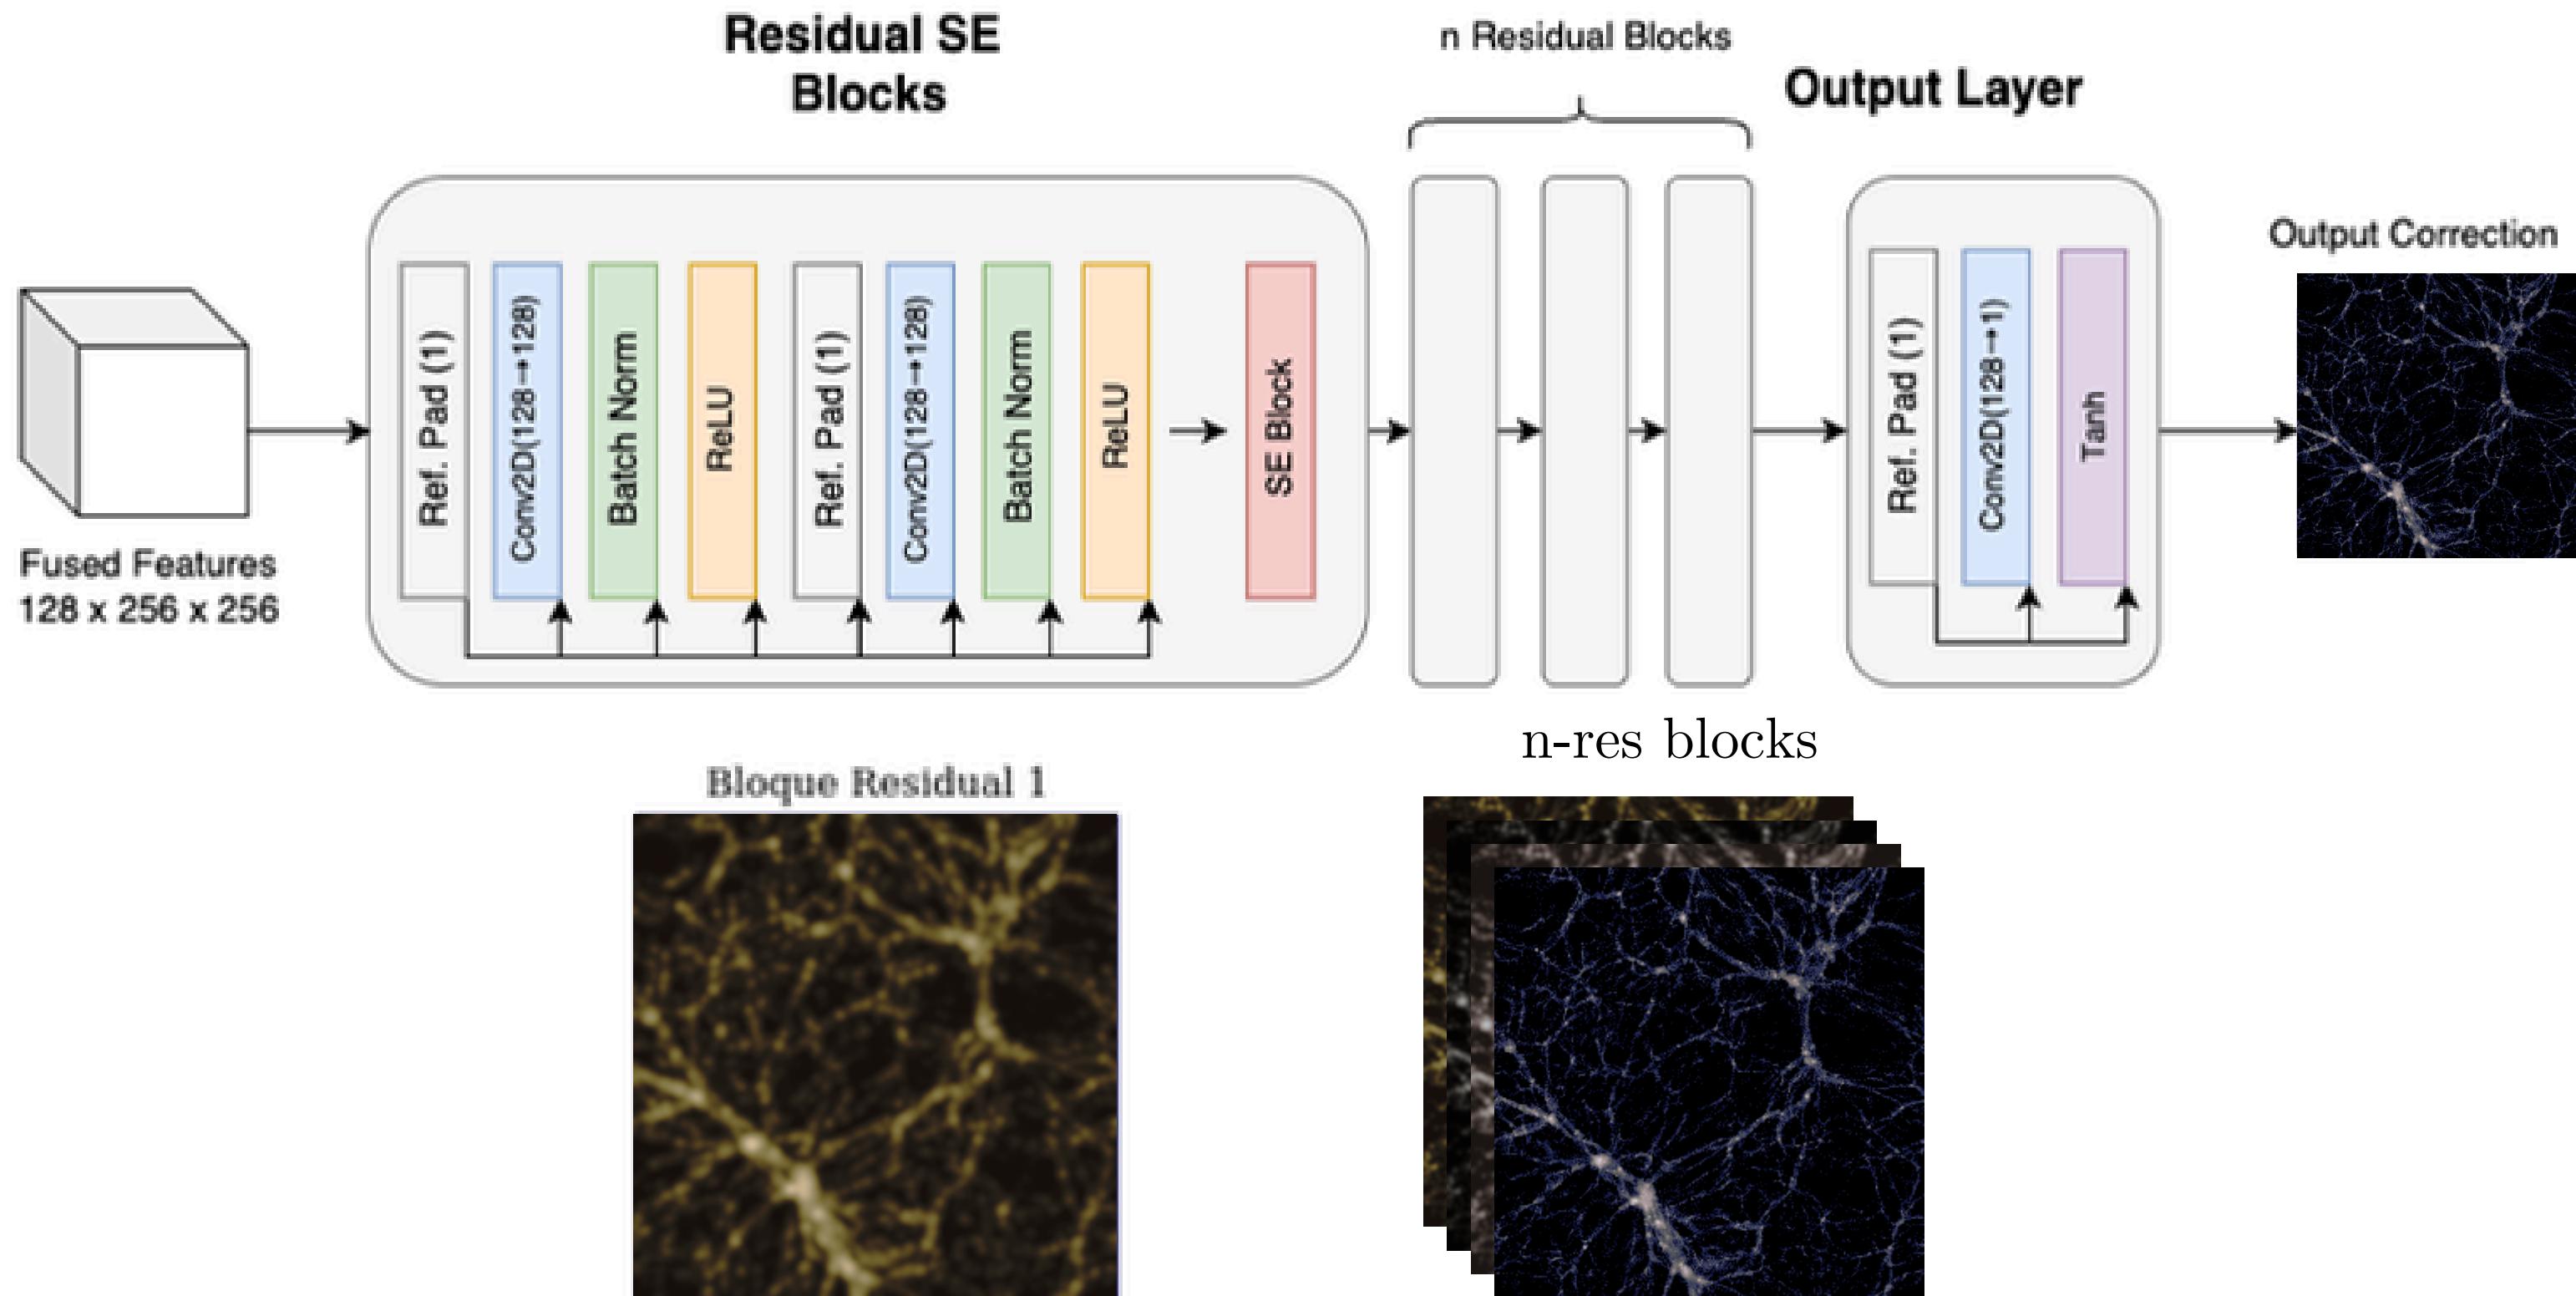
Arquitectura





Estructura de la red

Arquitectura

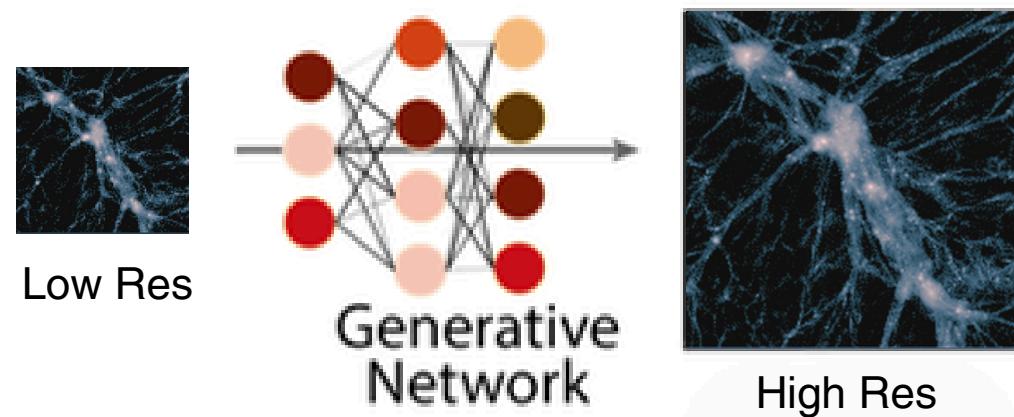




Loss Function

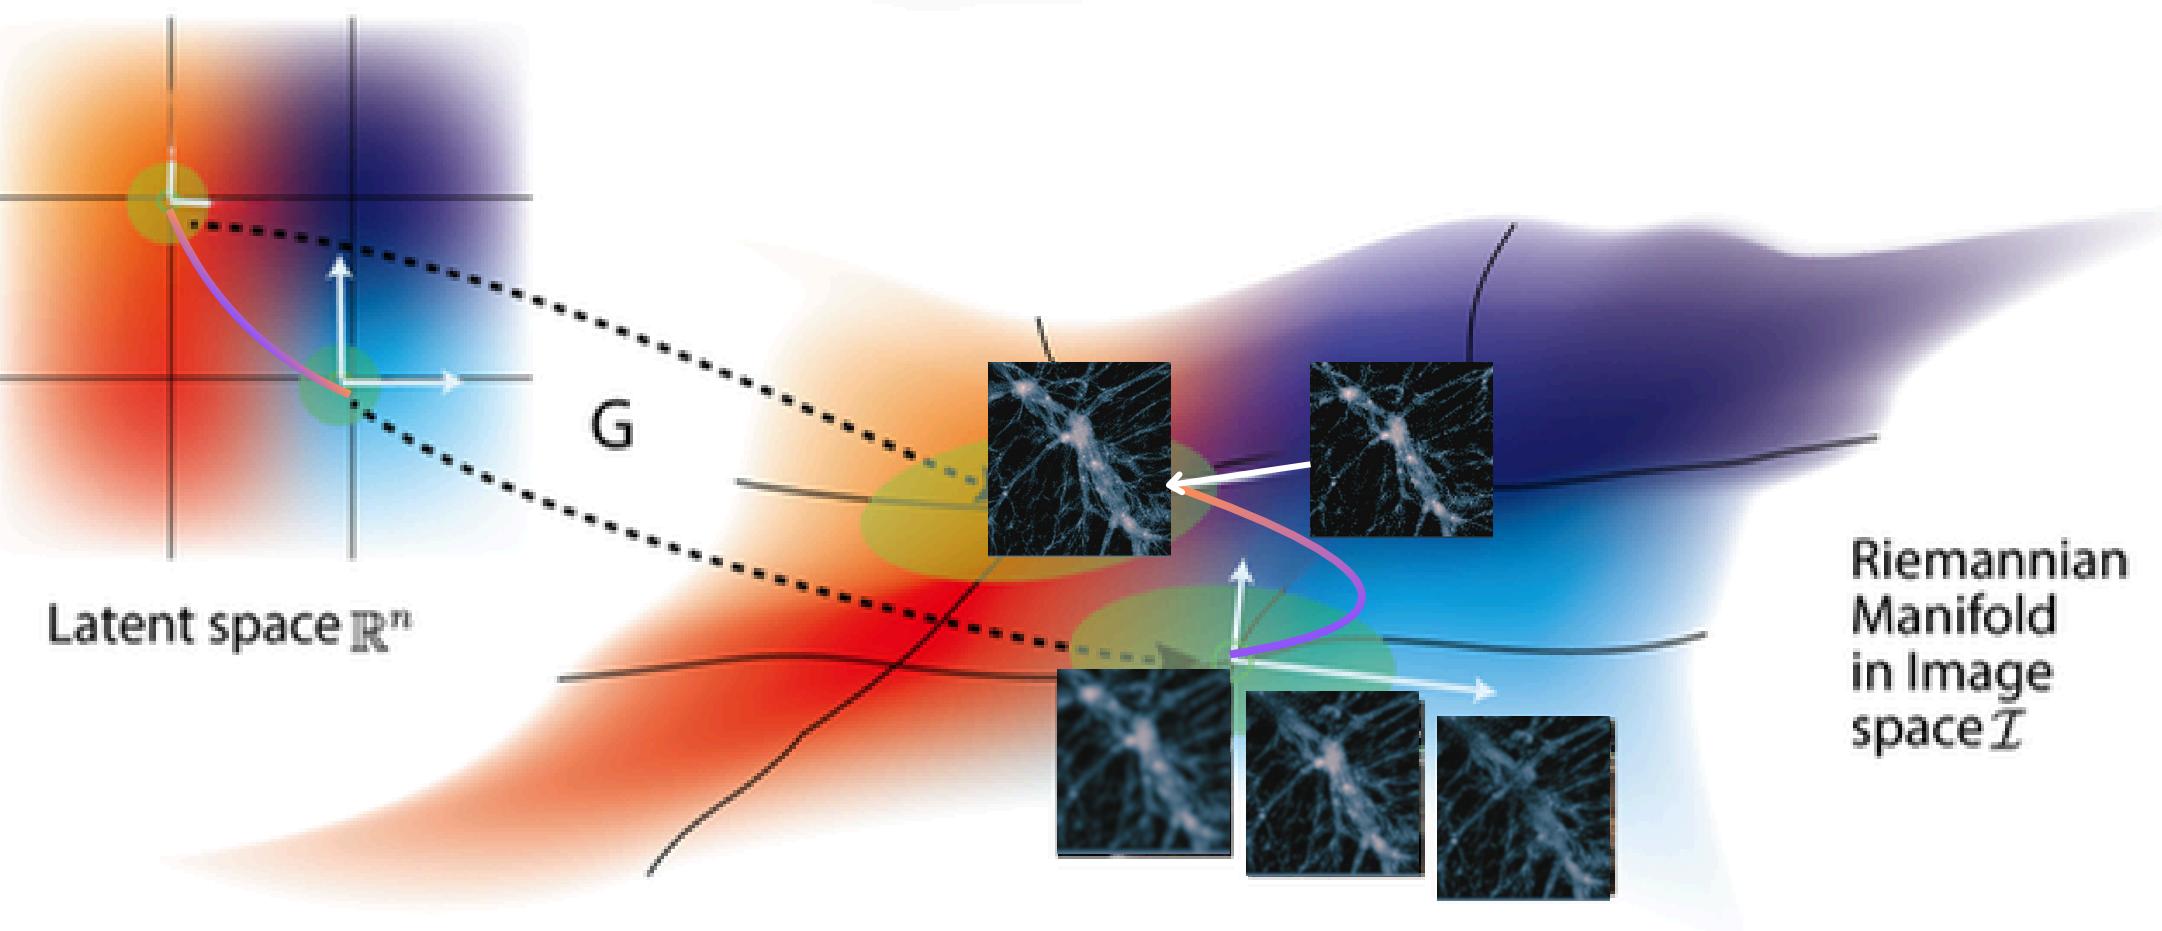
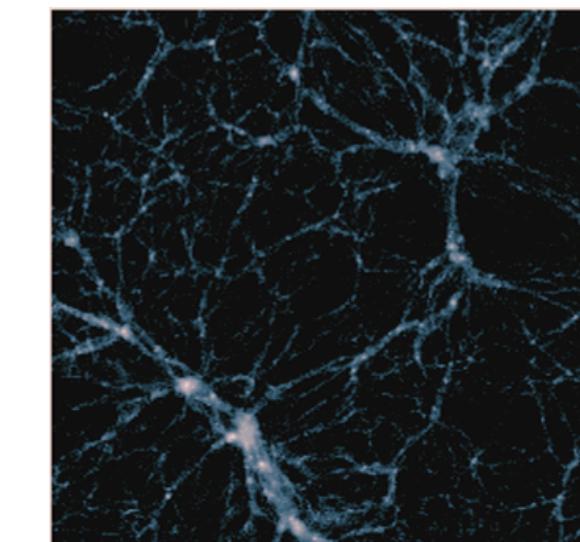
Calidad de una imagen

Riemannian Geometry of Generator

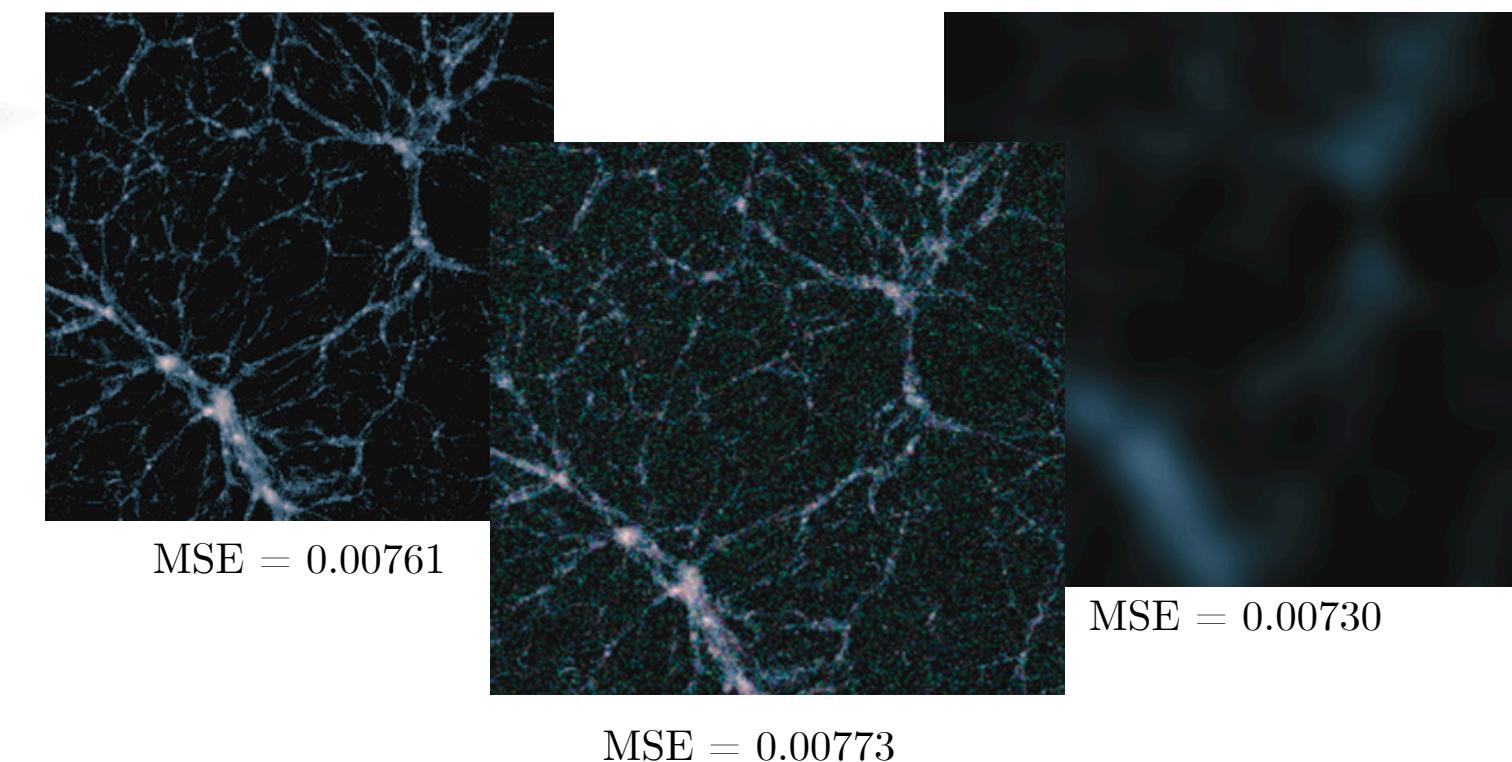


Loss functions guide the network to approximate the trajectory to the high resolution image

L2 Loss



Riemannian
Manifold
in Image
space \mathcal{I}

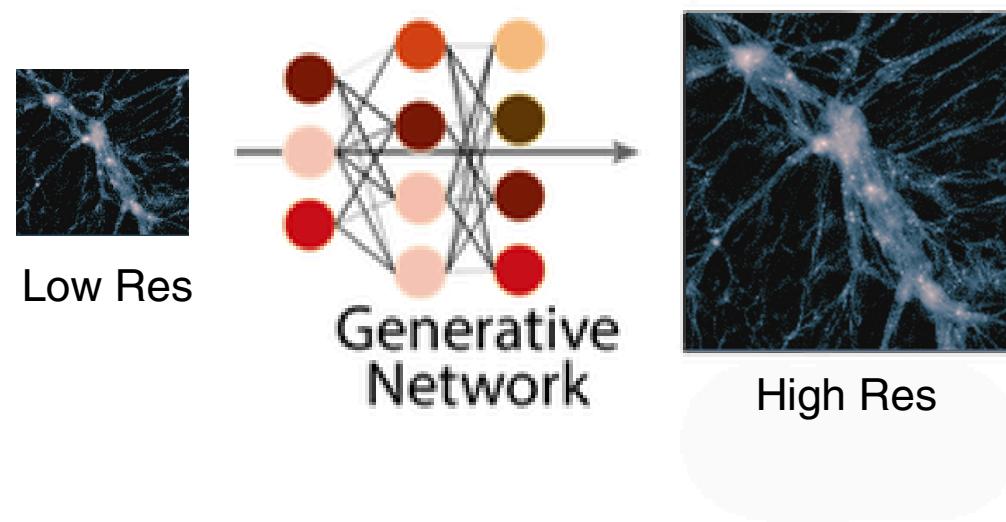




Loss Function

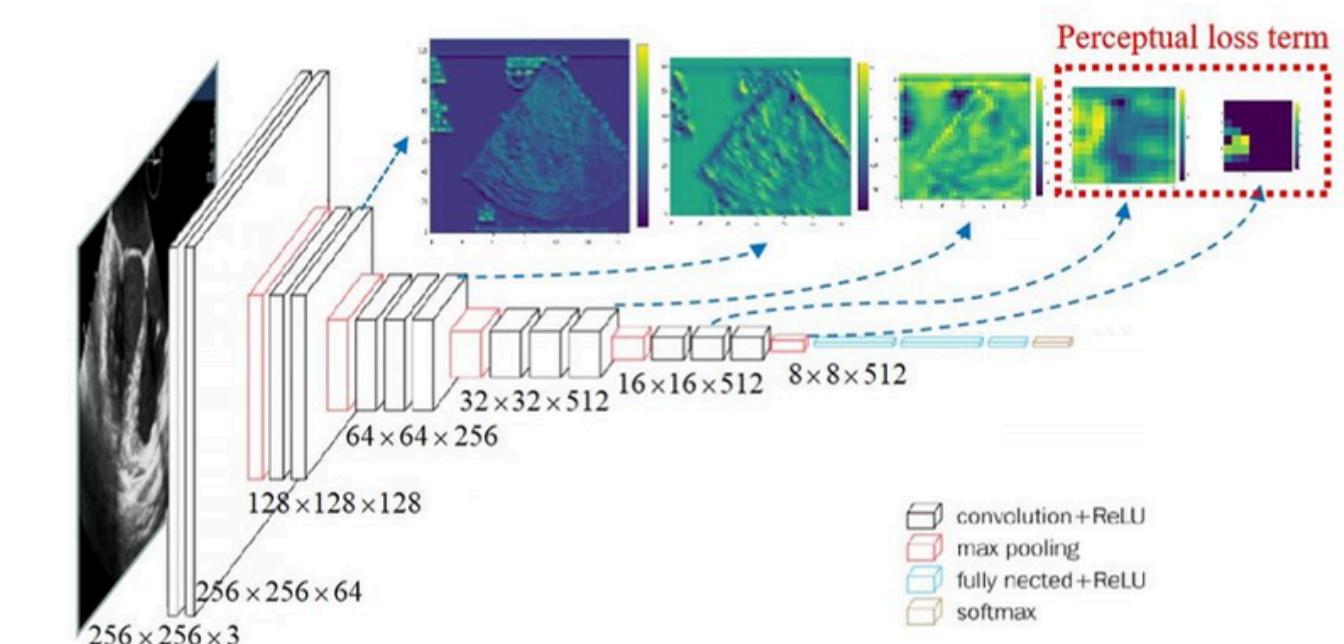
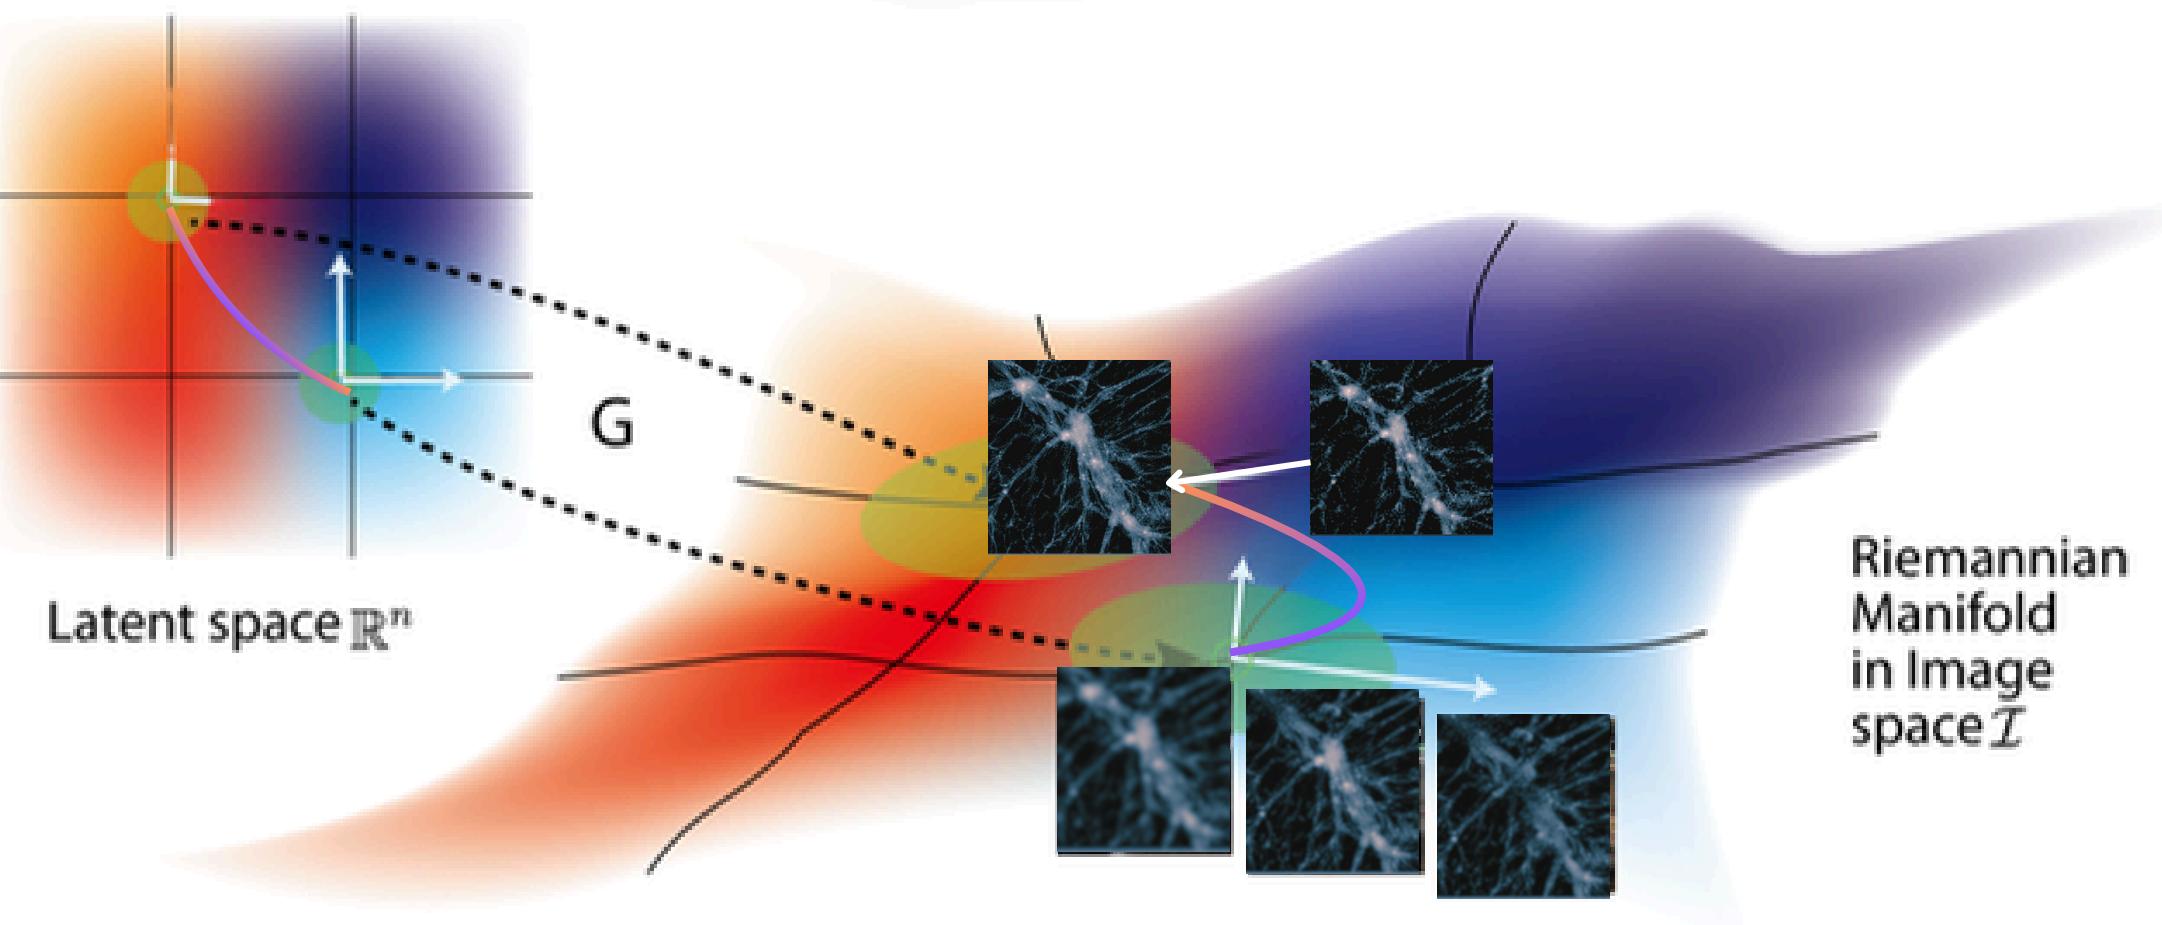
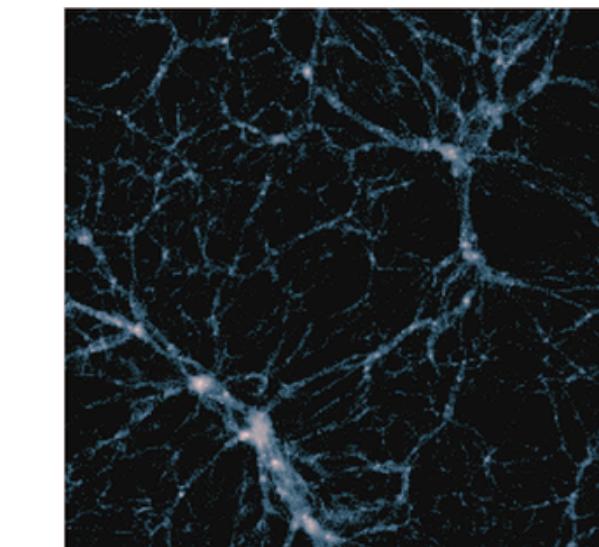
Calidad de una imagen

Riemannian Geometry of Generator



Loss functions guide the network to approximate the trajectory to the high resolution image

Perceptual Loss

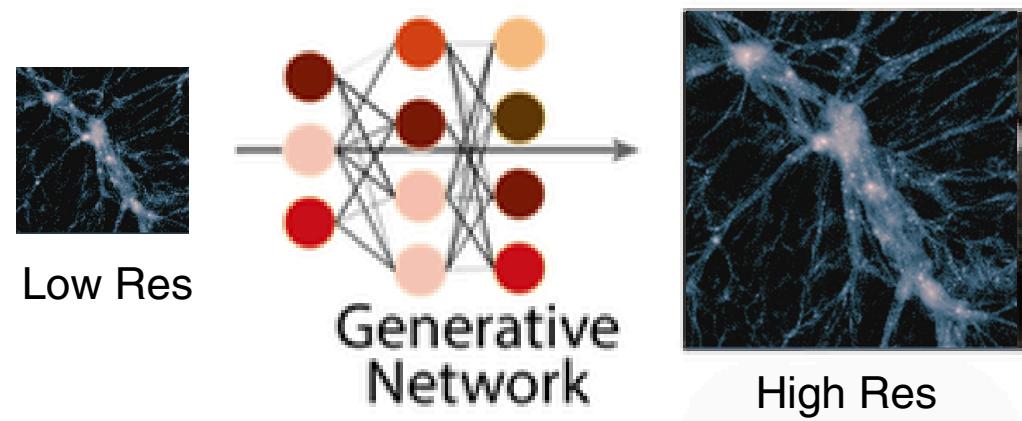




Loss Function

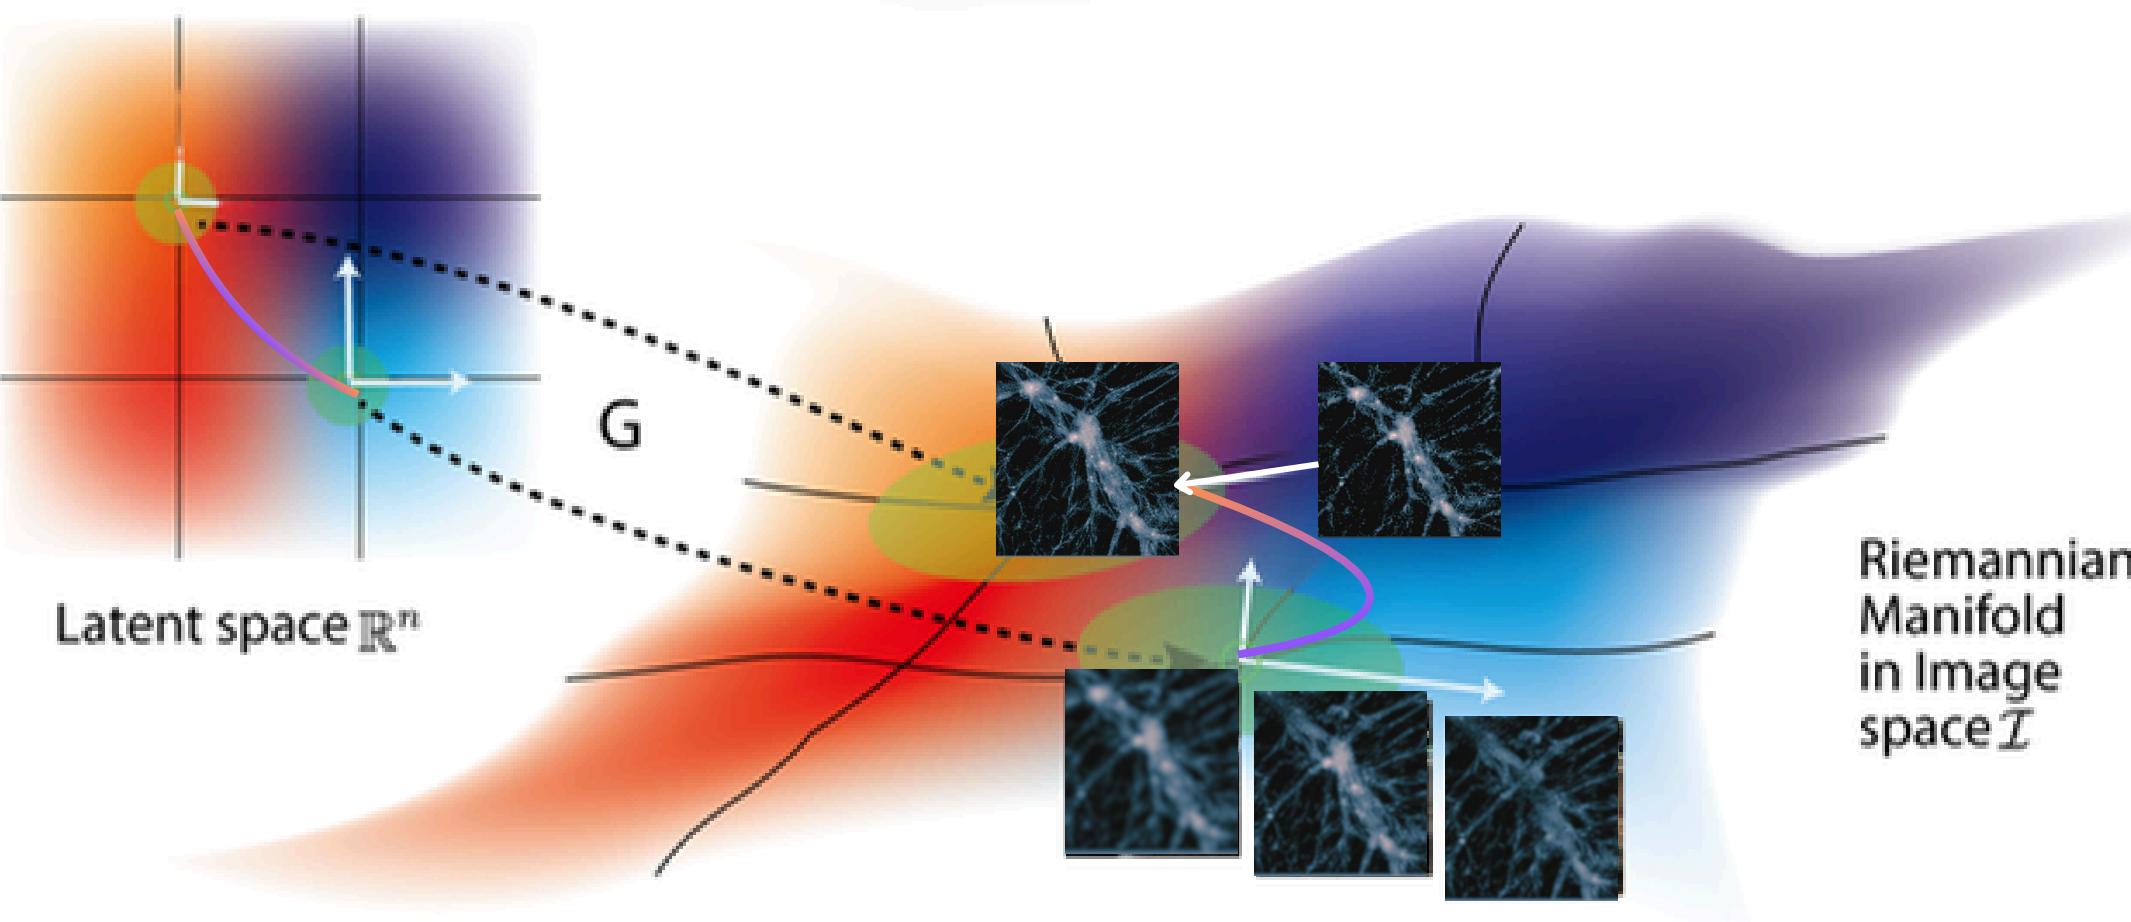
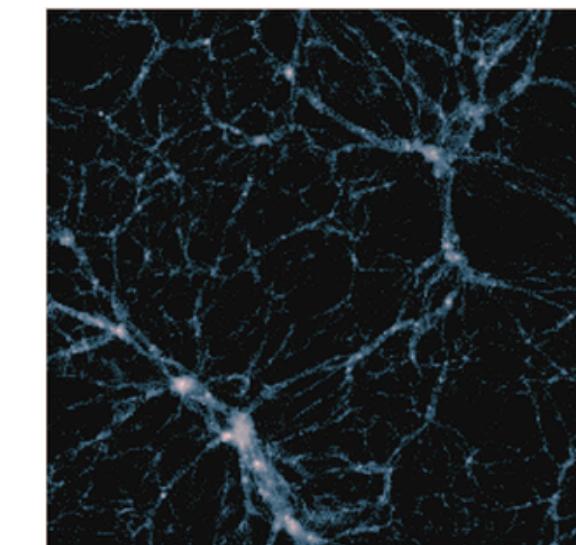
Calidad de una imagen

Riemannian Geometry of Generator

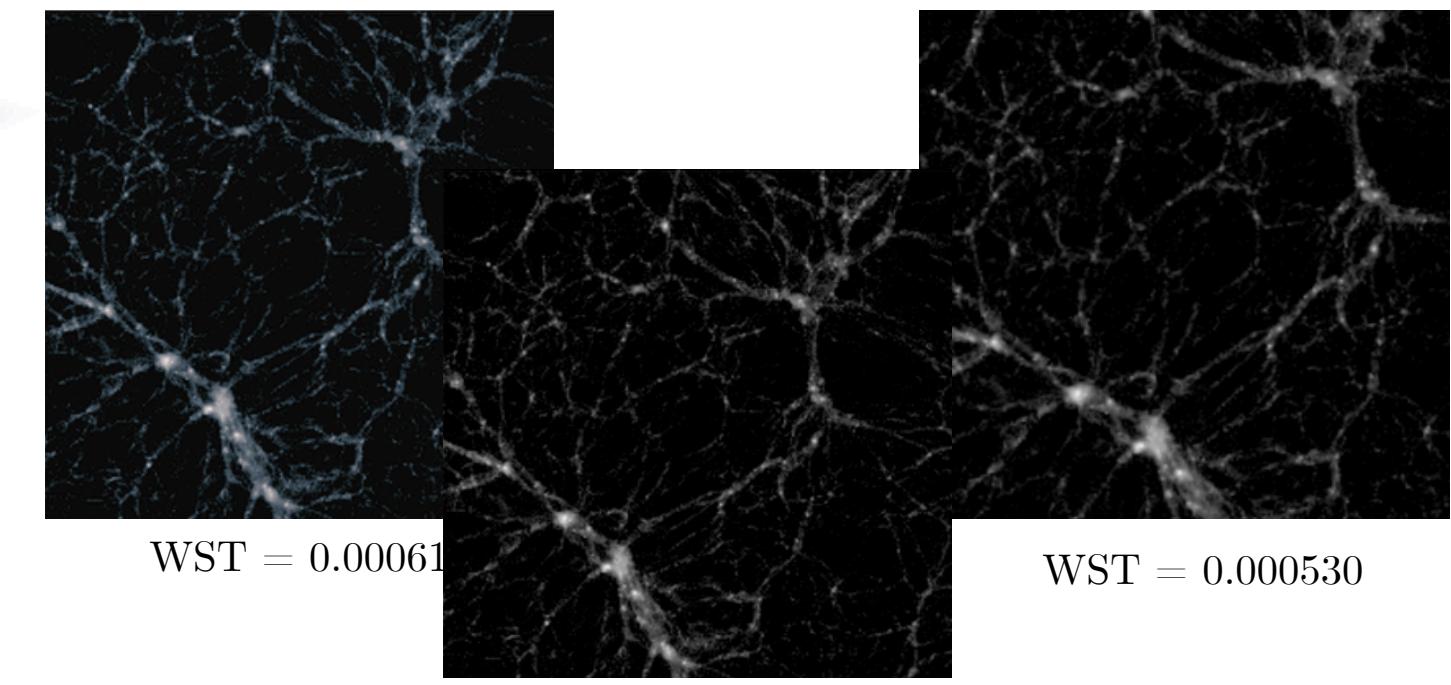


Loss functions guide the network to approximate the trajectory to the high resolution image

WST Loss



Riemannian
Manifold
in Image
space \mathcal{I}

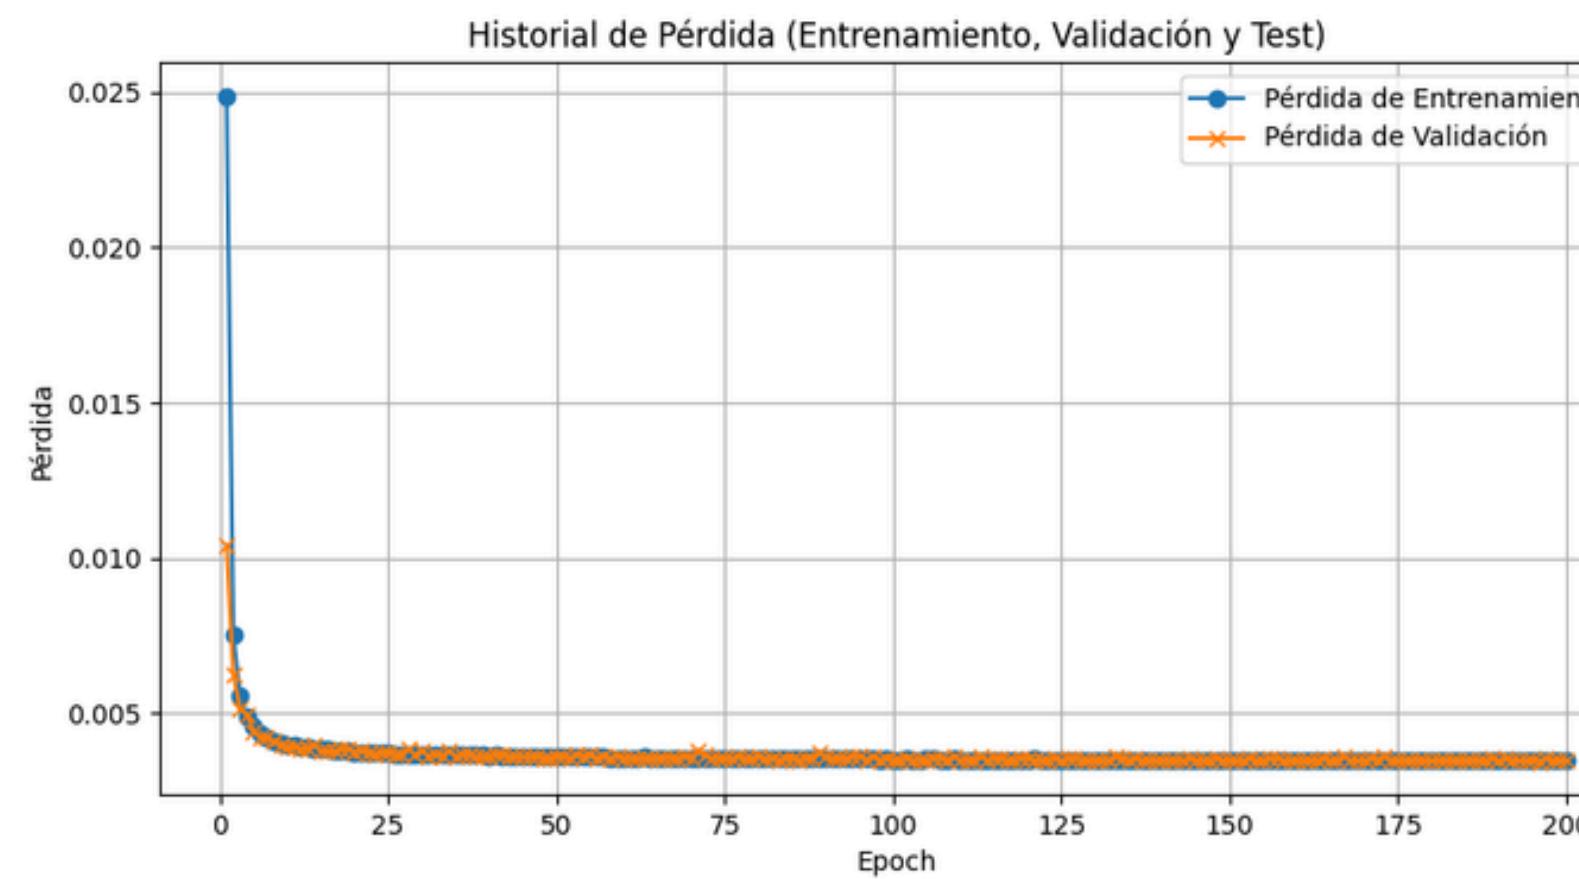




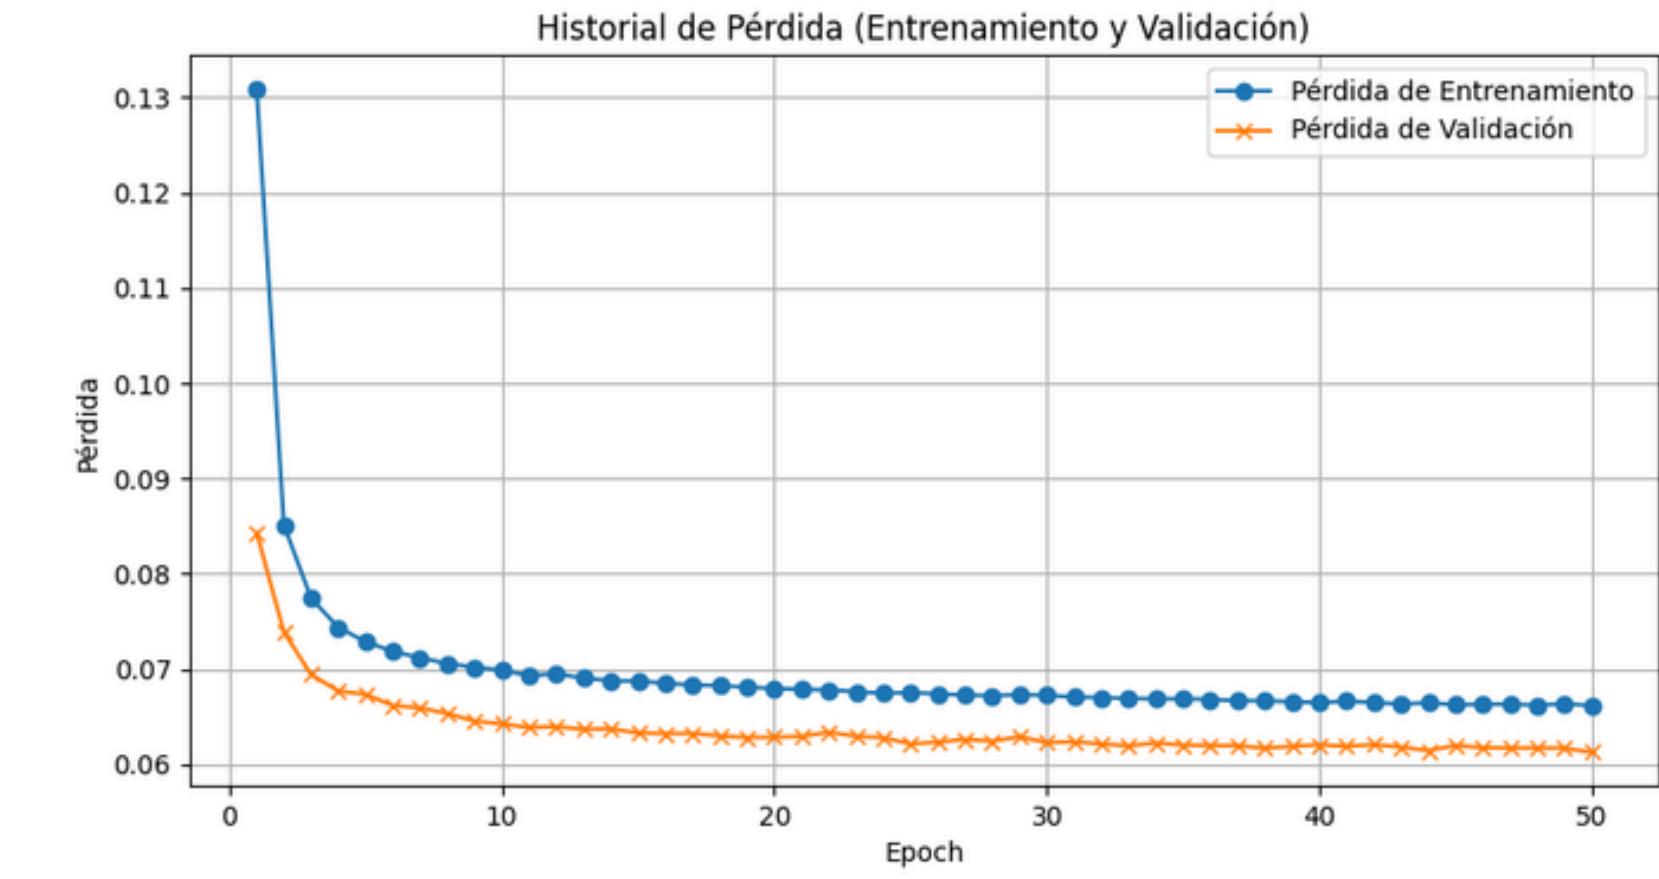
Entrenamiento

Proceso computacional

Se realizaron diferentes entrenamientos variando el numero de bloques residuales y de loss functions, cada entrenamiento se realizó empleando una tarjeta grafica RTX 4090 de 24 GB de V-RAM, tomando un tiempo de ejecucion continuo de 8 horas



4 bloques residuales



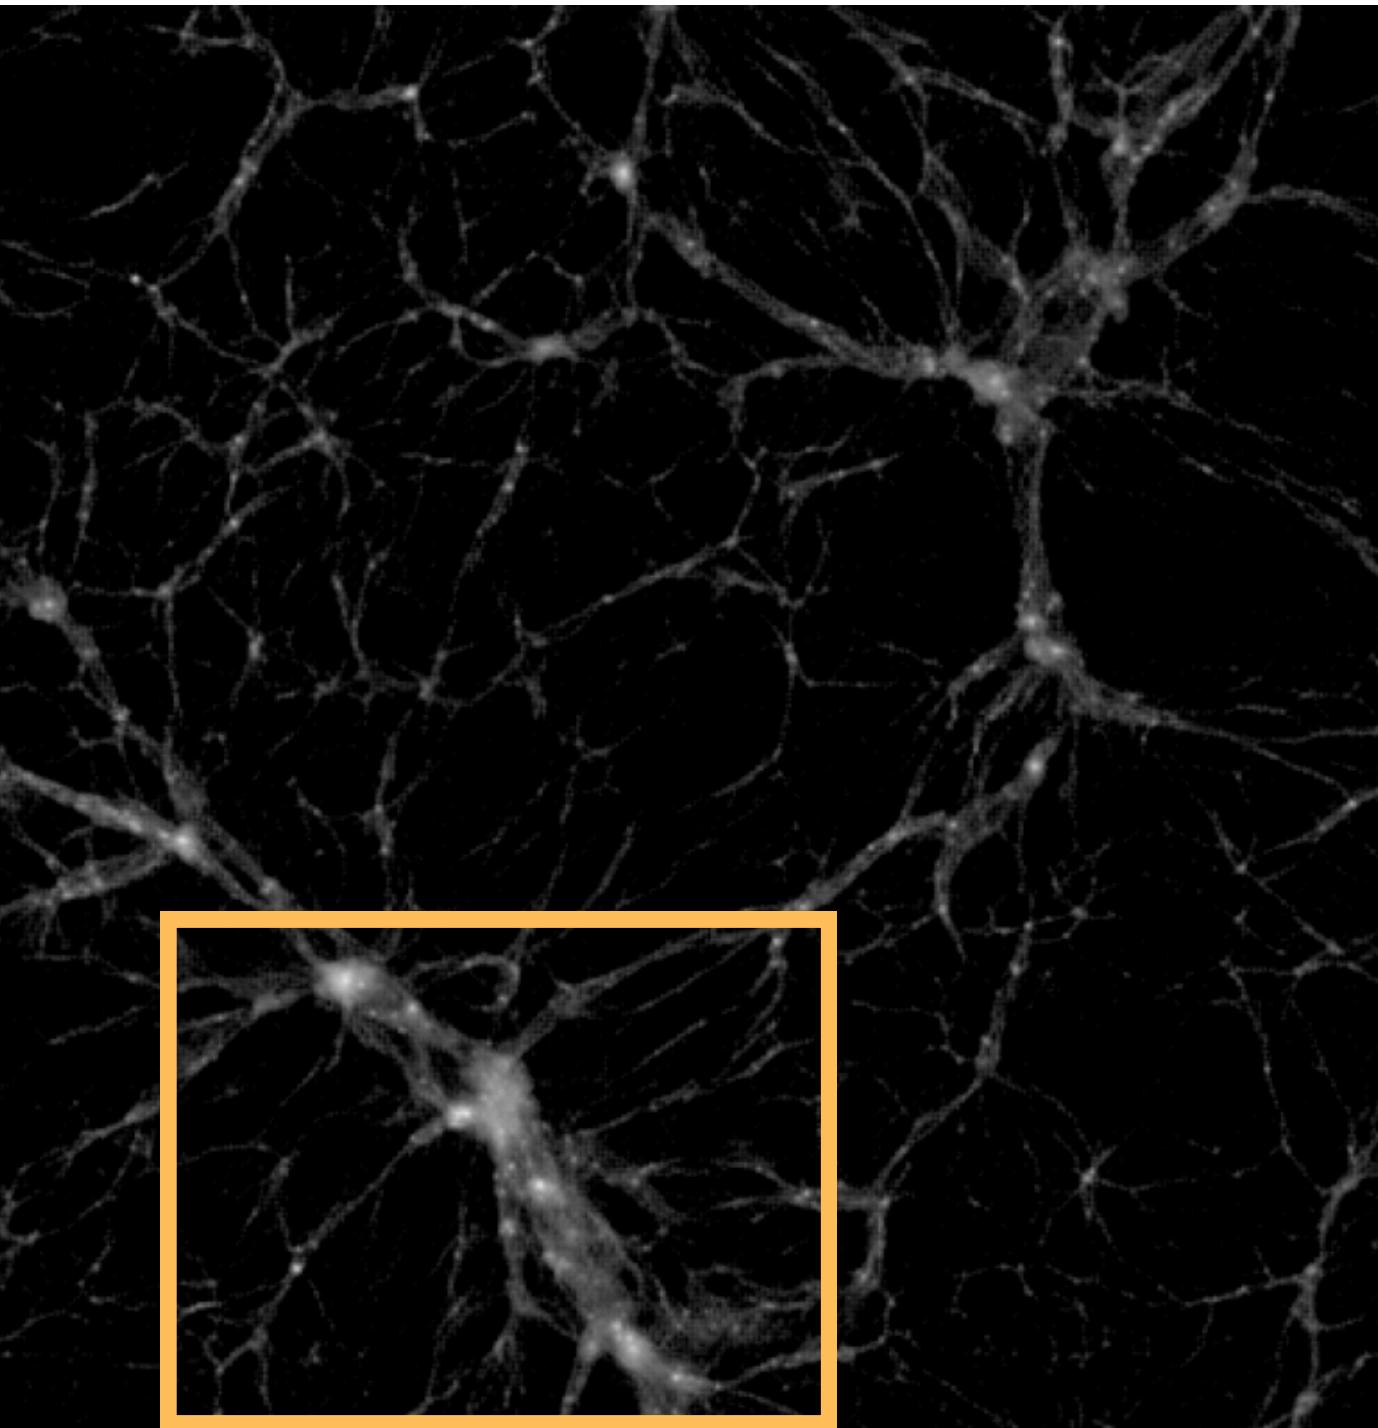
10 bloques residuales



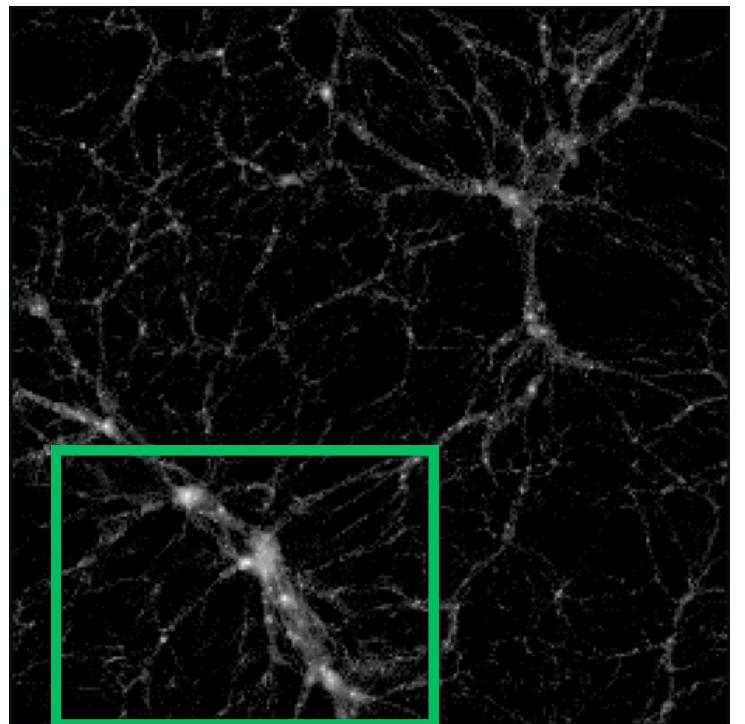
Resultados

Evaluación

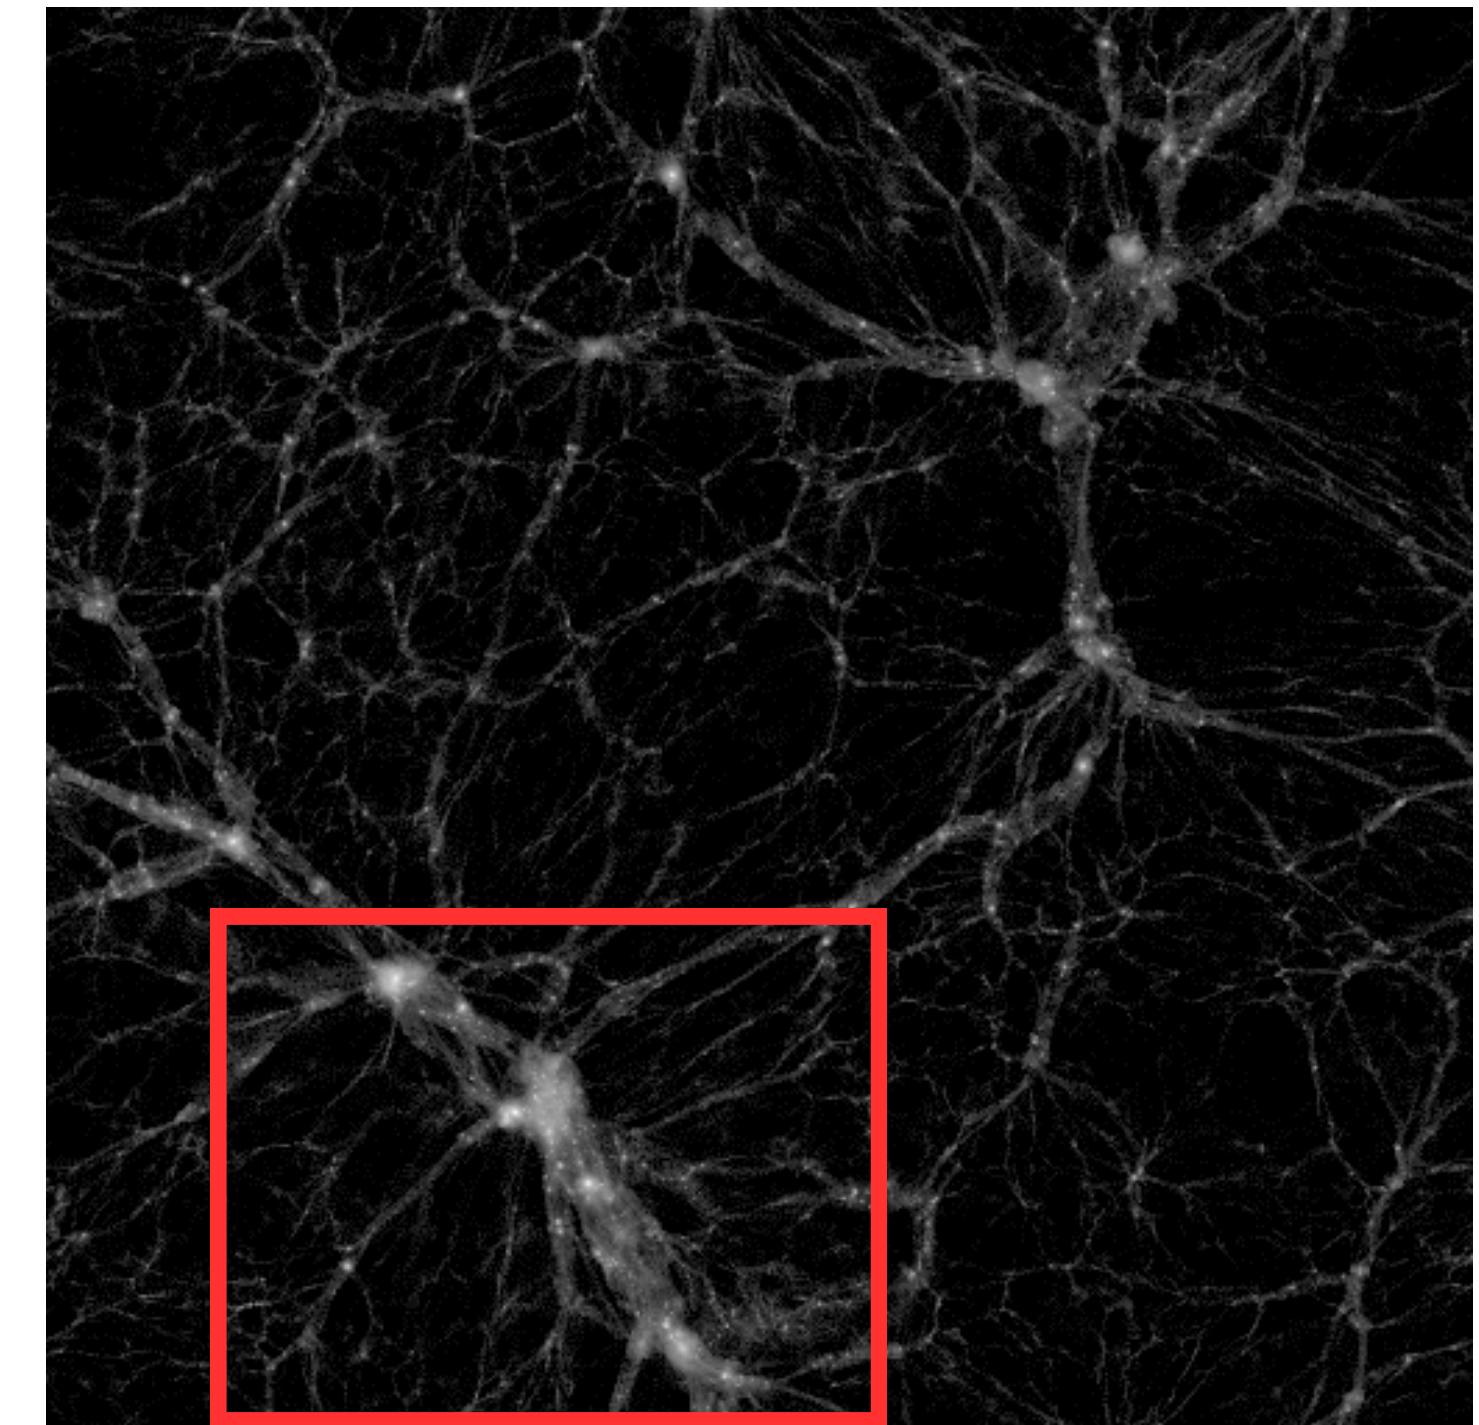
Model Result



Illustris-3



Illustris 2

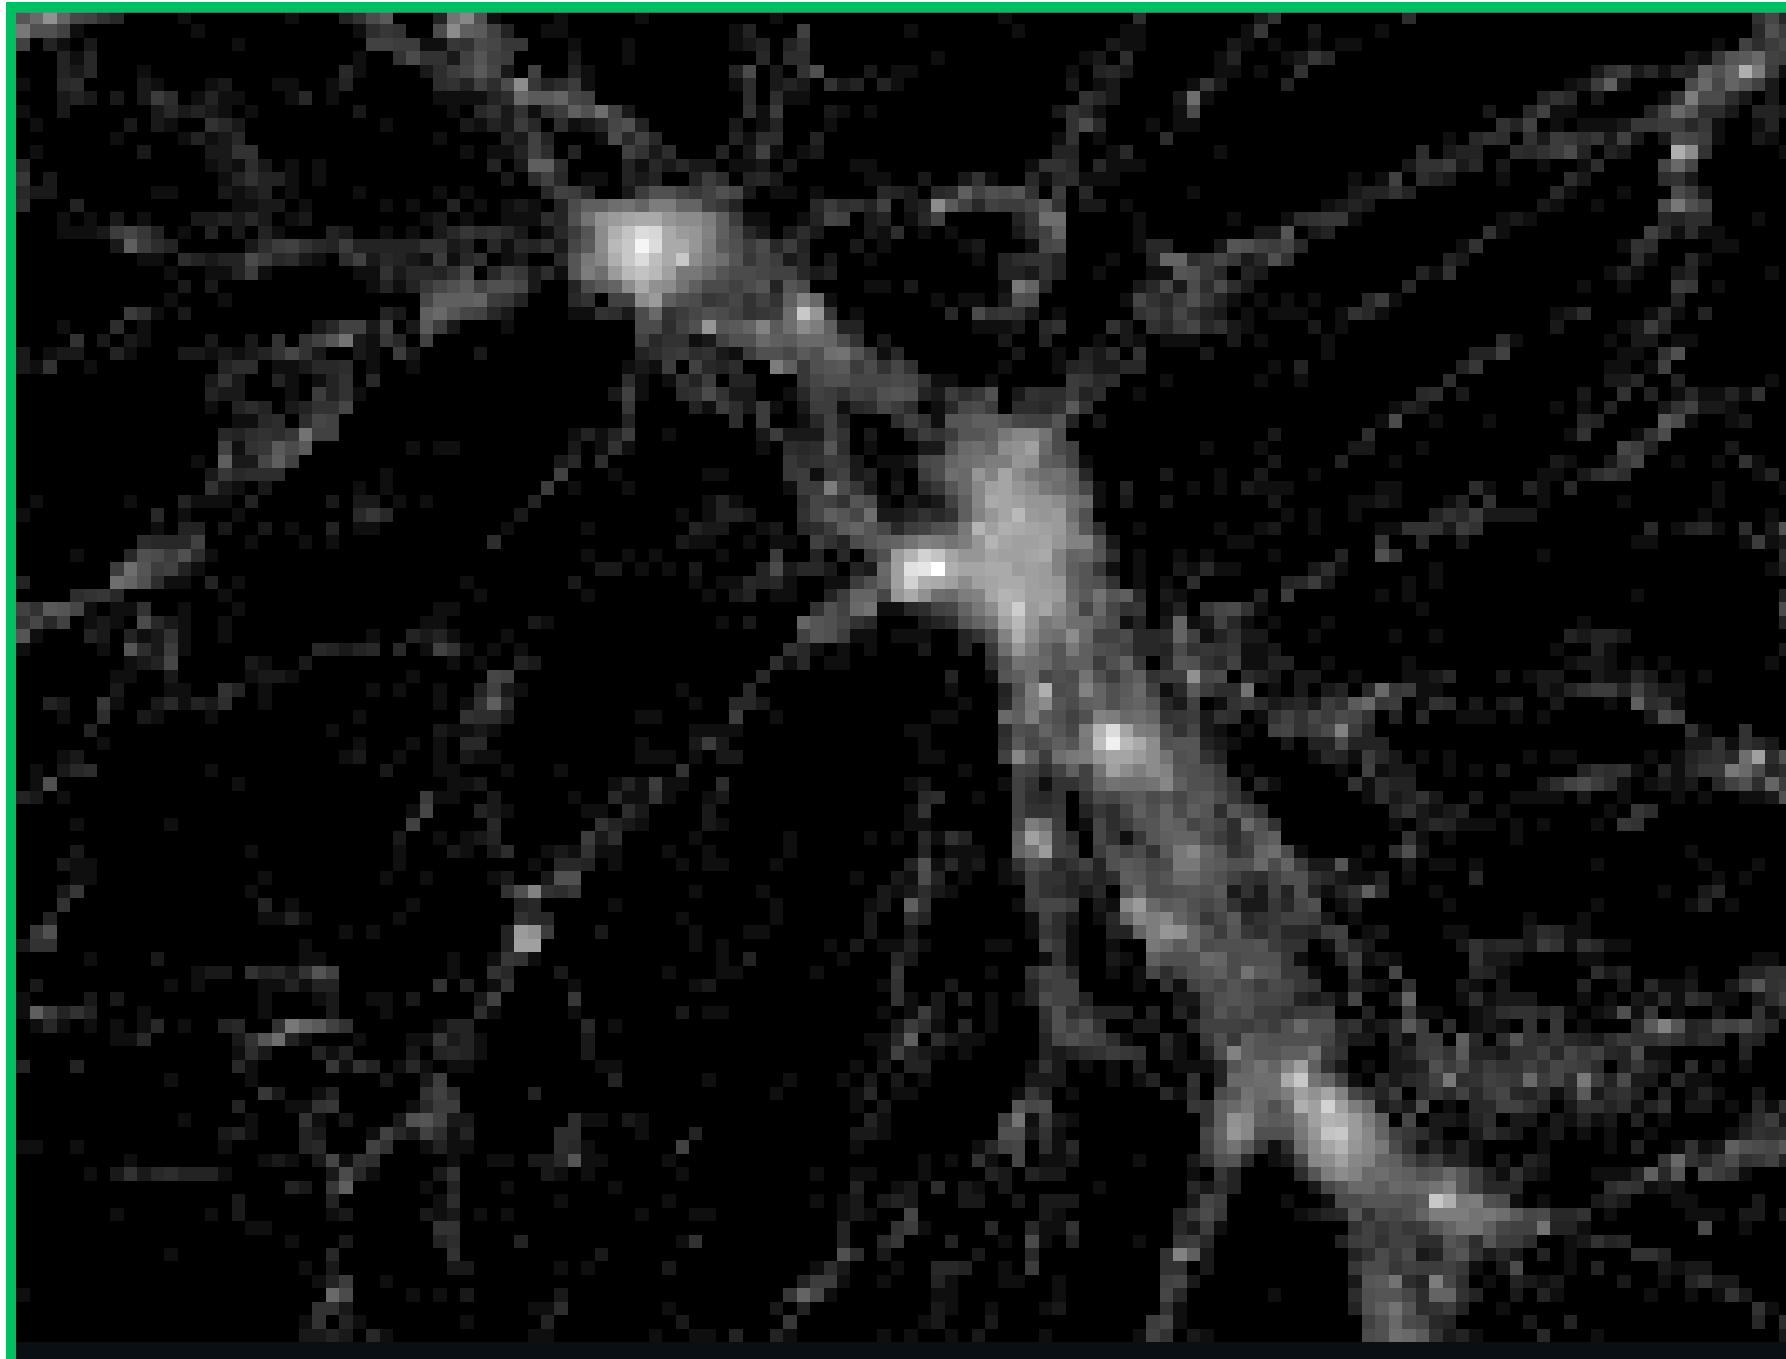




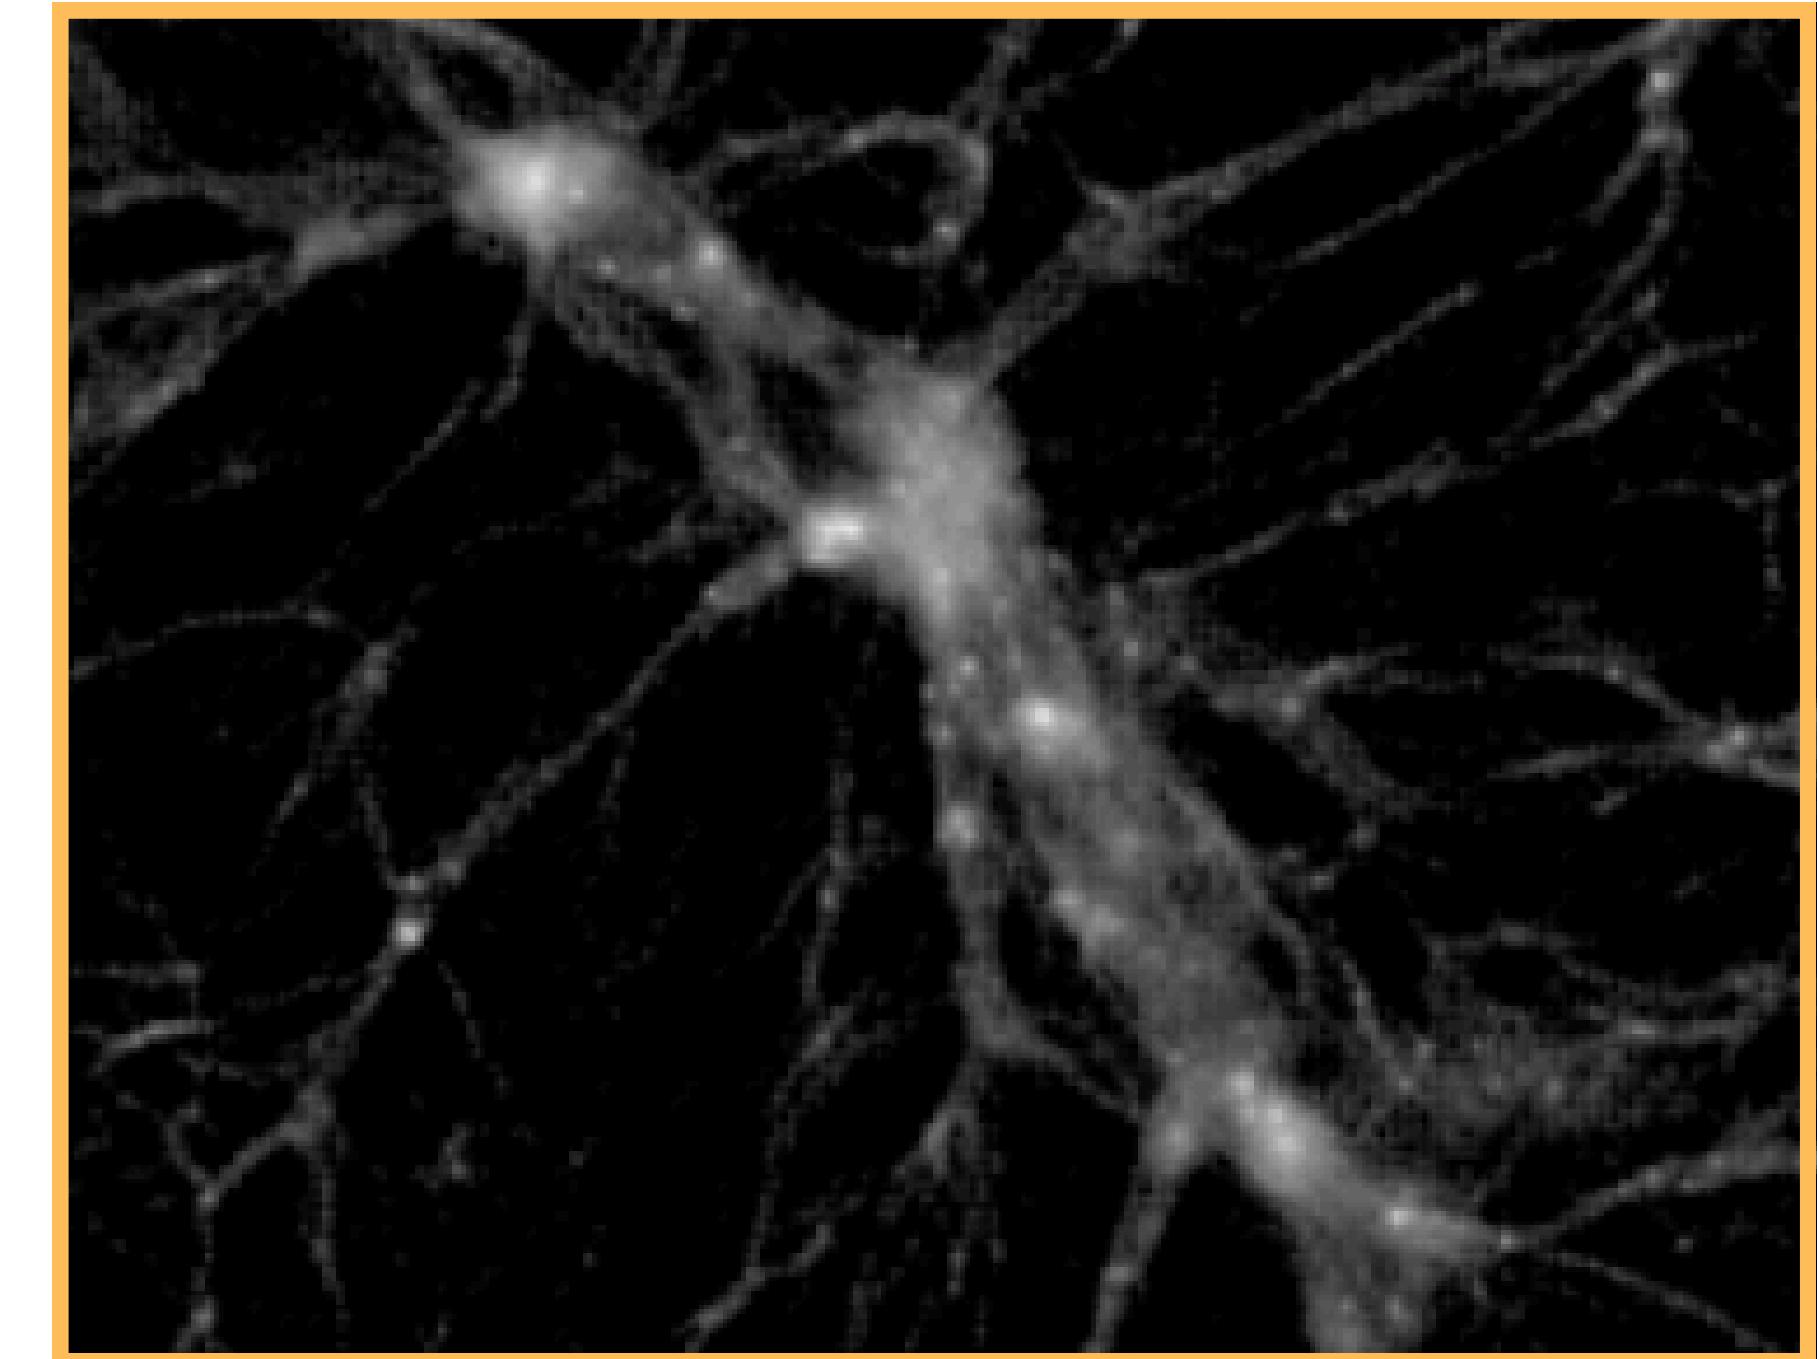
Resultados

Evaluación

Illustris-3



Model Result

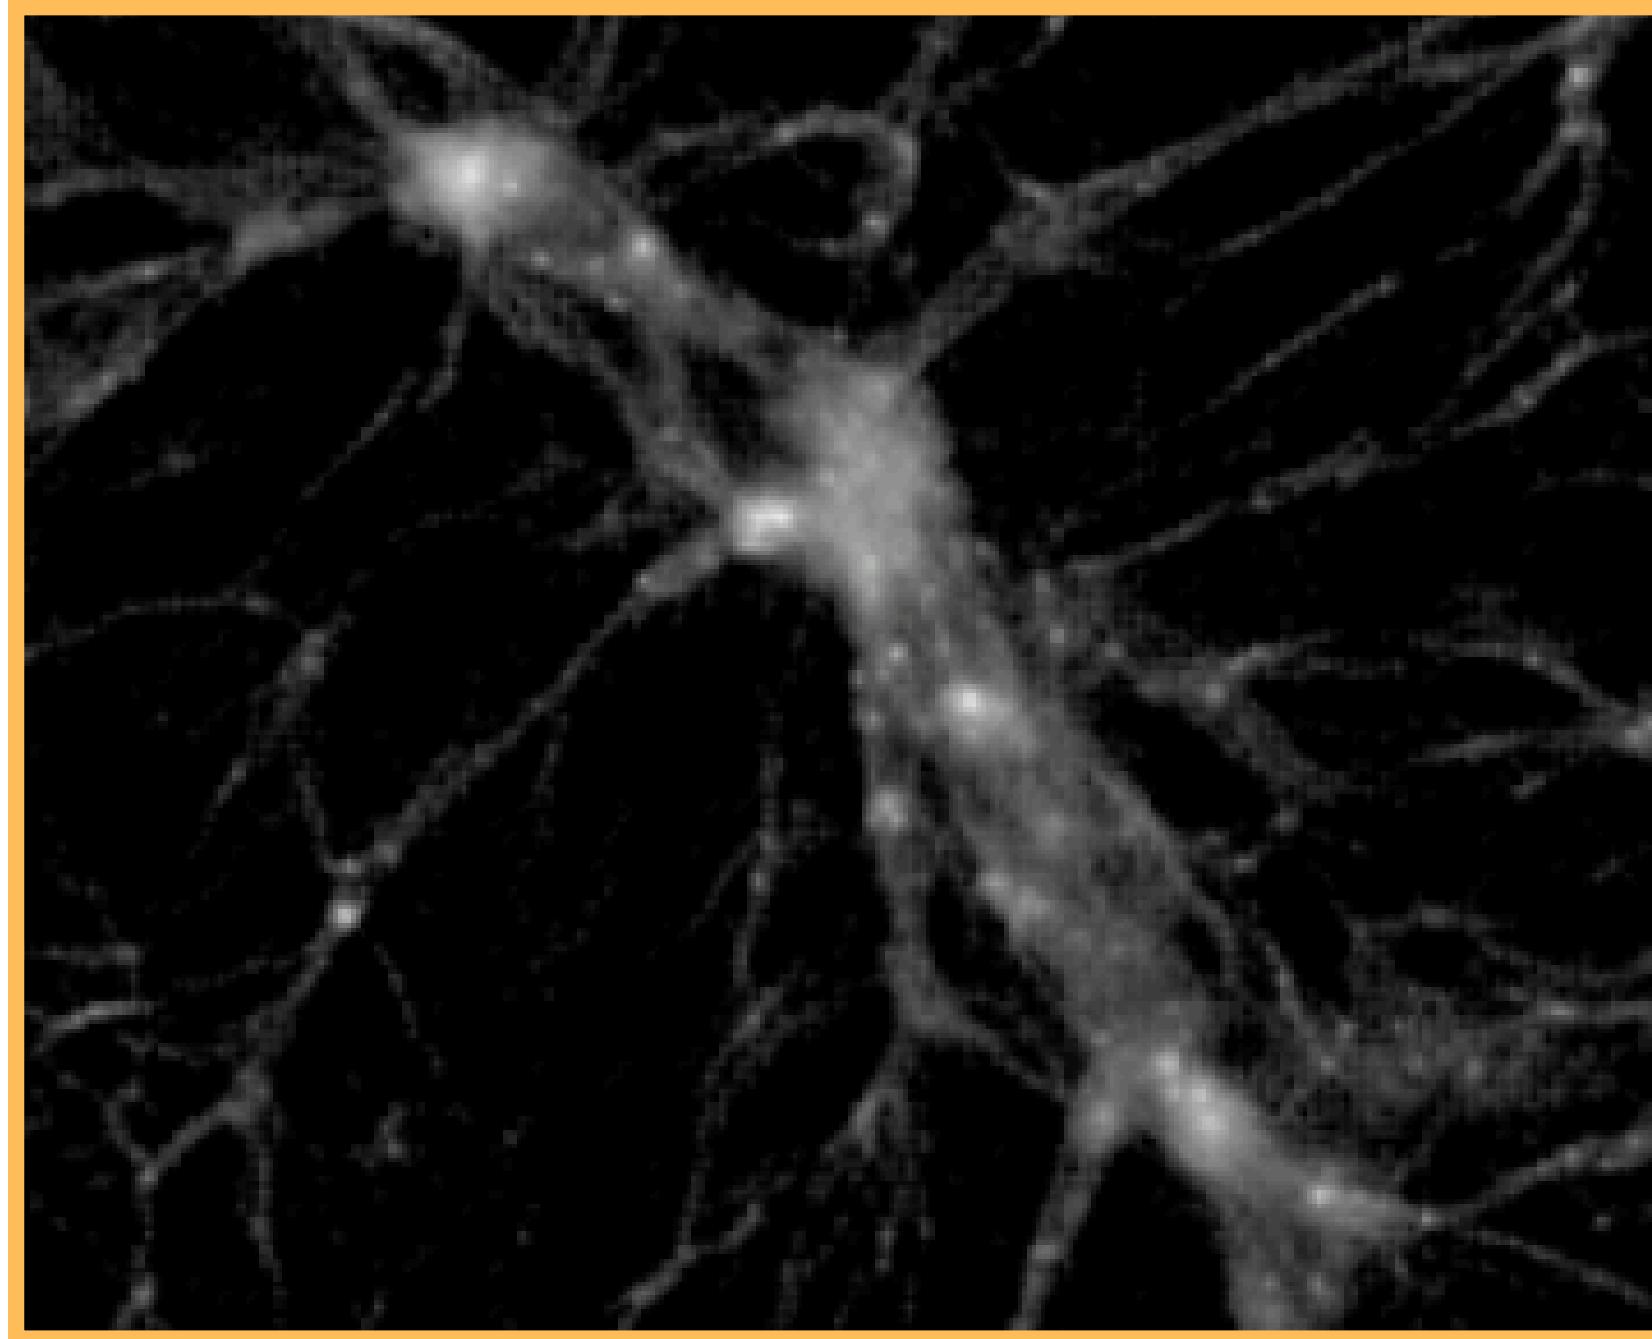




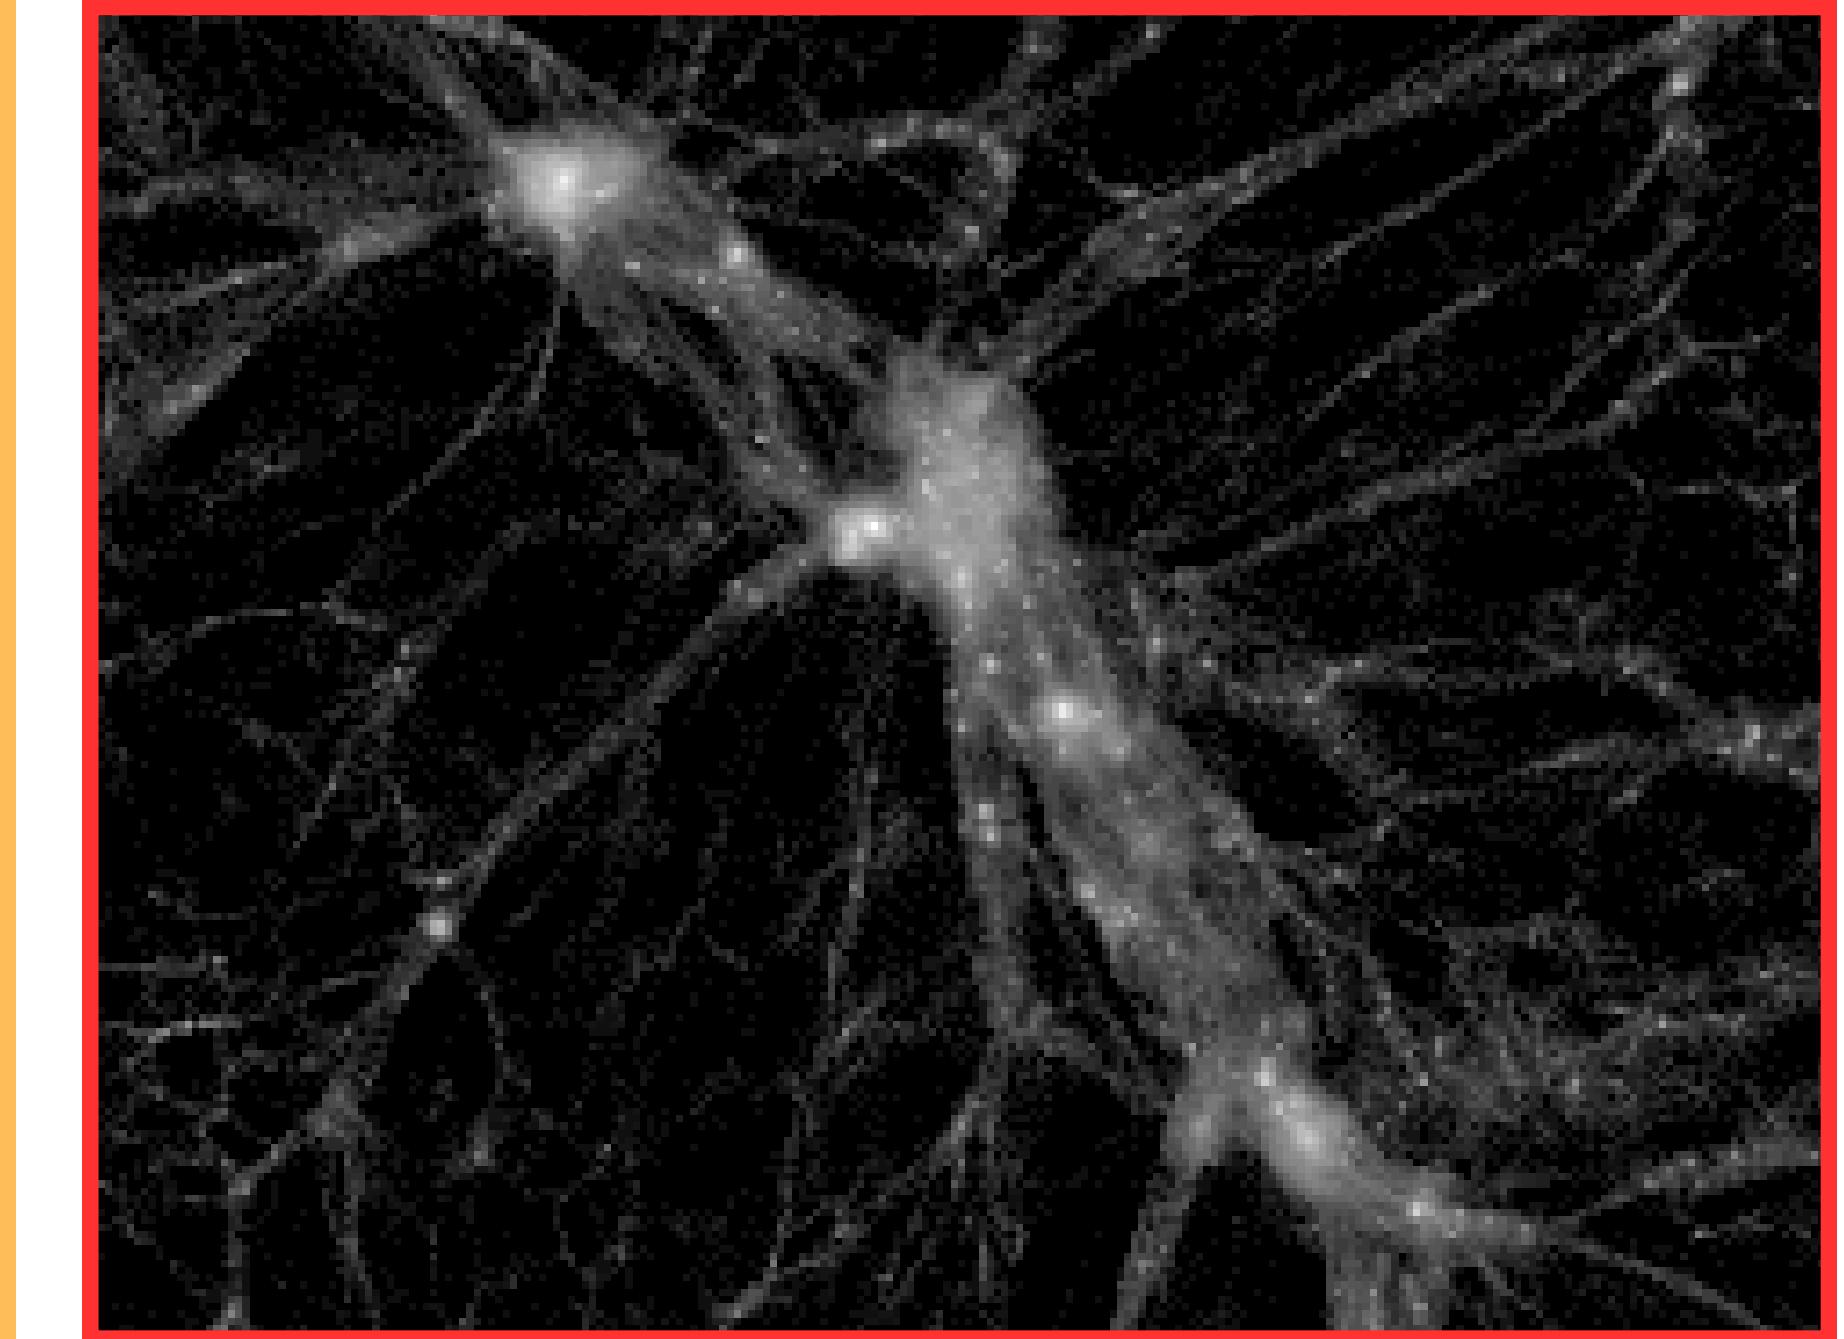
Resultados

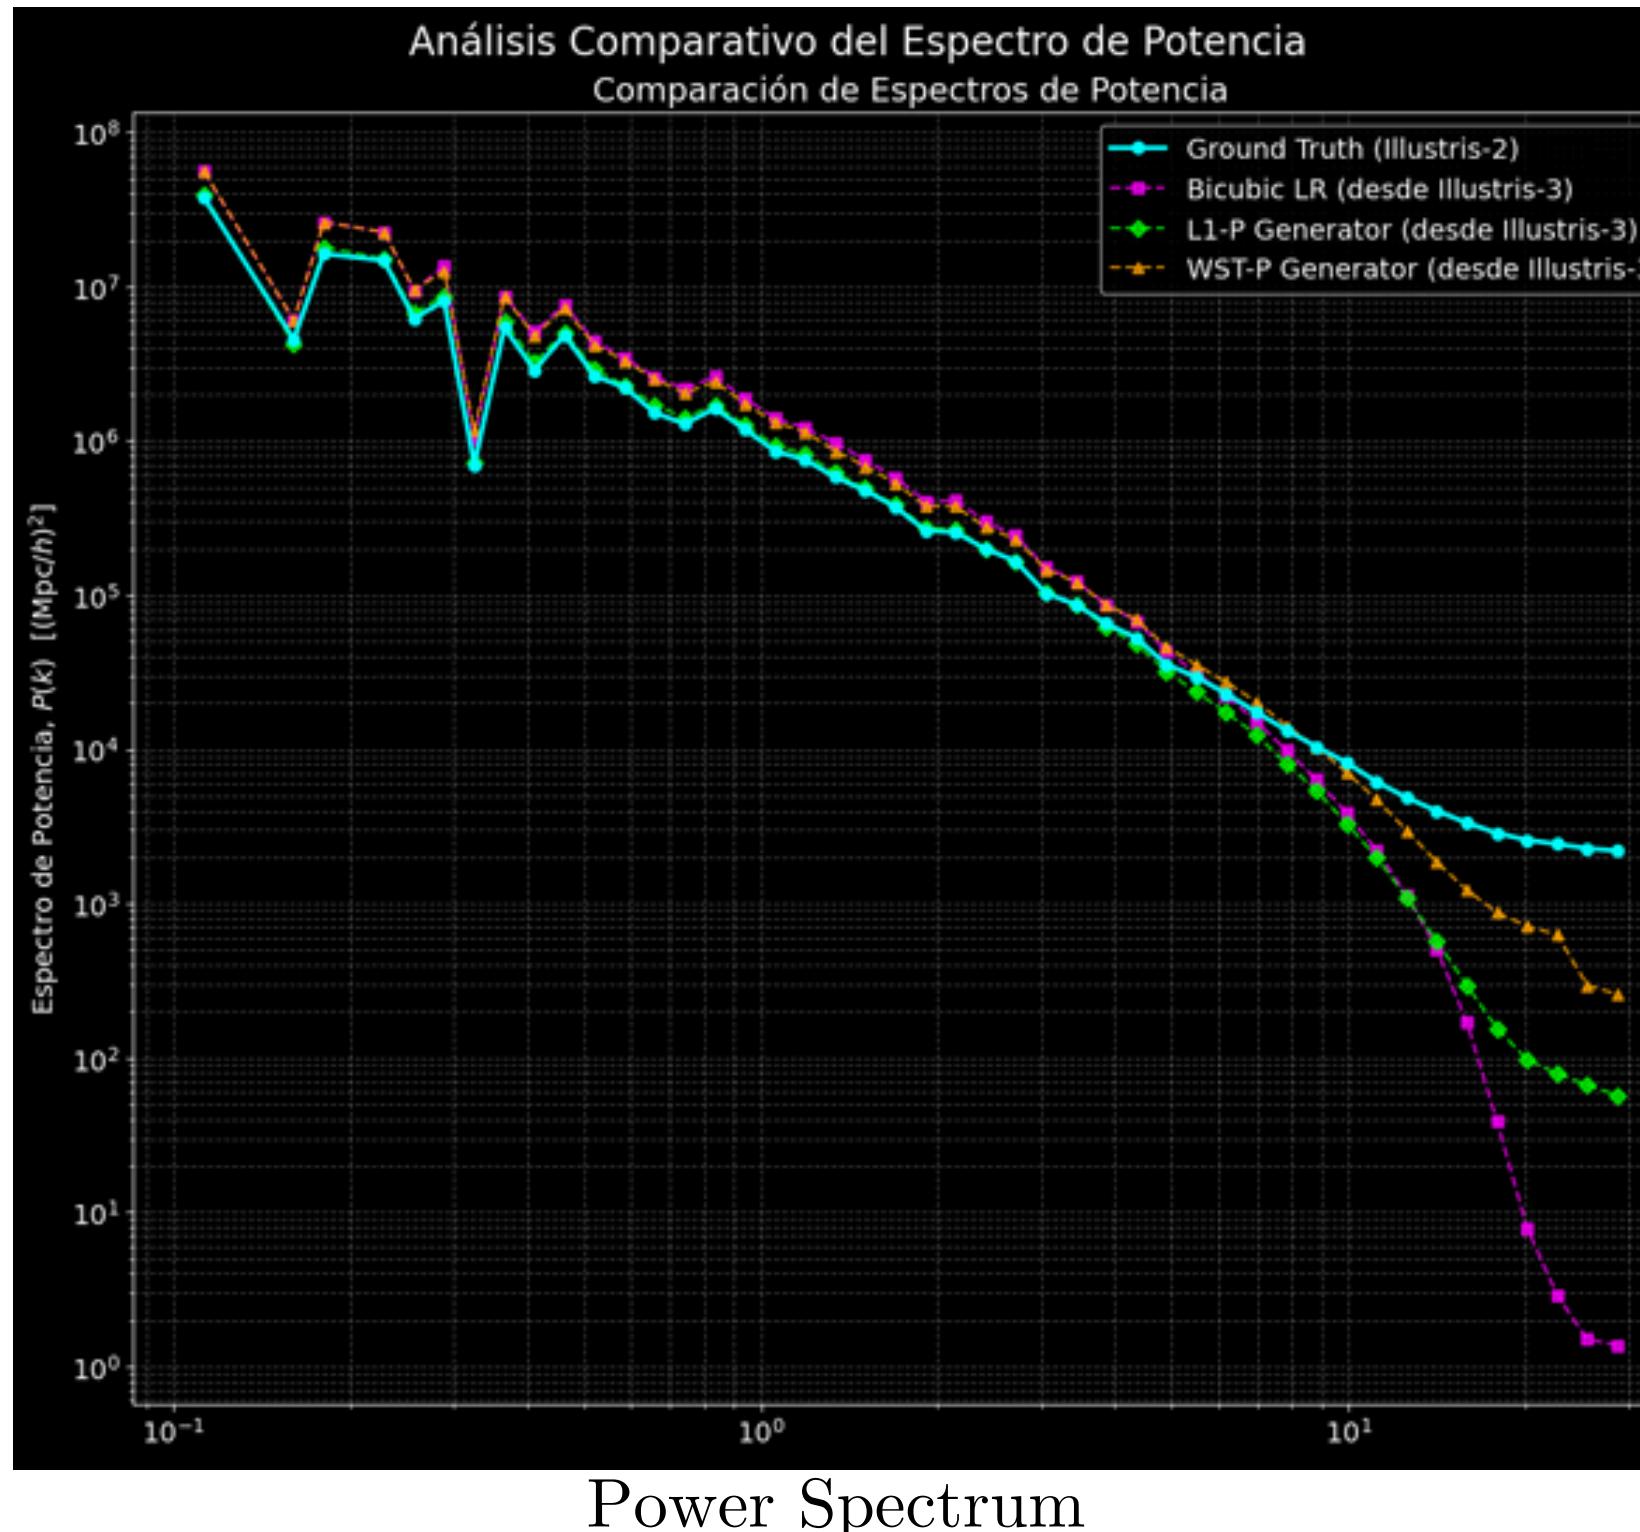
Evaluación

Model Result



Illustris 2





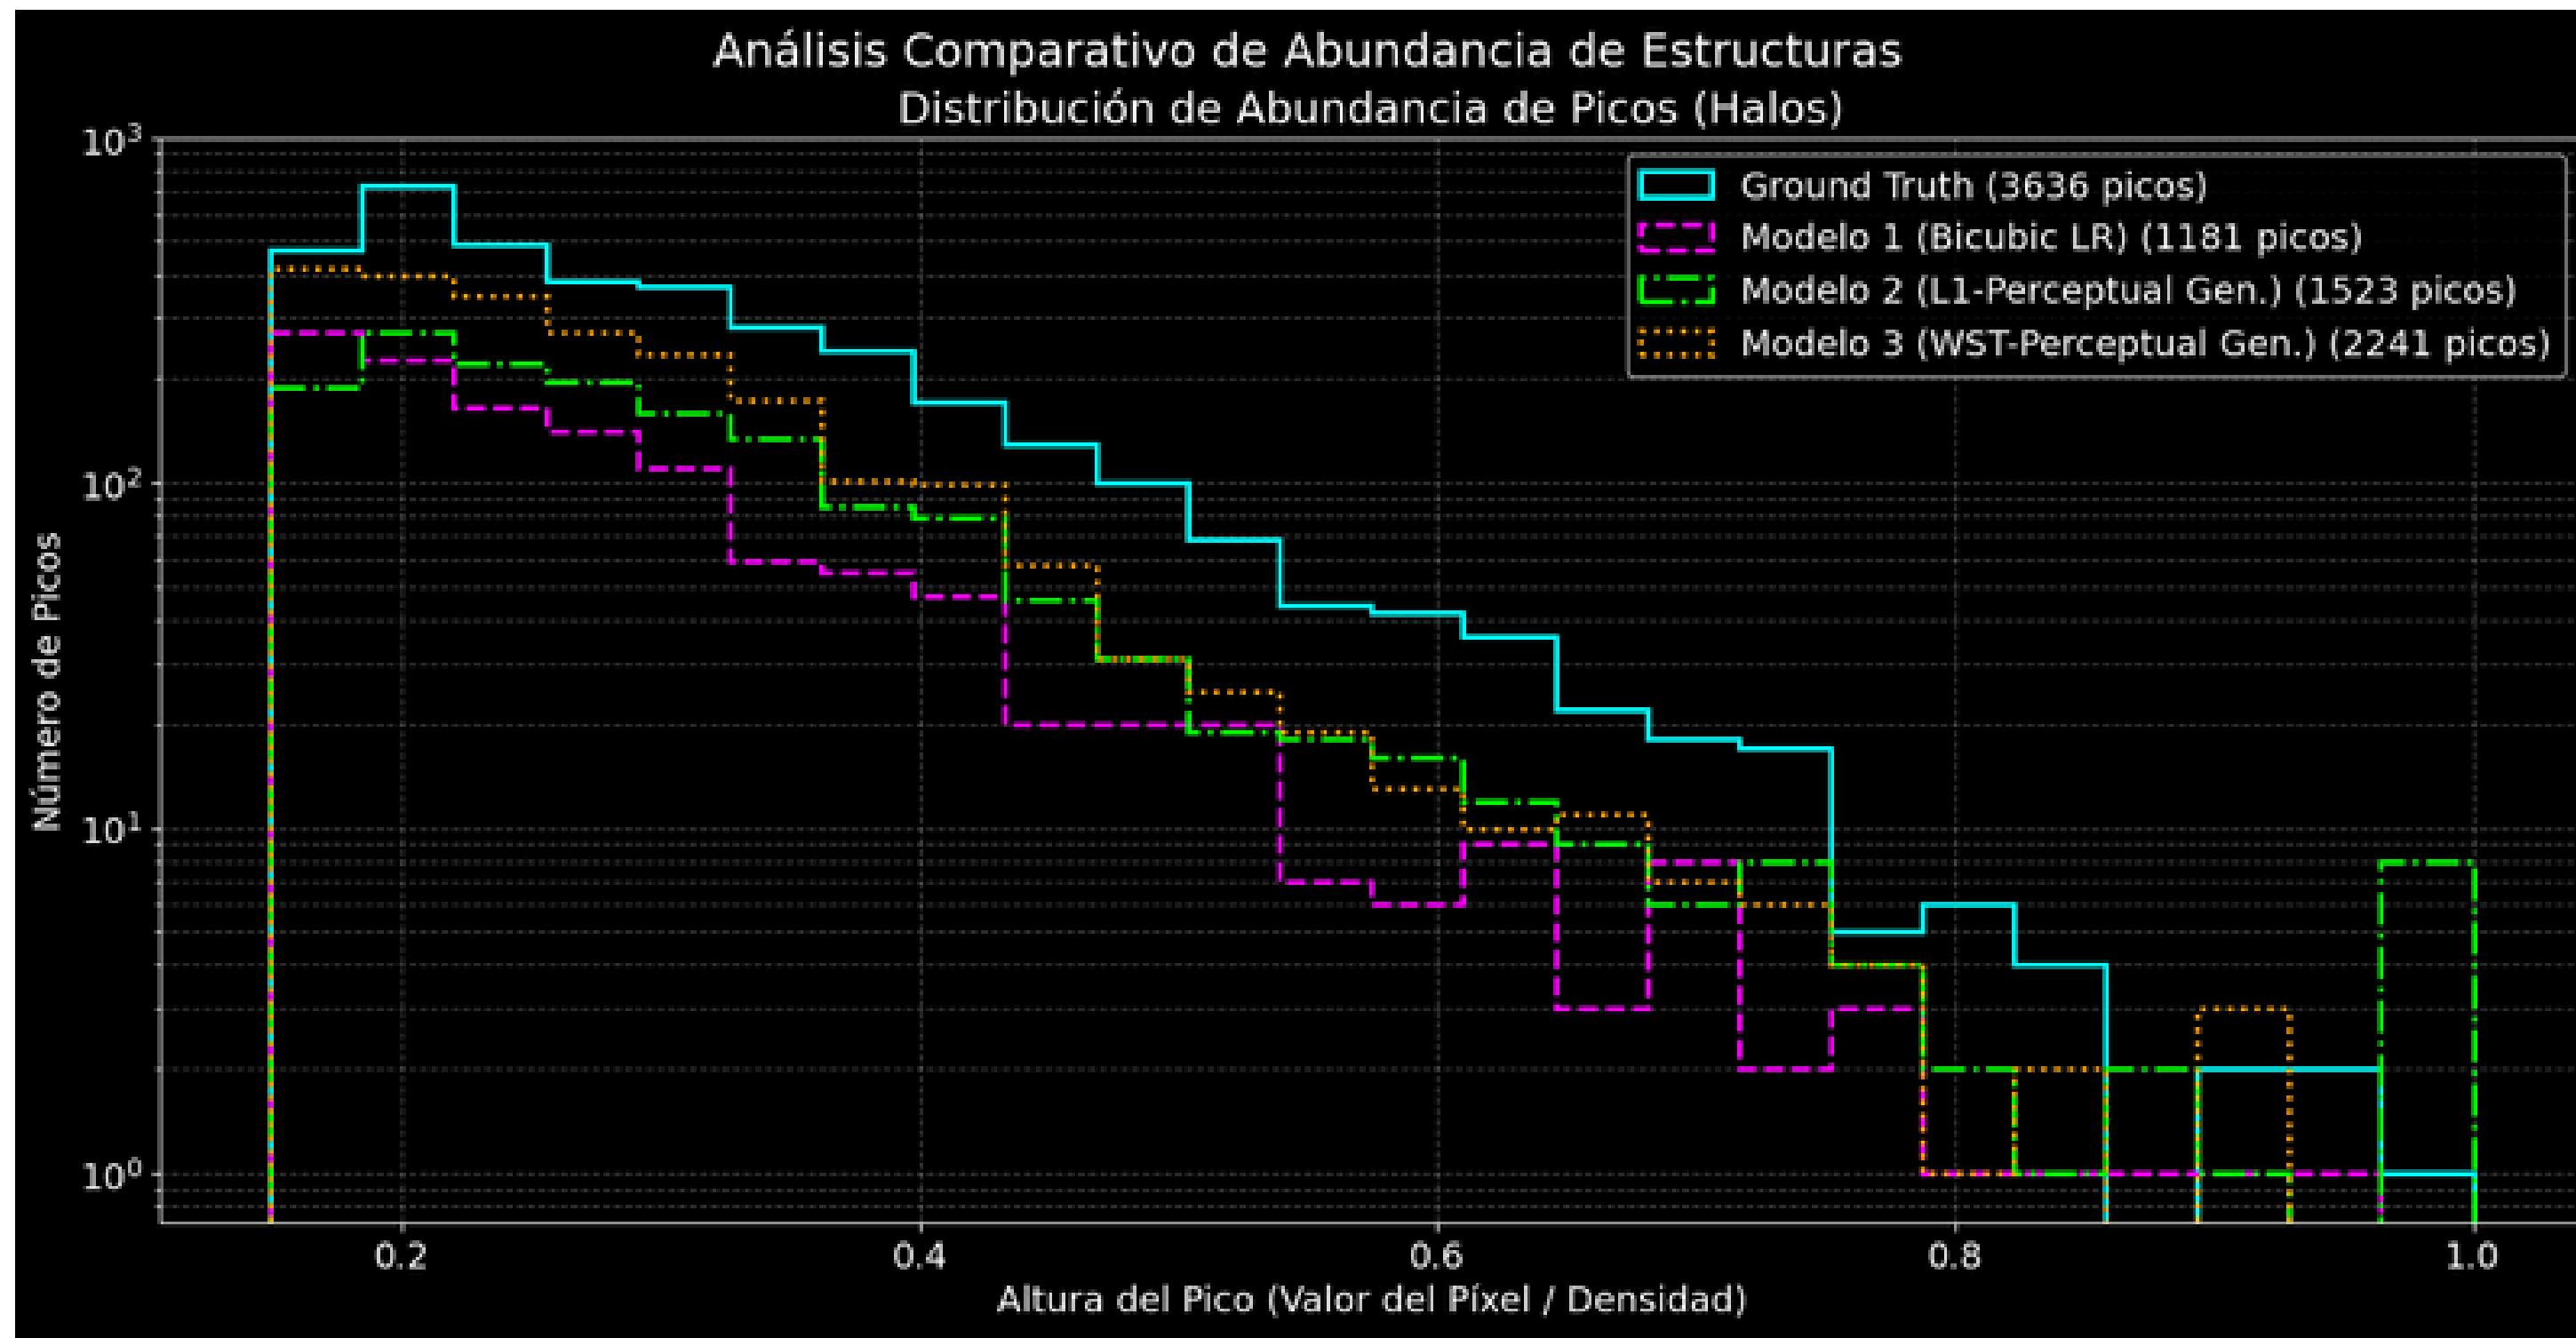
Espectro de Potencia ($P(k)$)

- Los modelos SR deben seguir la curva del Ground Truth (azul cian).
 - :Bicúbico (Magenta): Pierde severamente la potencia en escalas pequeñas ($k > 2 \text{ h/Mpc}$). Suaviza la imagen.
 - L1-Perceptual (Verde): Mejora significativamente, sigue mejor el Ground Truth hasta escalas intermedias.
 - WST-Perceptual (Naranja): Mejor rendimiento. Sigue al Ground Truth de forma muy cercana en un rango de escalas amplio, incluso en escalas más pequeñas ($k \approx 5-6 \text{ h/Mpc}$).

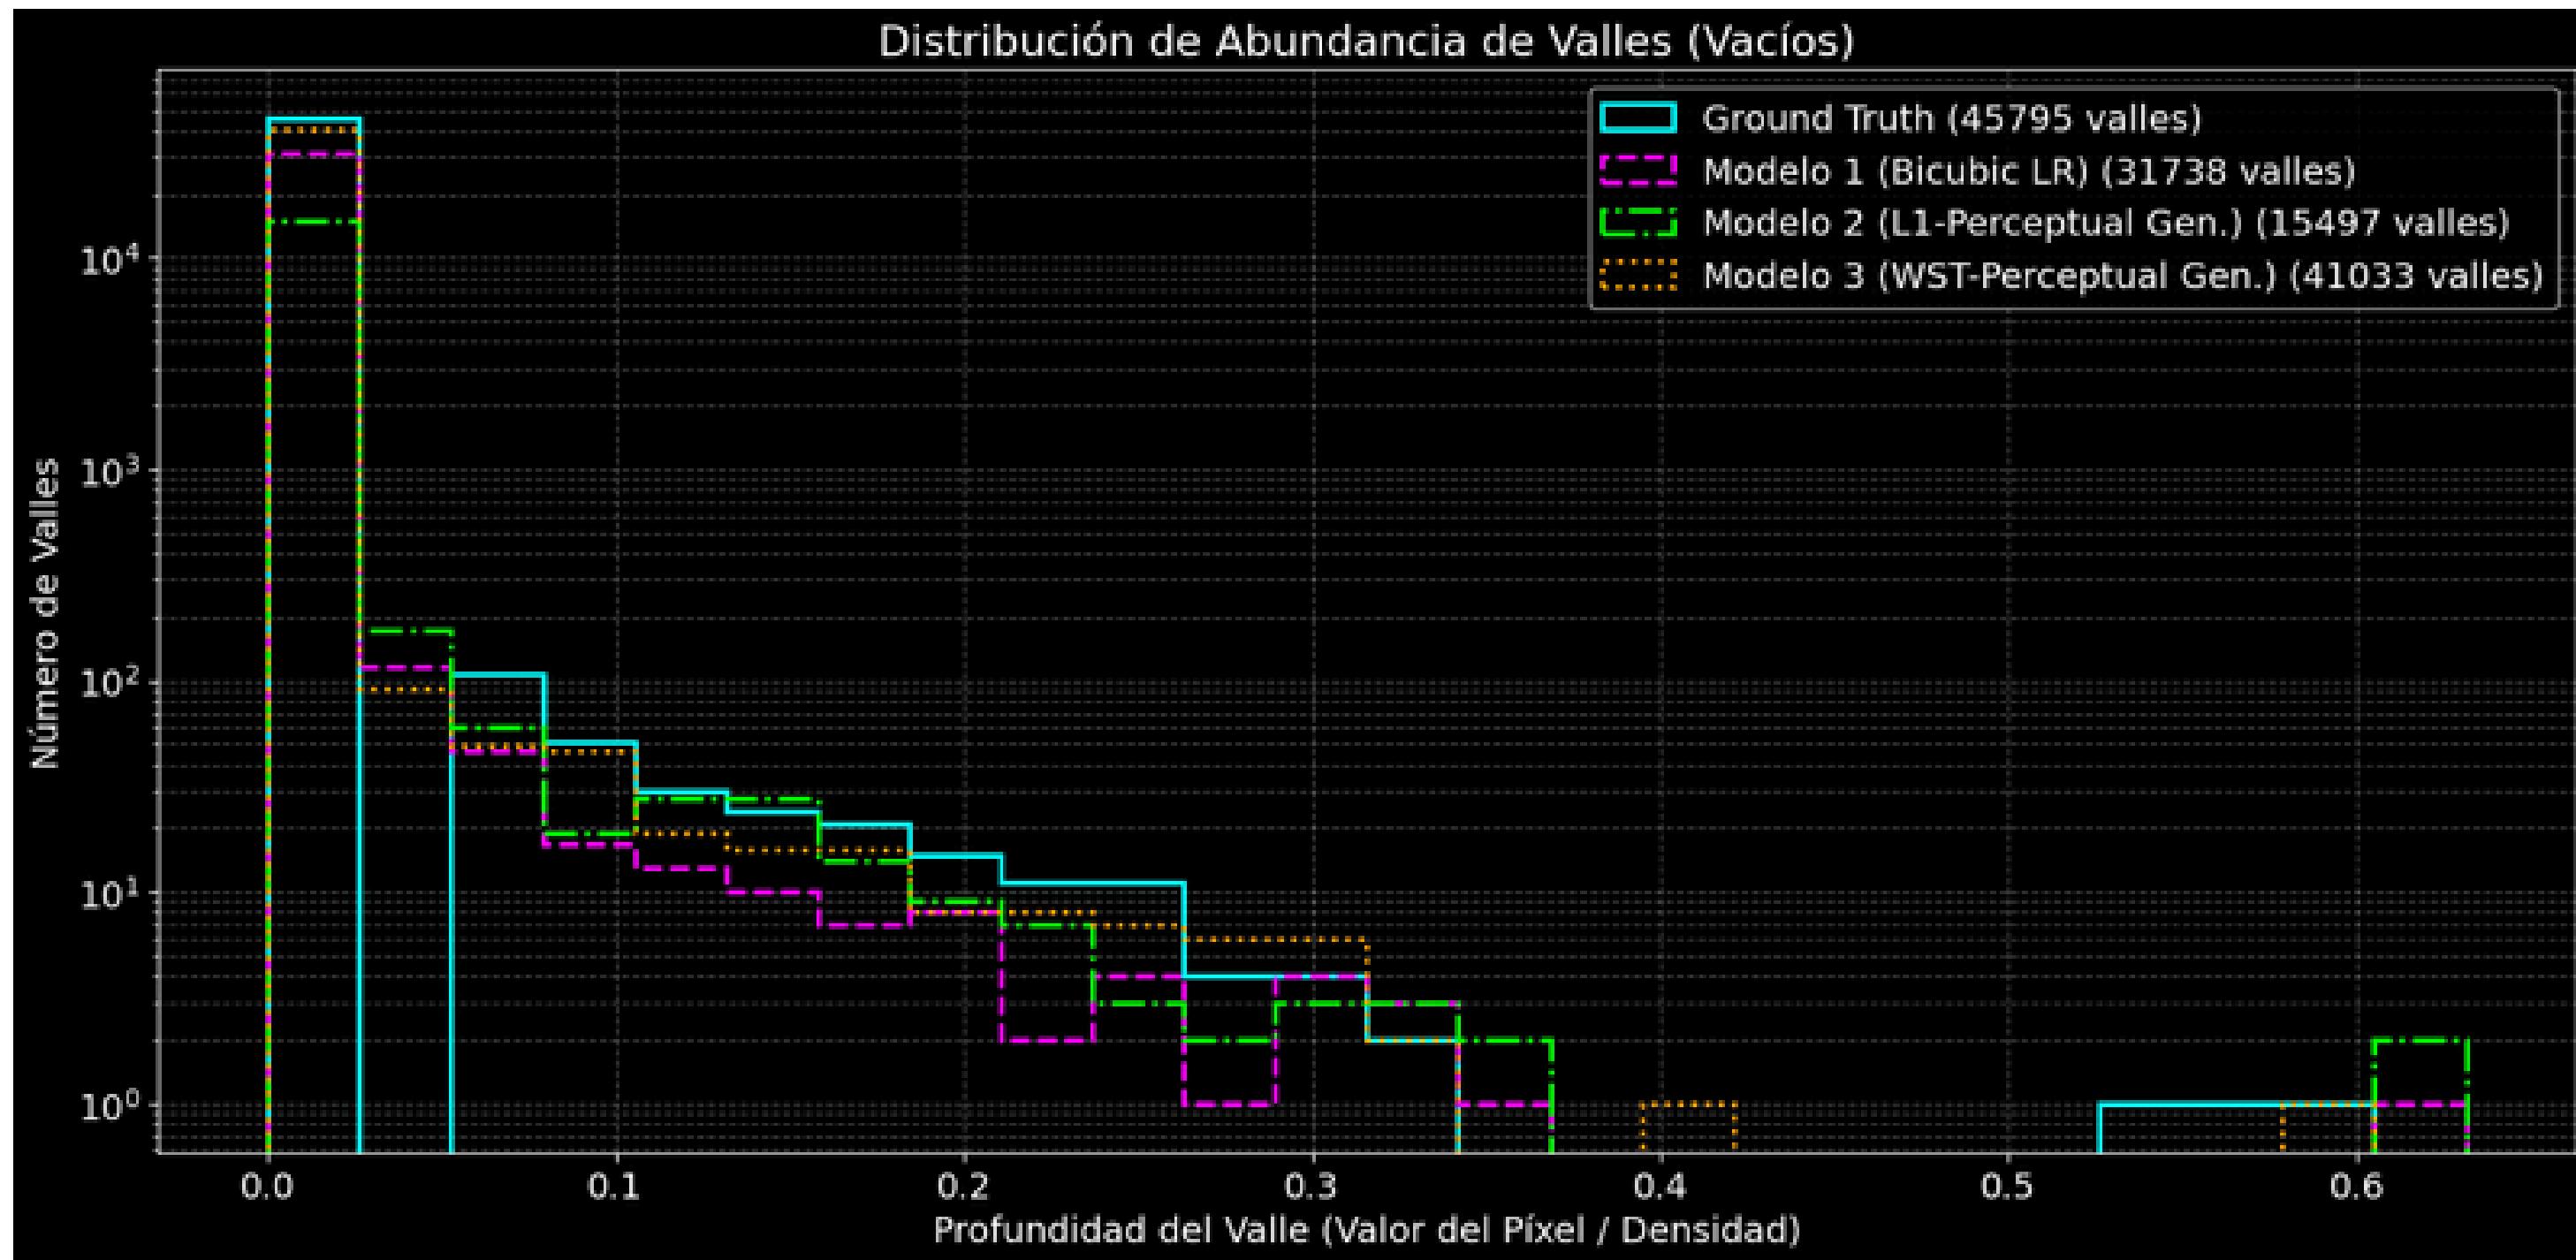


Metricas

Evaluación



Densidad de maximos

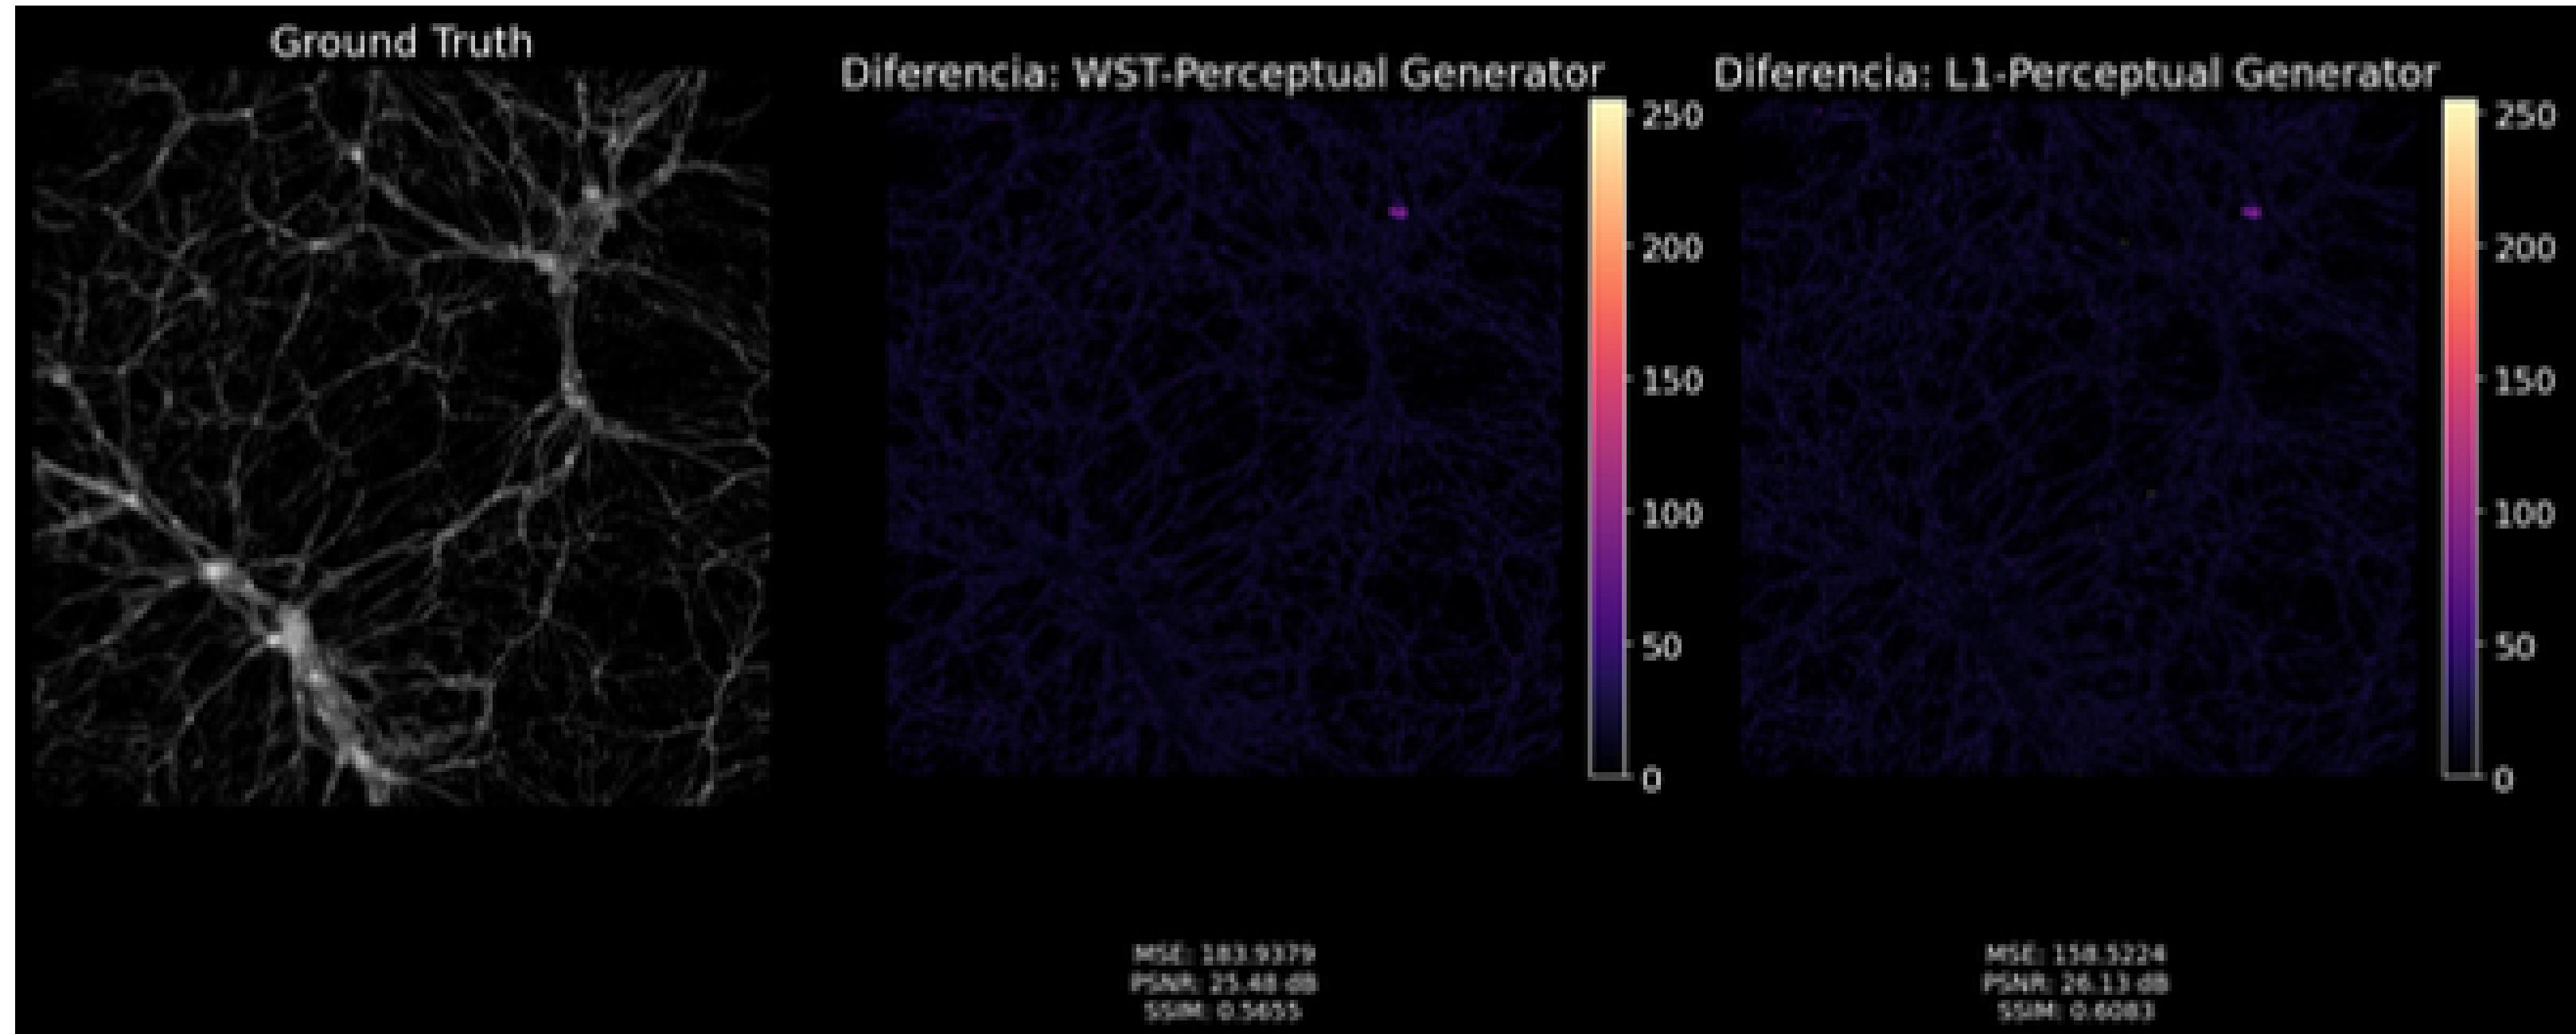


Densidad de valles



Metricas

Evaluación





Conclusiones

Evaluación

Nuestros análisis sugieren que la incorporación de WST en una red neuronal generativa demuestra un rendimiento robusto en la tarea de super-resolución para campos de densidad de materia oscura cosmológica.

Los resultados indican que este modelo logra preservar y reconstruir de manera más efectiva la distribución estadística presente en las simulaciones de alta resolución, el modelo ofrece una reconstrucción con una fidelidad considerable, lo que es alentador para la reproducción de propiedades físicas clave.

Si bien persisten desafíos en la reconstrucción precisa de las escalas más finas y complejas, estos avances sugieren el potencial para:

- Desarrollar herramientas que podrían complementar las simulaciones numéricas tradicionales, contribuyendo a una exploración más eficiente en las simulaciones cosmológicas.
- Generar datos de calidad que alimenten el entrenamiento de otros modelos de aprendizaje automático.
- Complementar simulaciones de baja resolución ya existentes



Conclusiones

Evaluación

Desafíos Clave para Futuras Mejoras:

- Mayor Capacidad del Modelo: Incrementar bloques residuales para capturar detalles finos y correlaciones complejas.
- Información de Entrada: Utilizar más coeficientes WST (mayor J) para una representación más rica de escalas pequeñas.
- Implementación en 3D: Extender el modelo a tres dimensiones, lo que implica un aumento exponencial en la complejidad computacional y de memoria.
- Recursos de Entrenamiento: Requiere significativamente más GPUs y tiempo para entrenar modelos más grandes y procesar datos de mayor dimensionalidad.

¡Gracias por su atención!

Espacio de preguntas



Fuentes

1. Akarsu, Ö., Ó Colgáin, E., Özüker, E., Thakur, S., & Yin, L. (2023). Inevitable manifestation of wiggles in the expansion of the late Universe. arXiv:2207.10609v2.
2. Andén, J., & Mallat, S. (2014). Deep scattering spectrum. arXiv:1304.6763v2.
3. Bruna, J., & Mallat, S. (2012). Invariant scattering convolution networks. arXiv:1203.1513v2.
4. Cheng, S., Morel, R., Ally, E., Ménard, B., & Mallat, S. (2024). Scattering spectra models for physics. arXiv:2306.17210v2.
5. Escamilla, L. A., Özüker, E., Akarsu, Ö., Di Valentino, E., & Vázquez, J. A. (2024). Do we need wavelets in the late Universe? arXiv:2408.12516v1.



Fuentes

6. Ledig, C., Theis, L., Huszár, F., Caballero, J., Cunningham, A., Acosta, A., Aitken, A. P., Tejani, A., Totz, J., Wang, Z., & Shi, W. (2017). Photo-realistic single image super-resolution using a generative adversarial network. arXiv:1609.04802v5.
7. Li, Y., Modi, C., & White, M. (2020). AI-assisted super-resolution cosmological simulations. arXiv:2010.06608v2.
8. Marinescu, R. V., Moyer, D., & Golland, P. (2021). Bayesian image reconstruction using deep generative models. arXiv:2012.04567v5.
9. Sabogal, M. A., Silva, E., Nunes, R. C., Kumar, S., & Di Valentino, E. (2025). Sign switching in dark sector coupling interactions as a candidate for resolving cosmological tensions. arXiv:2501.10323v1.



Fuentes

10. Soberanes Soberanes, H. V. (2020). A generative model approach to N-body simulations in cosmology. Unpublished manuscript.
11. Valogiannis, G., & Dvorkin, C. (2022). Towards an optimal estimation of cosmological parameters with the wavelet scattering transform. Physical Review D, 105(10), 103534.

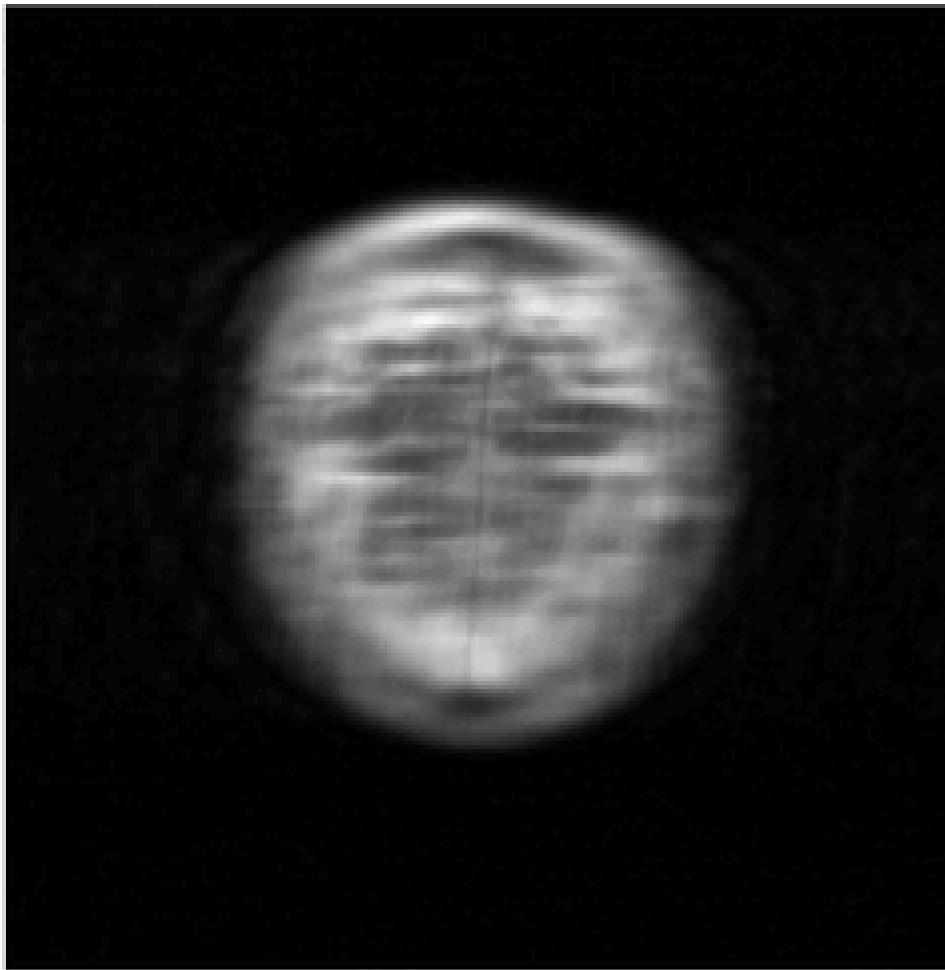


Anexo

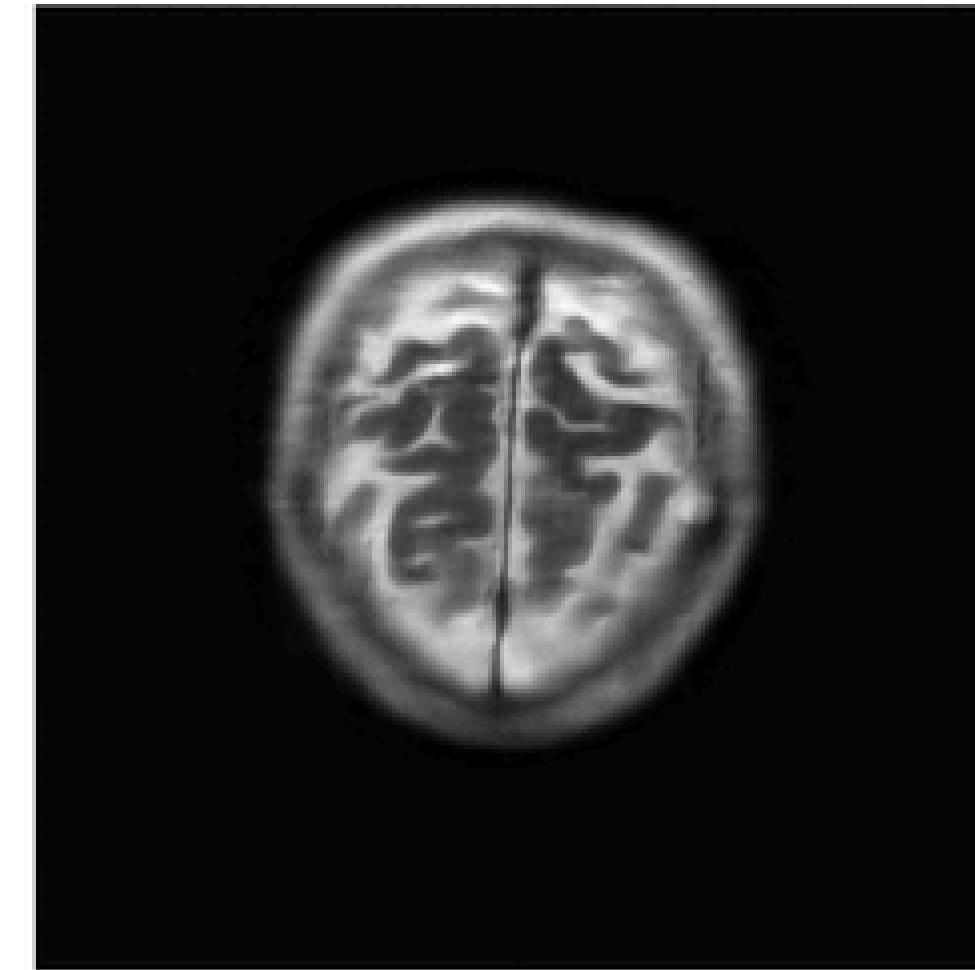
Resonancias magnéticas

En conjunto con el Laboratorio Avanzado de Análisis de imágenes de la facultad de ingeniería se esta estudiando la generación, aplicación e implementación del modelo para disminuir el tiepo de adquisición en resonancias magnéticas

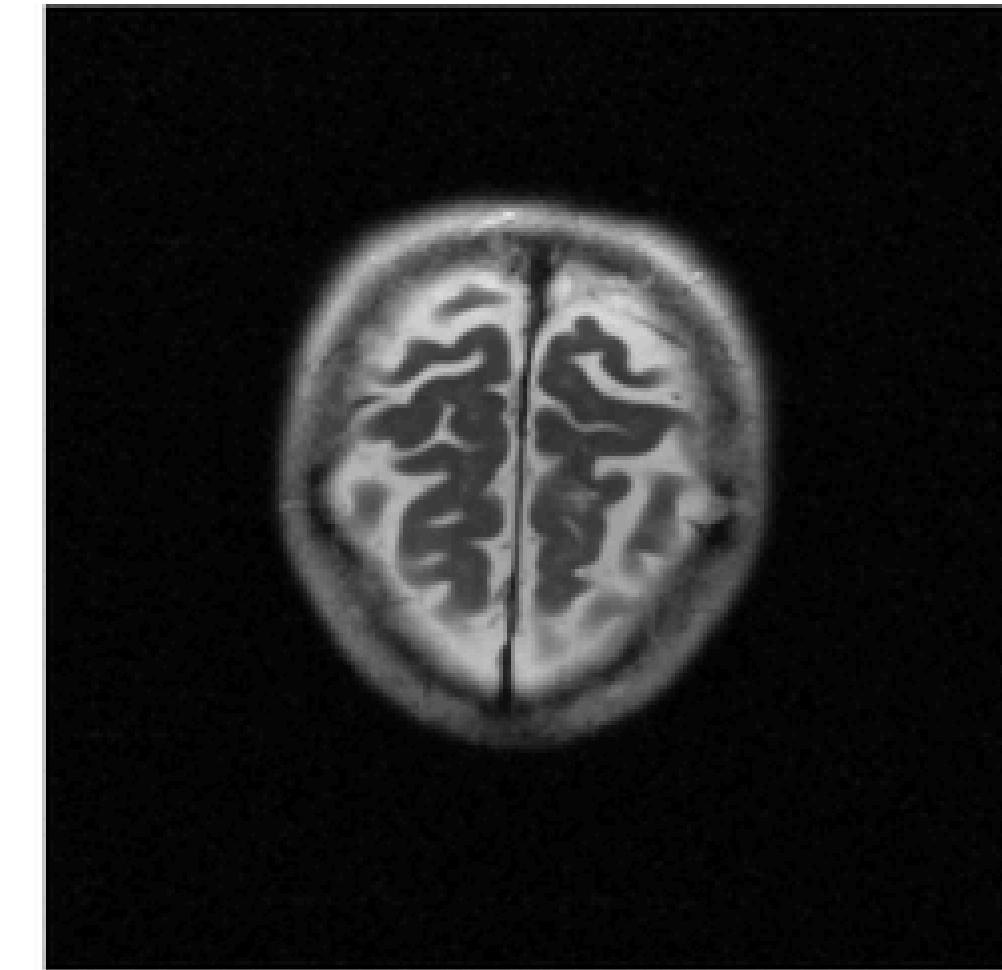
1/4 Adquisition Time



Model Result



Ground Truth



MSE: 0.0222, PSNR: 16.53, SSIM: 0.571

MSE: 0.0037, PSNR: 24.33, SSIM: 0.734

MSE: 0.0000, PSNR: inf, SSIM: 1.000